Deep Learning101

변분오토인코더

Variational AutoEncoder

VAEs

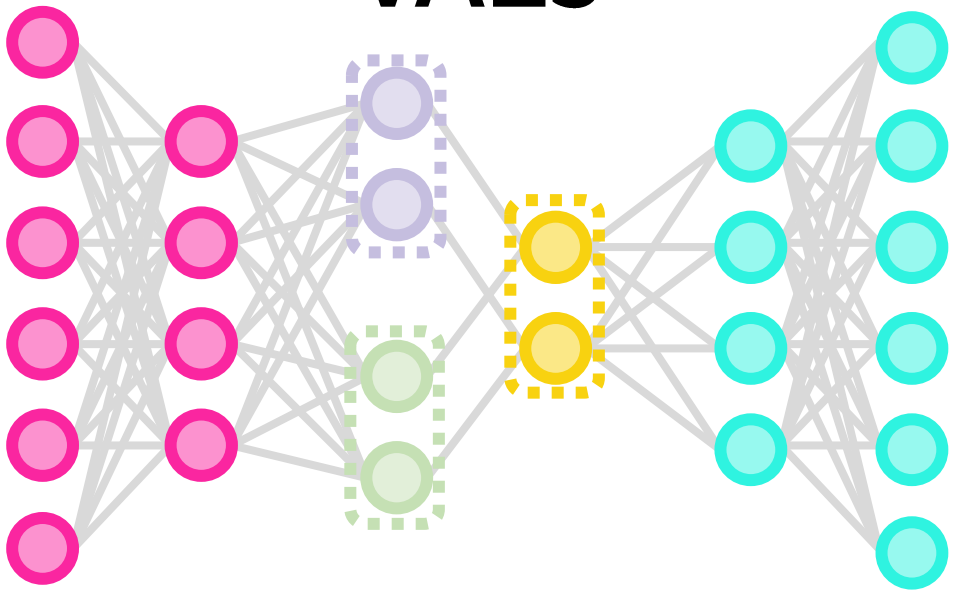

신박AI

안녕하세요 여러분! 신박AI입니다

신박AI

오늘은 Variational AutoEncoder,
줄여서 VAE에 대해
이야기해 보려고 합니다.

신박AI

VAE는 딥러닝에서 정말 중요한 개념 중 하나인데요, 특히 생성 모델 분야에서 많이 사용됩니다.

오늘 영상에서는 VAE가 무엇인지,
어떻게 동작하는지, 그리고 왜 중요
한지 하나씩 살펴보겠습니다.

먼저, 오토인코더의 기본 개념부터 시작해 보도록 하겠습니다.

오토인코더는 입력 데이터를 압축하고 다시 원래 형태로 복원하는 과정을 학습하는 신경망입니다.

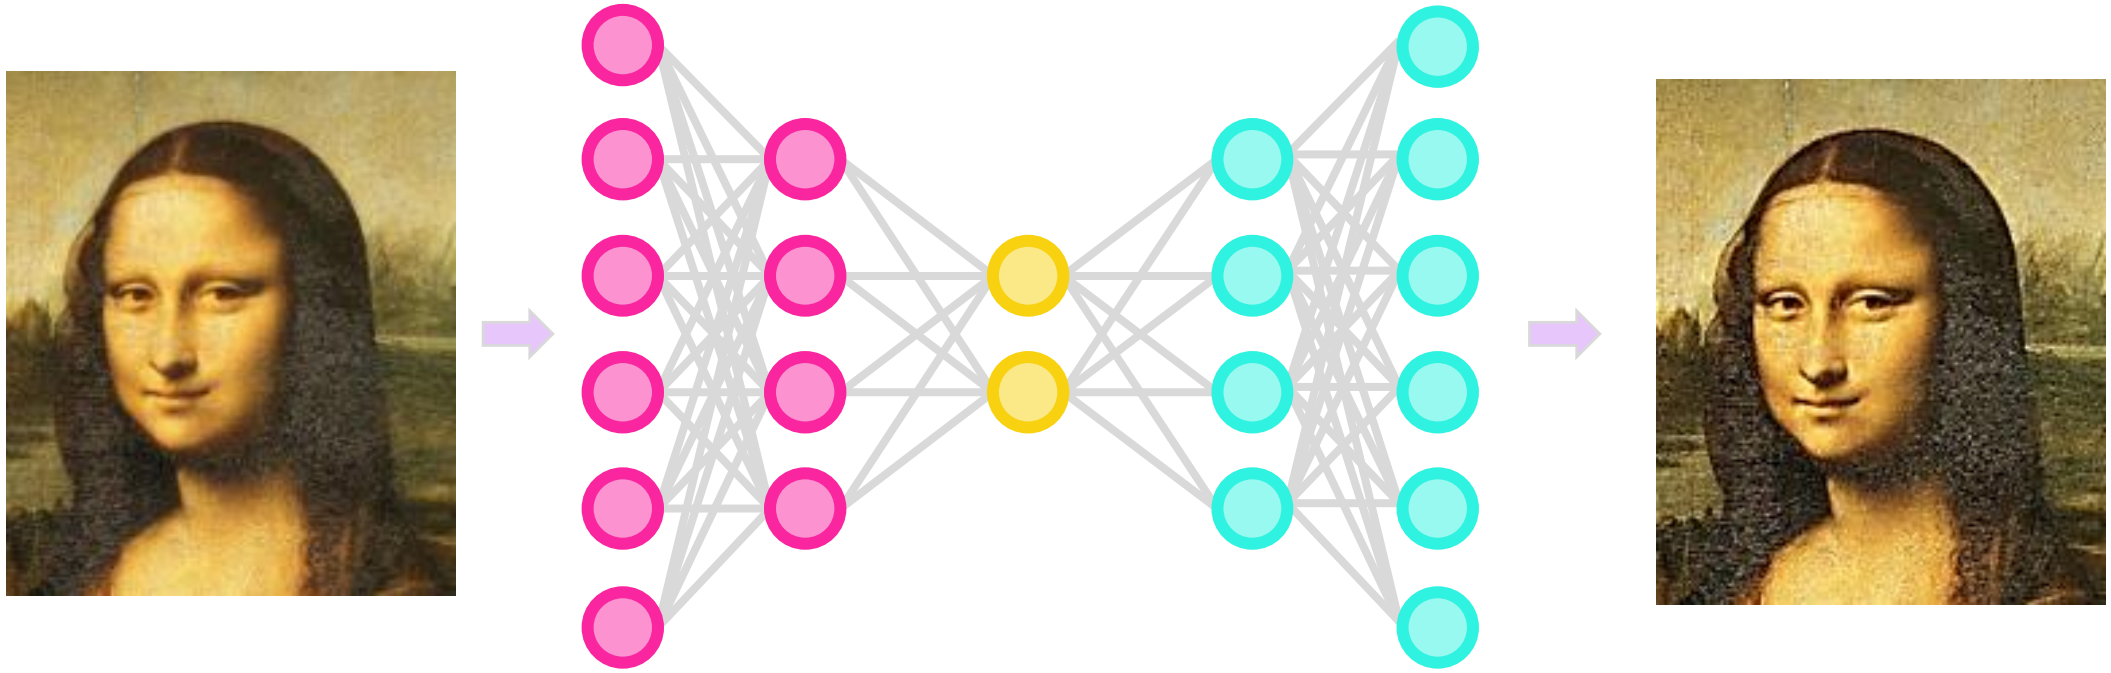

간단히 말해, 데이터를 압축하고 복원하는 과정에서 중요한 특징들을 학습하는 것이죠.

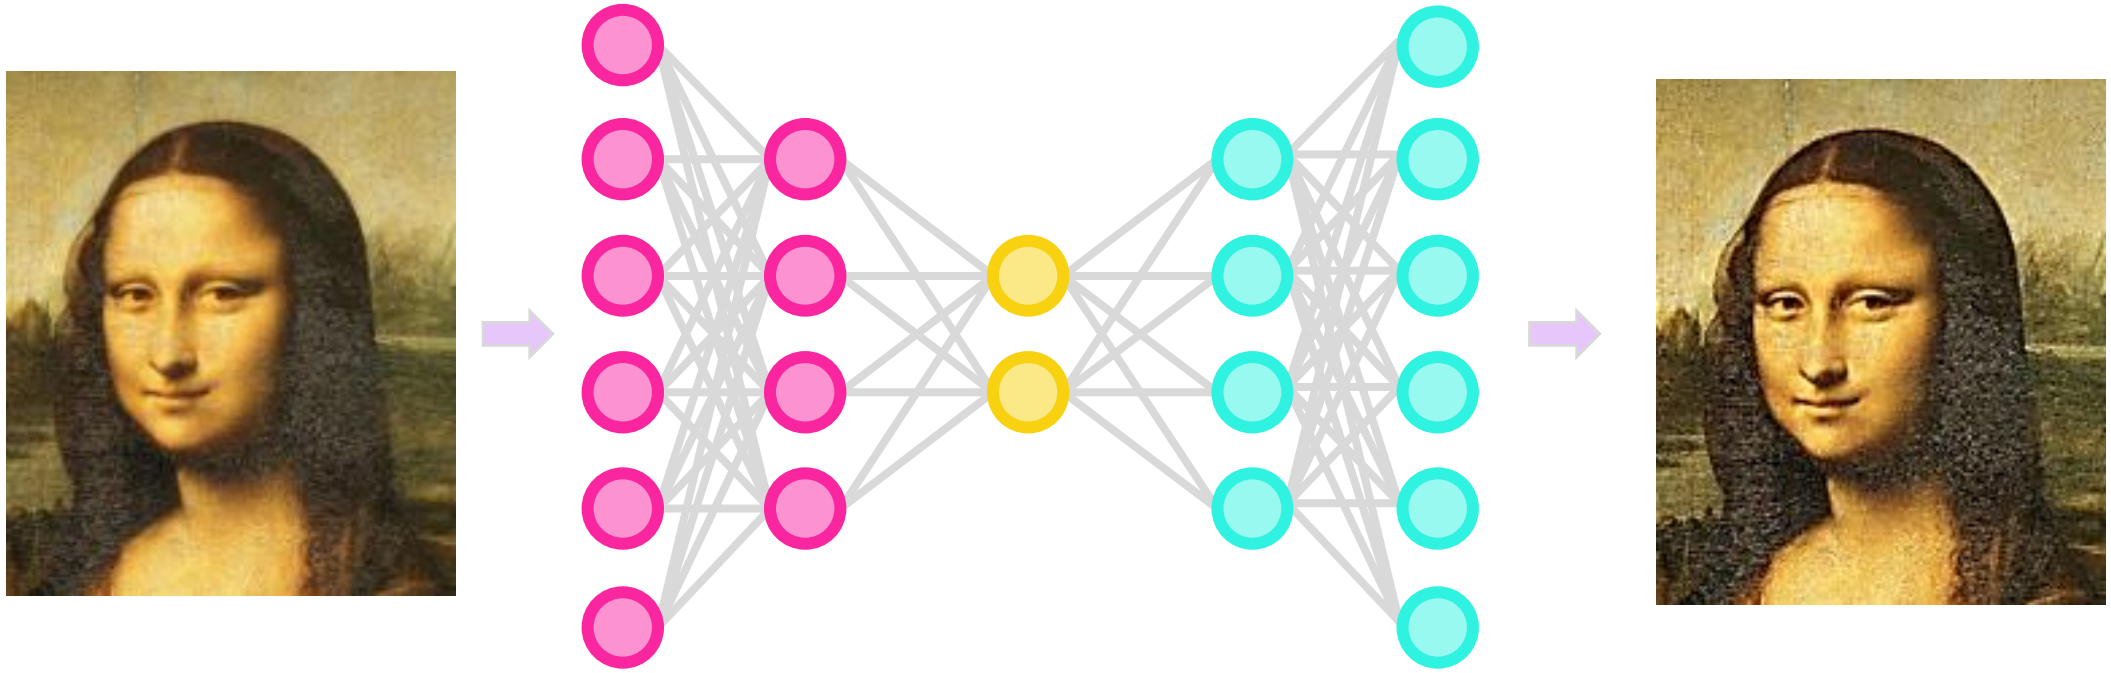

신박AI

예를 들어, 이미지의 경우 중요한 특징들을 압축하여 잠재공간에 표현하게 됩니다.

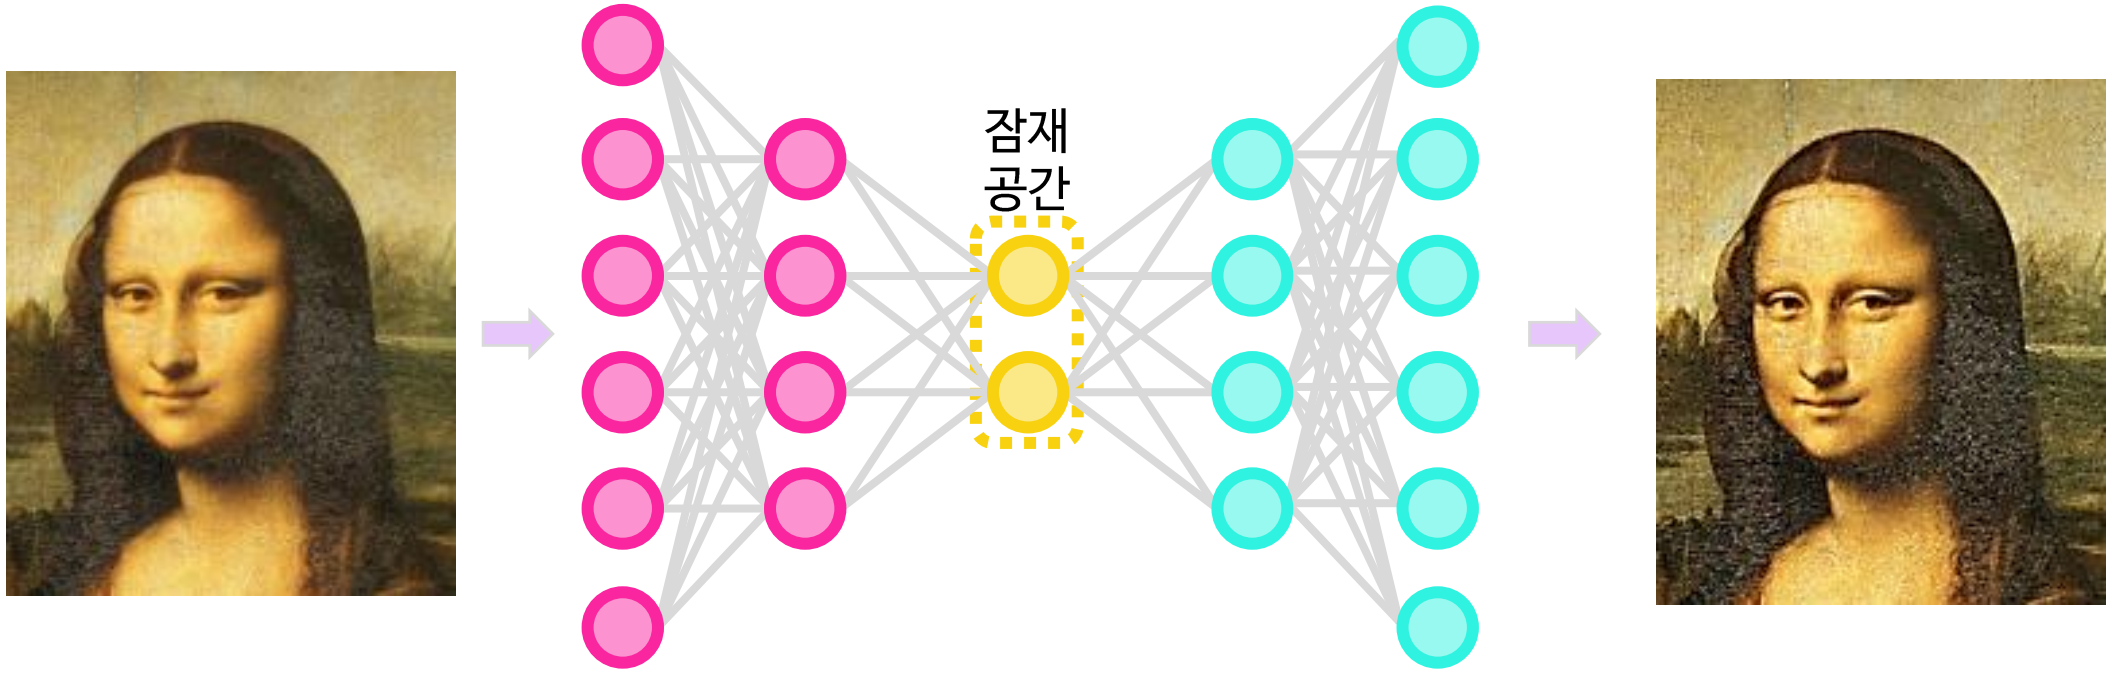

신박AI

이렇게 압축된 표현은 원래 이미지의 중요한 정보를 담고 있어서,

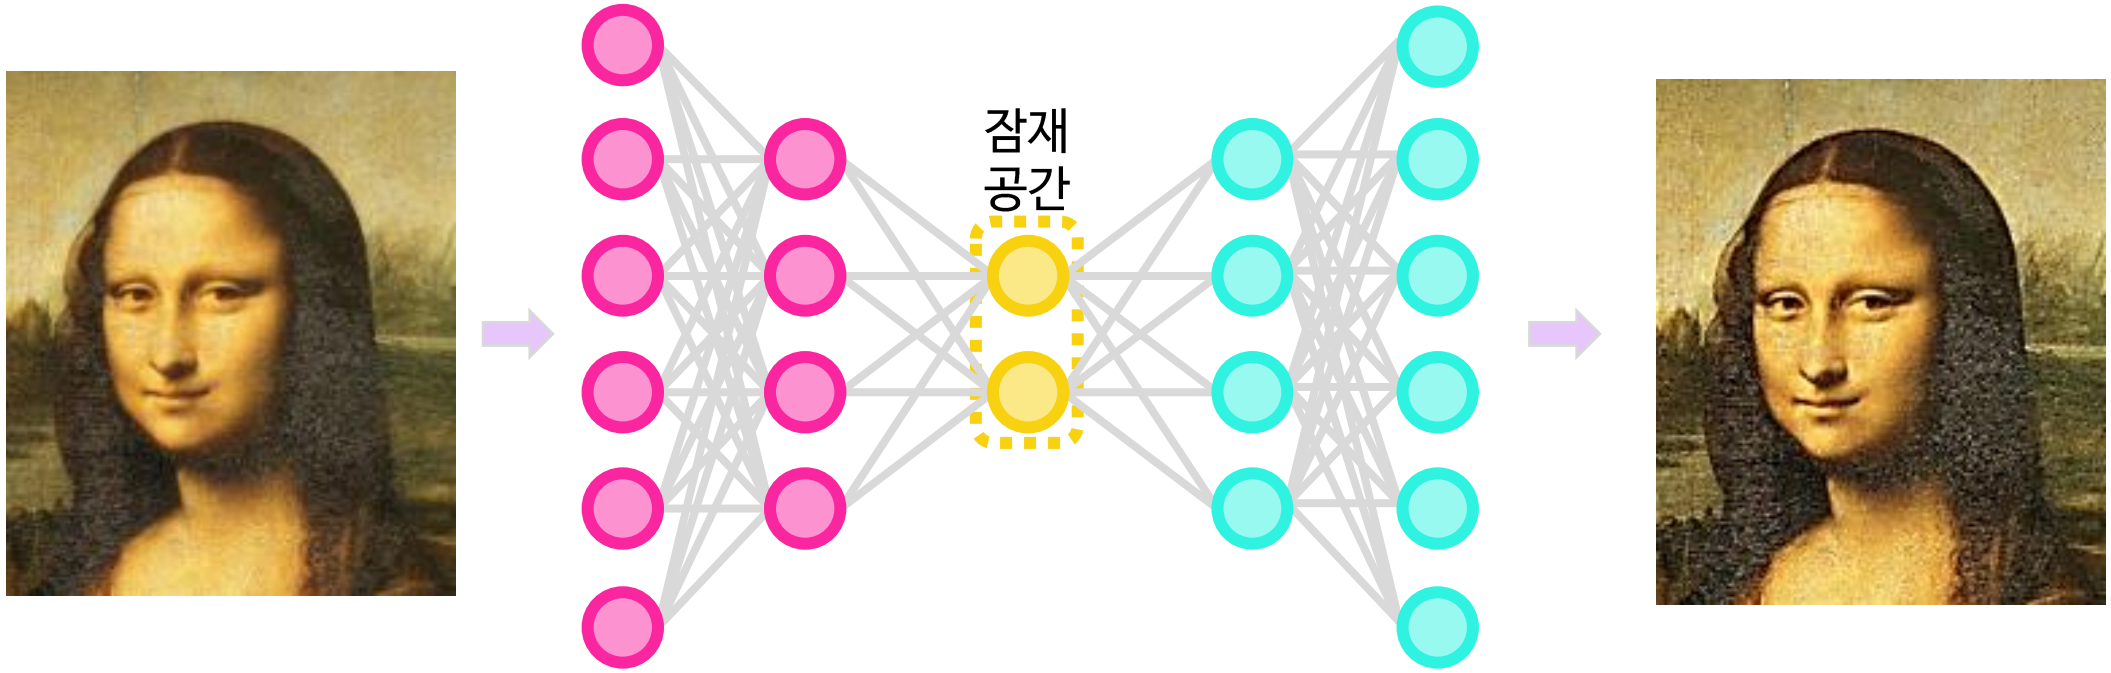

신박AI

노이즈 제거와 같은 작업이라든지,

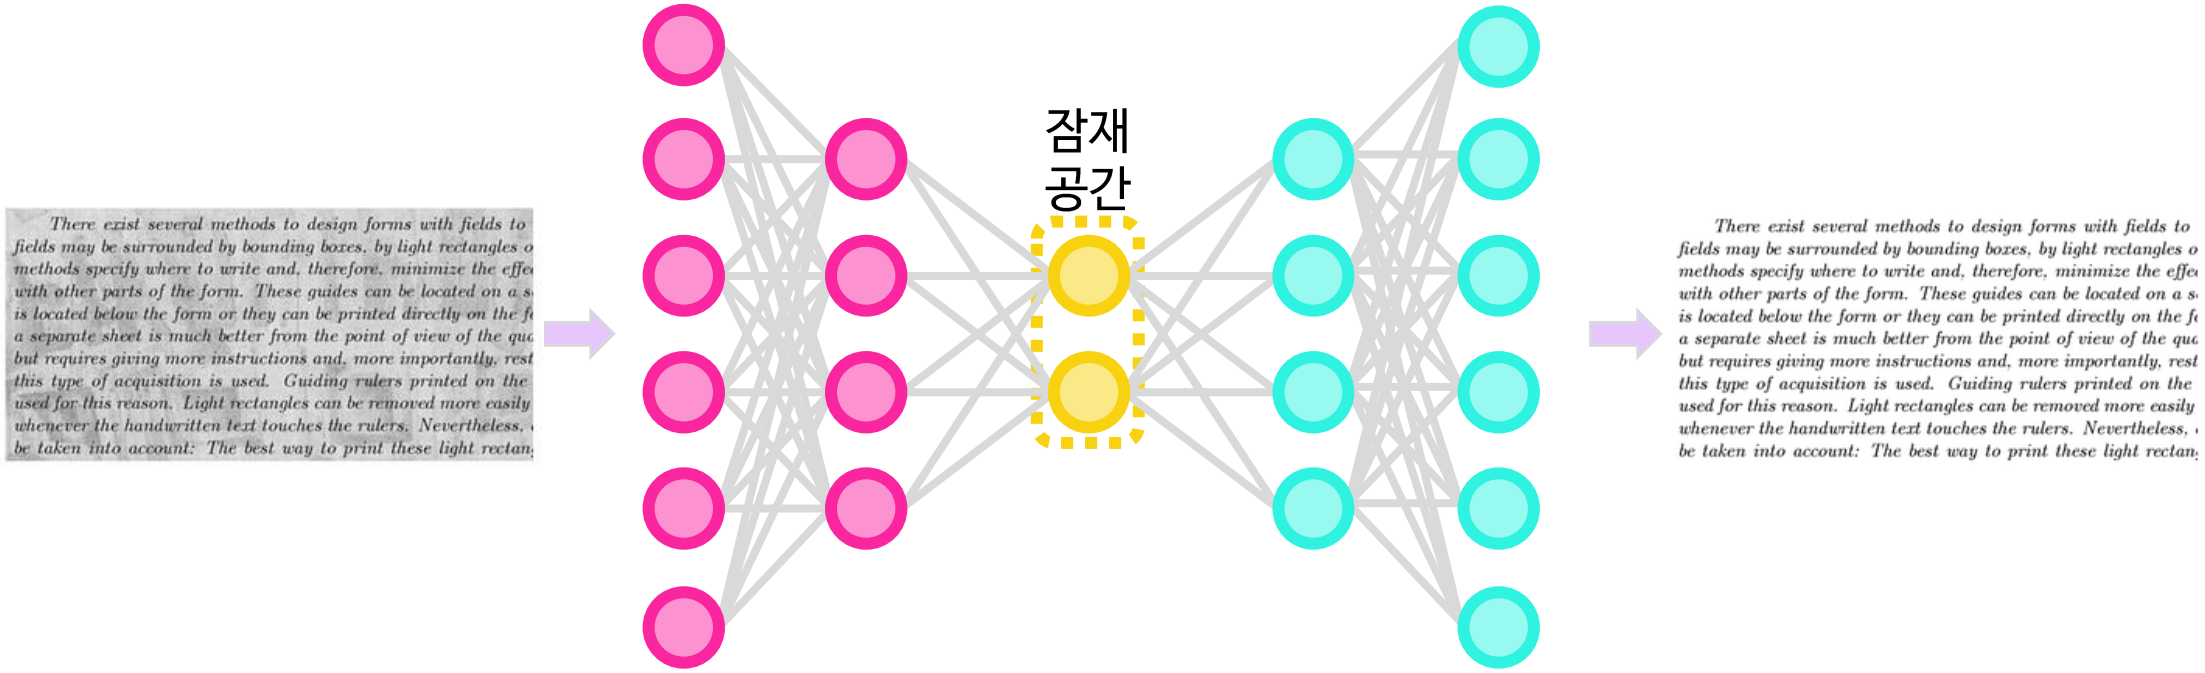

신박AI

흑백 이미지의 컬러를 복원하는데 사용되는 등 여러가지 쓰임새가 많은 신경망이었습니다.

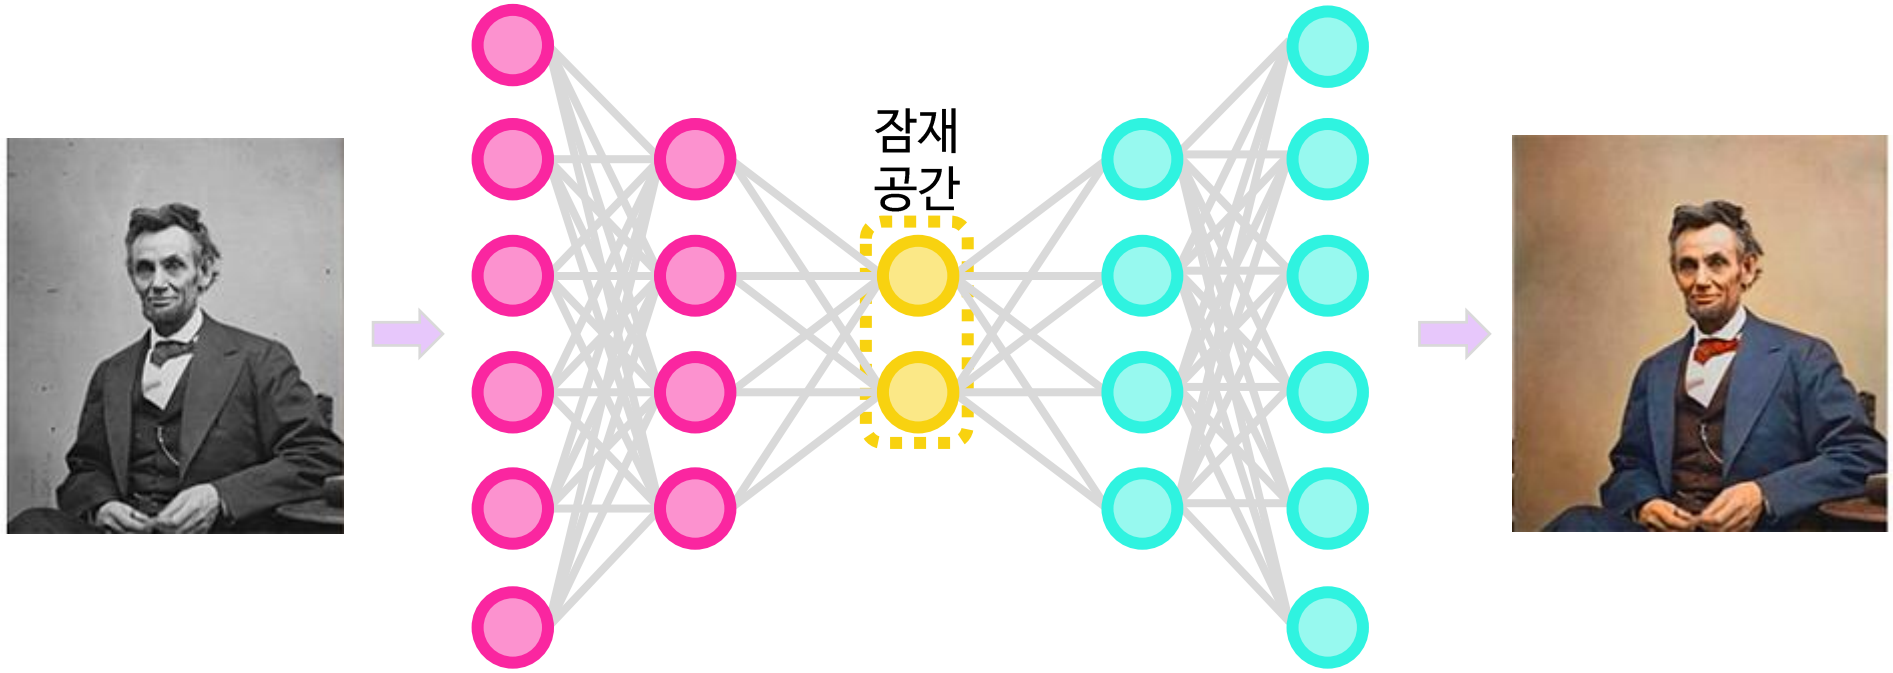

신박AI

Variational AutoEncoder는 오토인코더와 비슷하지만 몇 가지 중요한 차이점이 있습니다.

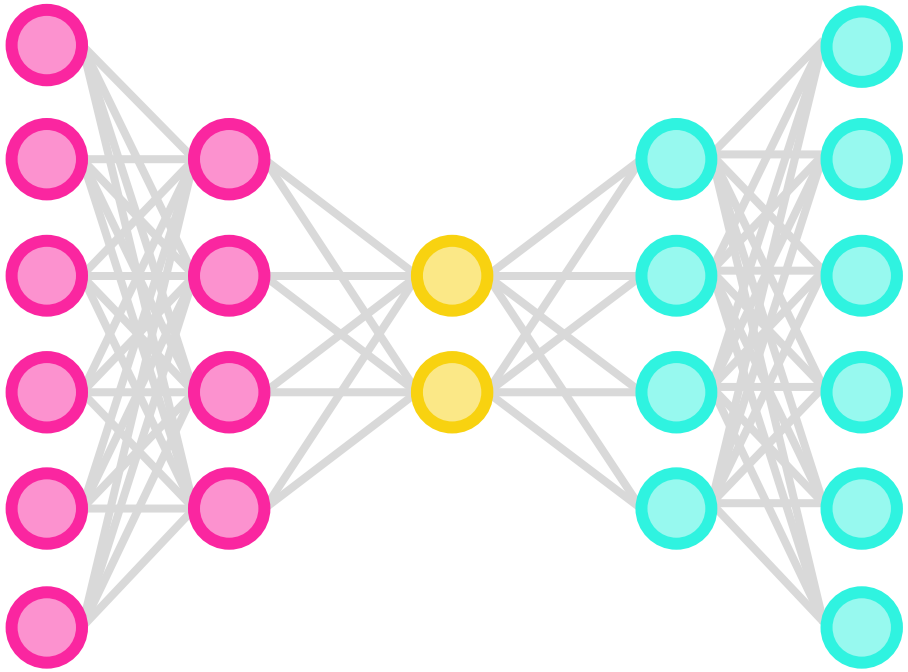

신박AI

일반적인 오토인코더는 입력 데이터를 단순히 압축하고 복원하는 반면,

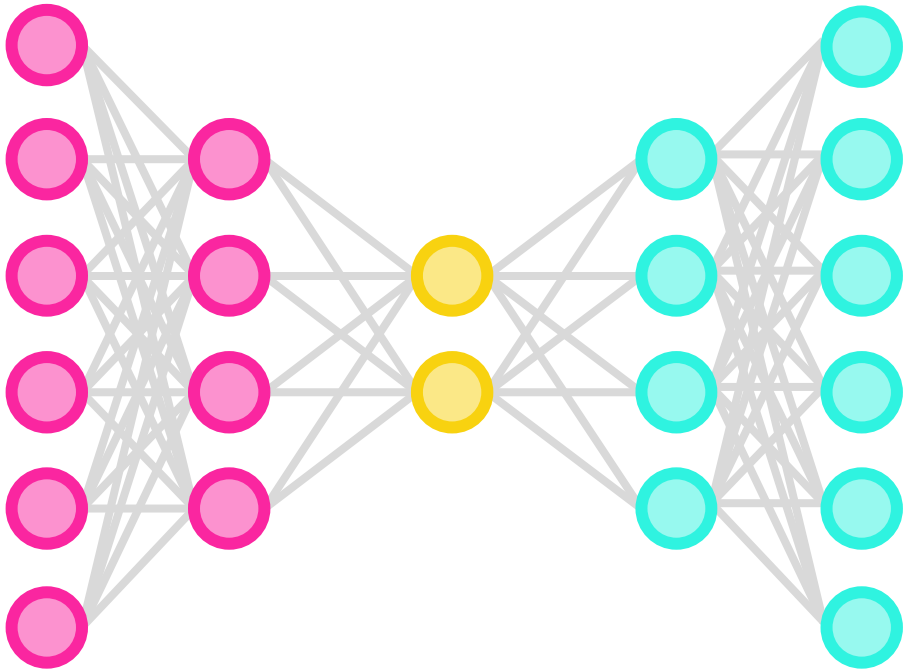

VAE는 특정 분포를 학습하여 새로운 데이터를 생성할 수 있습니다.

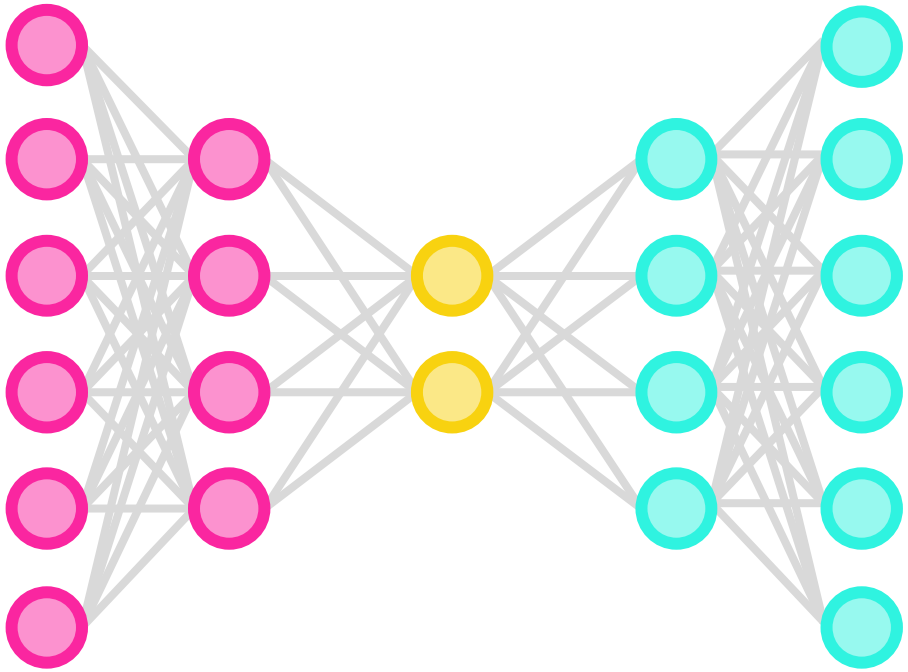

신박AI

이런 VAE의 특징을 먼저 알아보기 위해서,

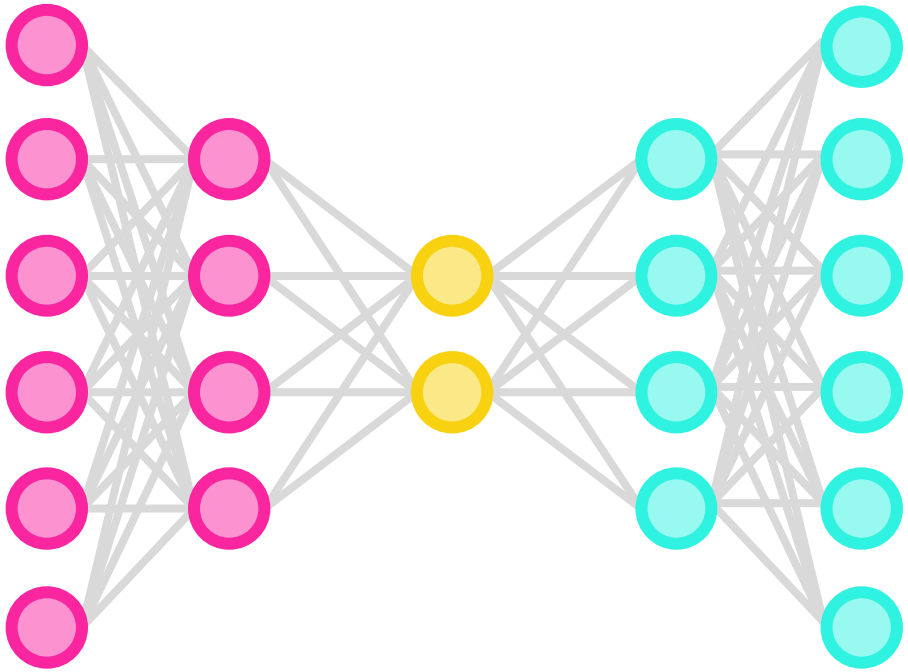

신박AI

간단한 VAE의 구조를 먼저 그림으로 그려보도록 하겠습니다.

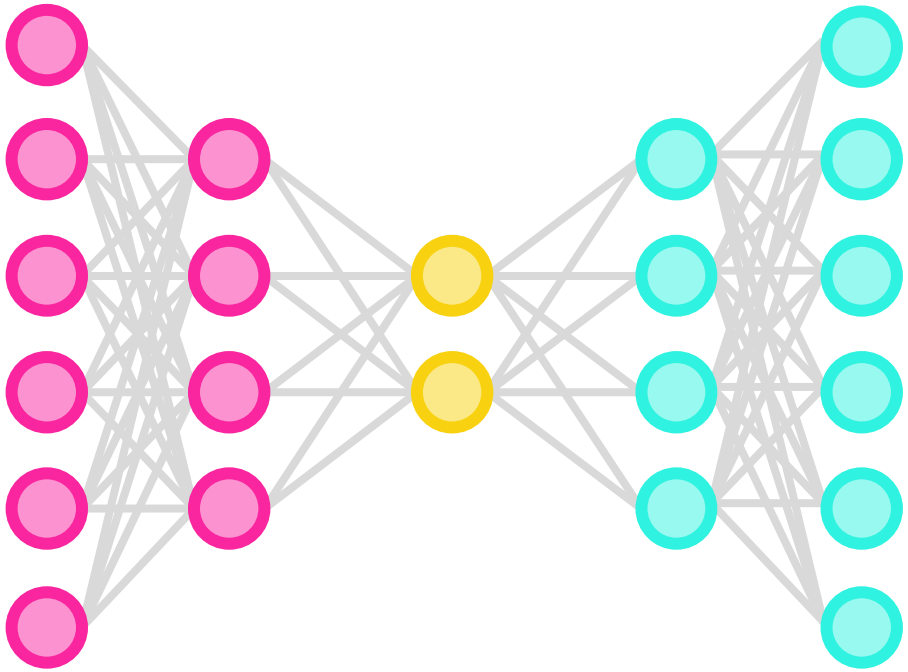

신박AI

간단한 VAE의 구조를 먼저 그림으로 그려보도록 하겠습니다.

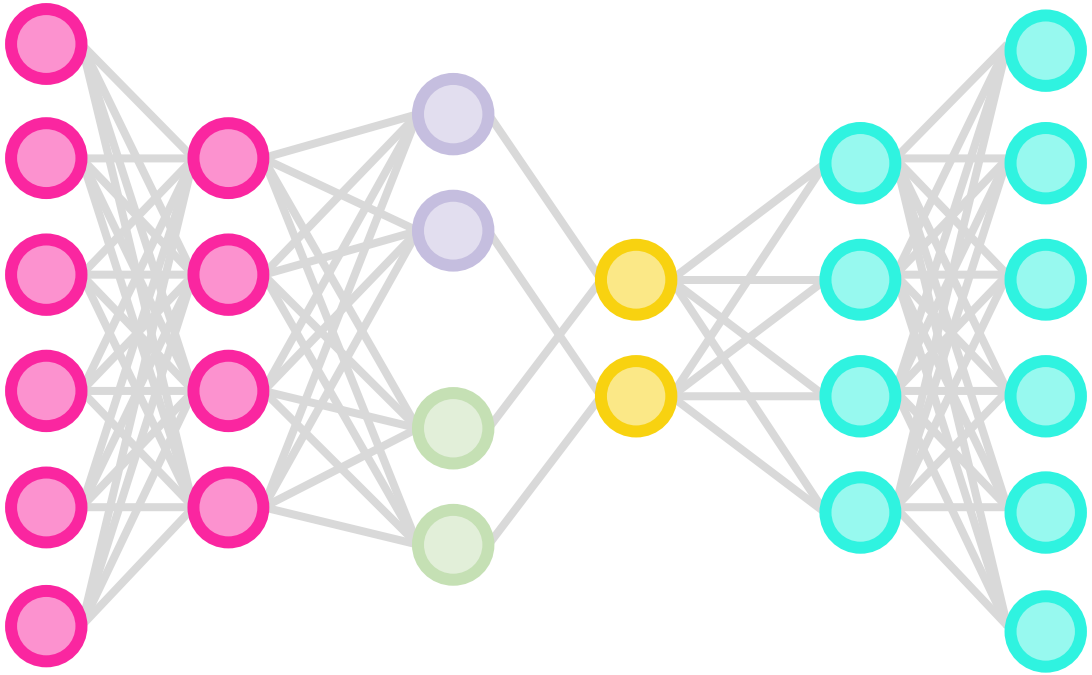

신박AI

여기서 VAE의 가장 큰 차이점은 잠재공간을 평균과 분산의 확률 분포로 모델링한다는 것입니다.

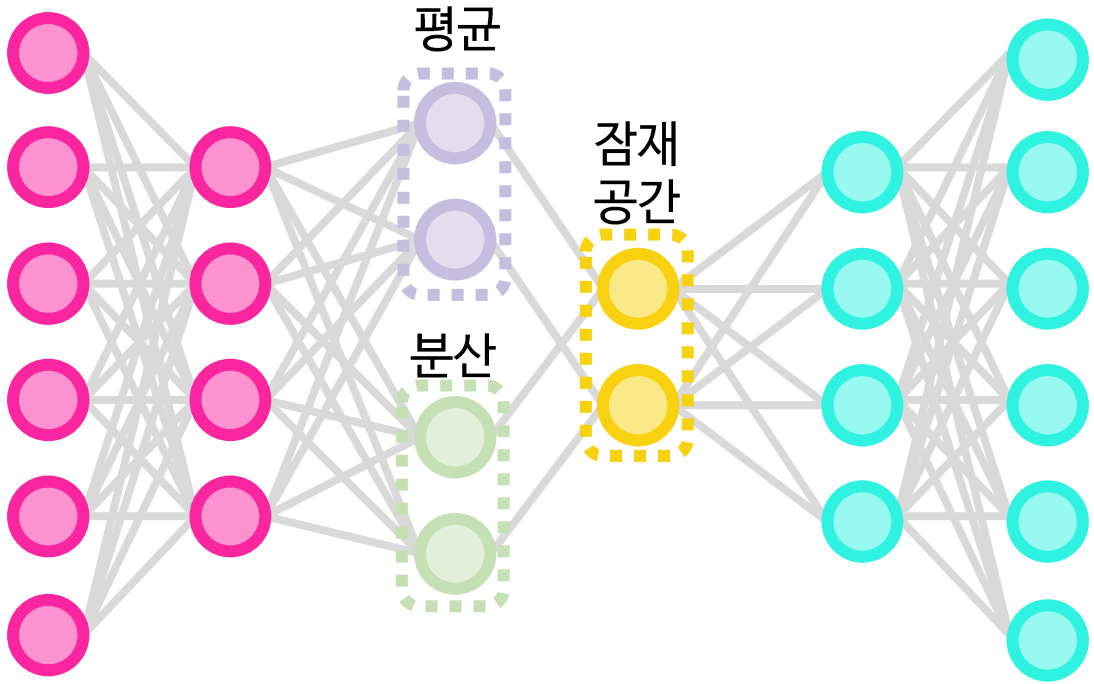

신박AI

일반적인 오토인코더의 잠재공간은 단순한 벡터 공간인 반면,

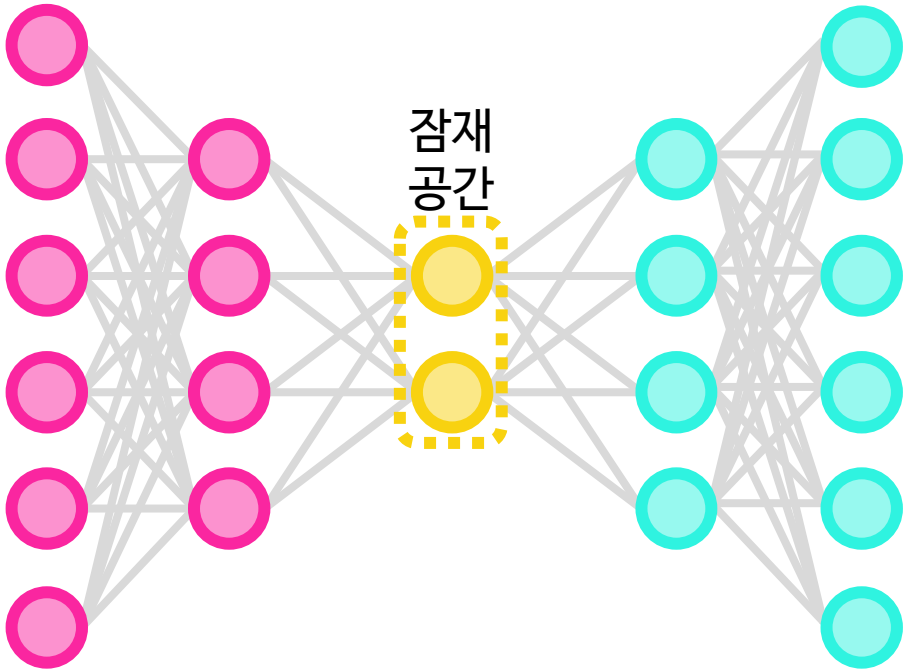

신박AI

VAE의 잠재공간은 평균과 분산이 만드는 확률 분포를 따릅니다.

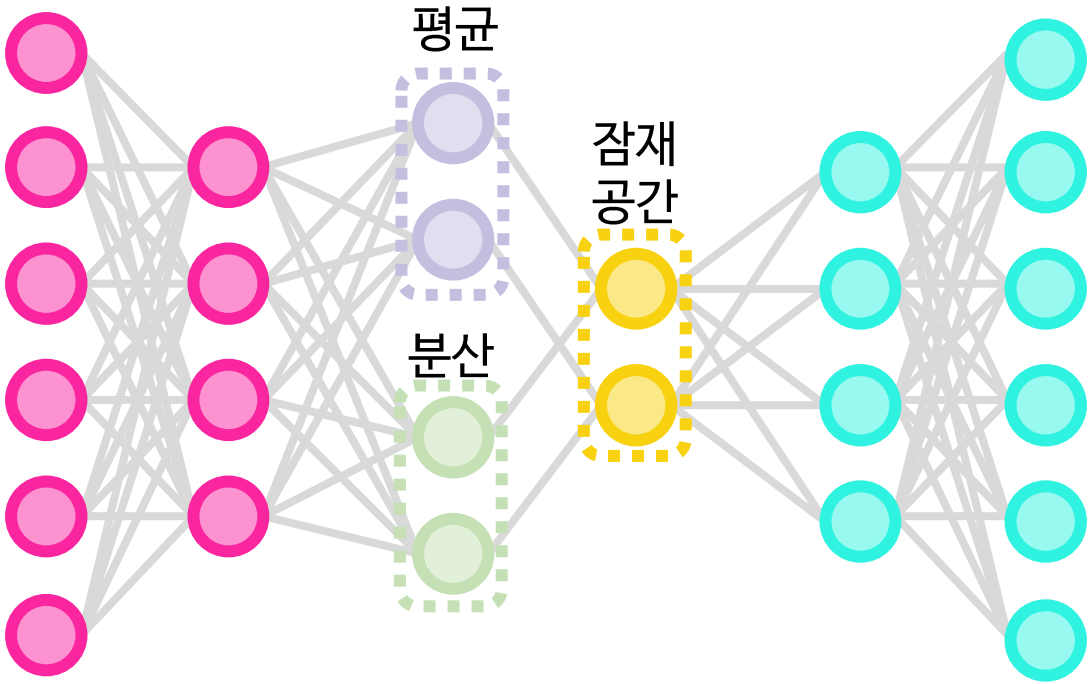

신박AI

이해를 돕기 위해 비유를 들어 설명해보도록 하겠습니다.

신박AI

예를 들어, 우리가 치킨집 가맹점을 운영한다고 가정해봅시다.

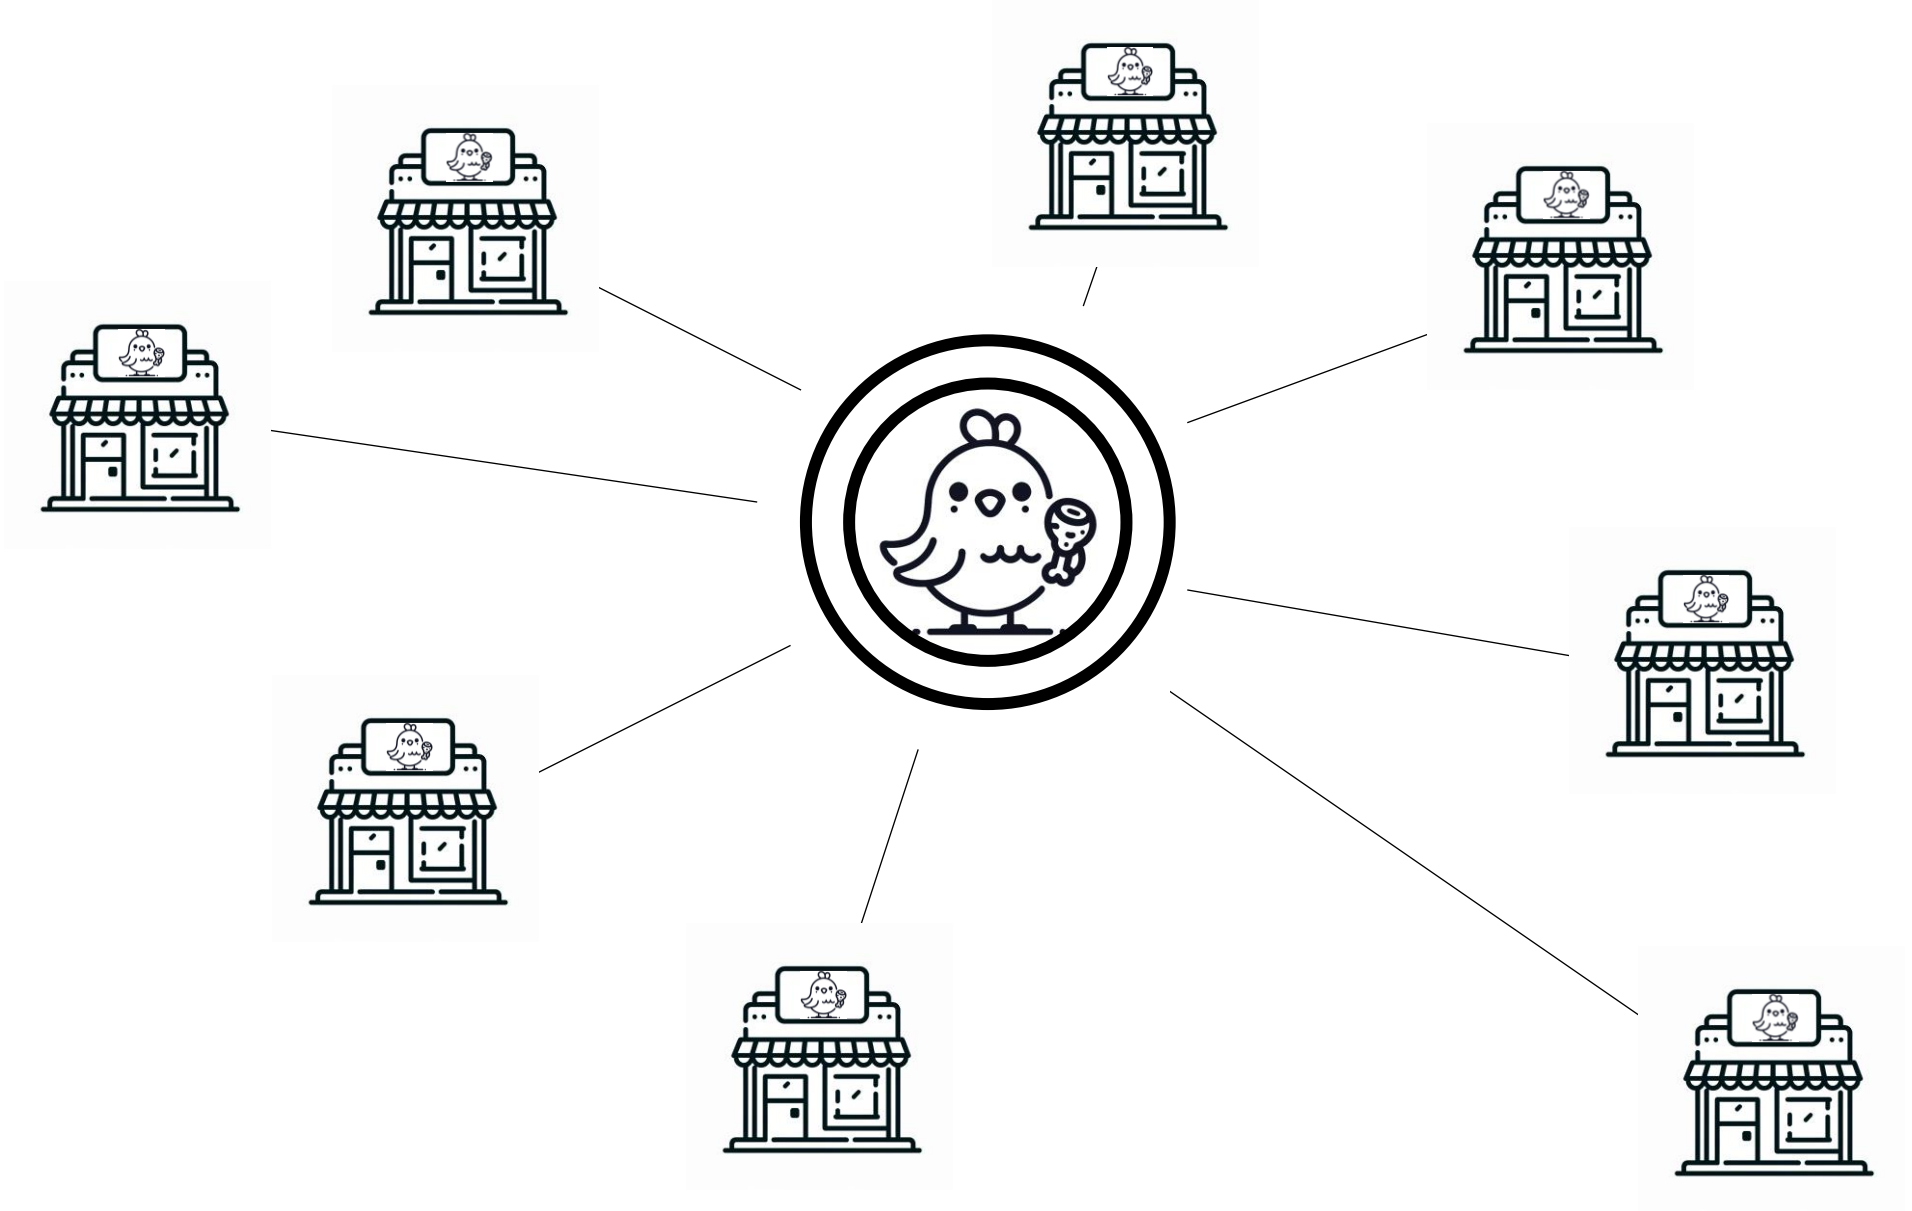

신박AI

이 치킨 프랜차이즈는 맛이 너무 좋아서 대단한 인기이지만,

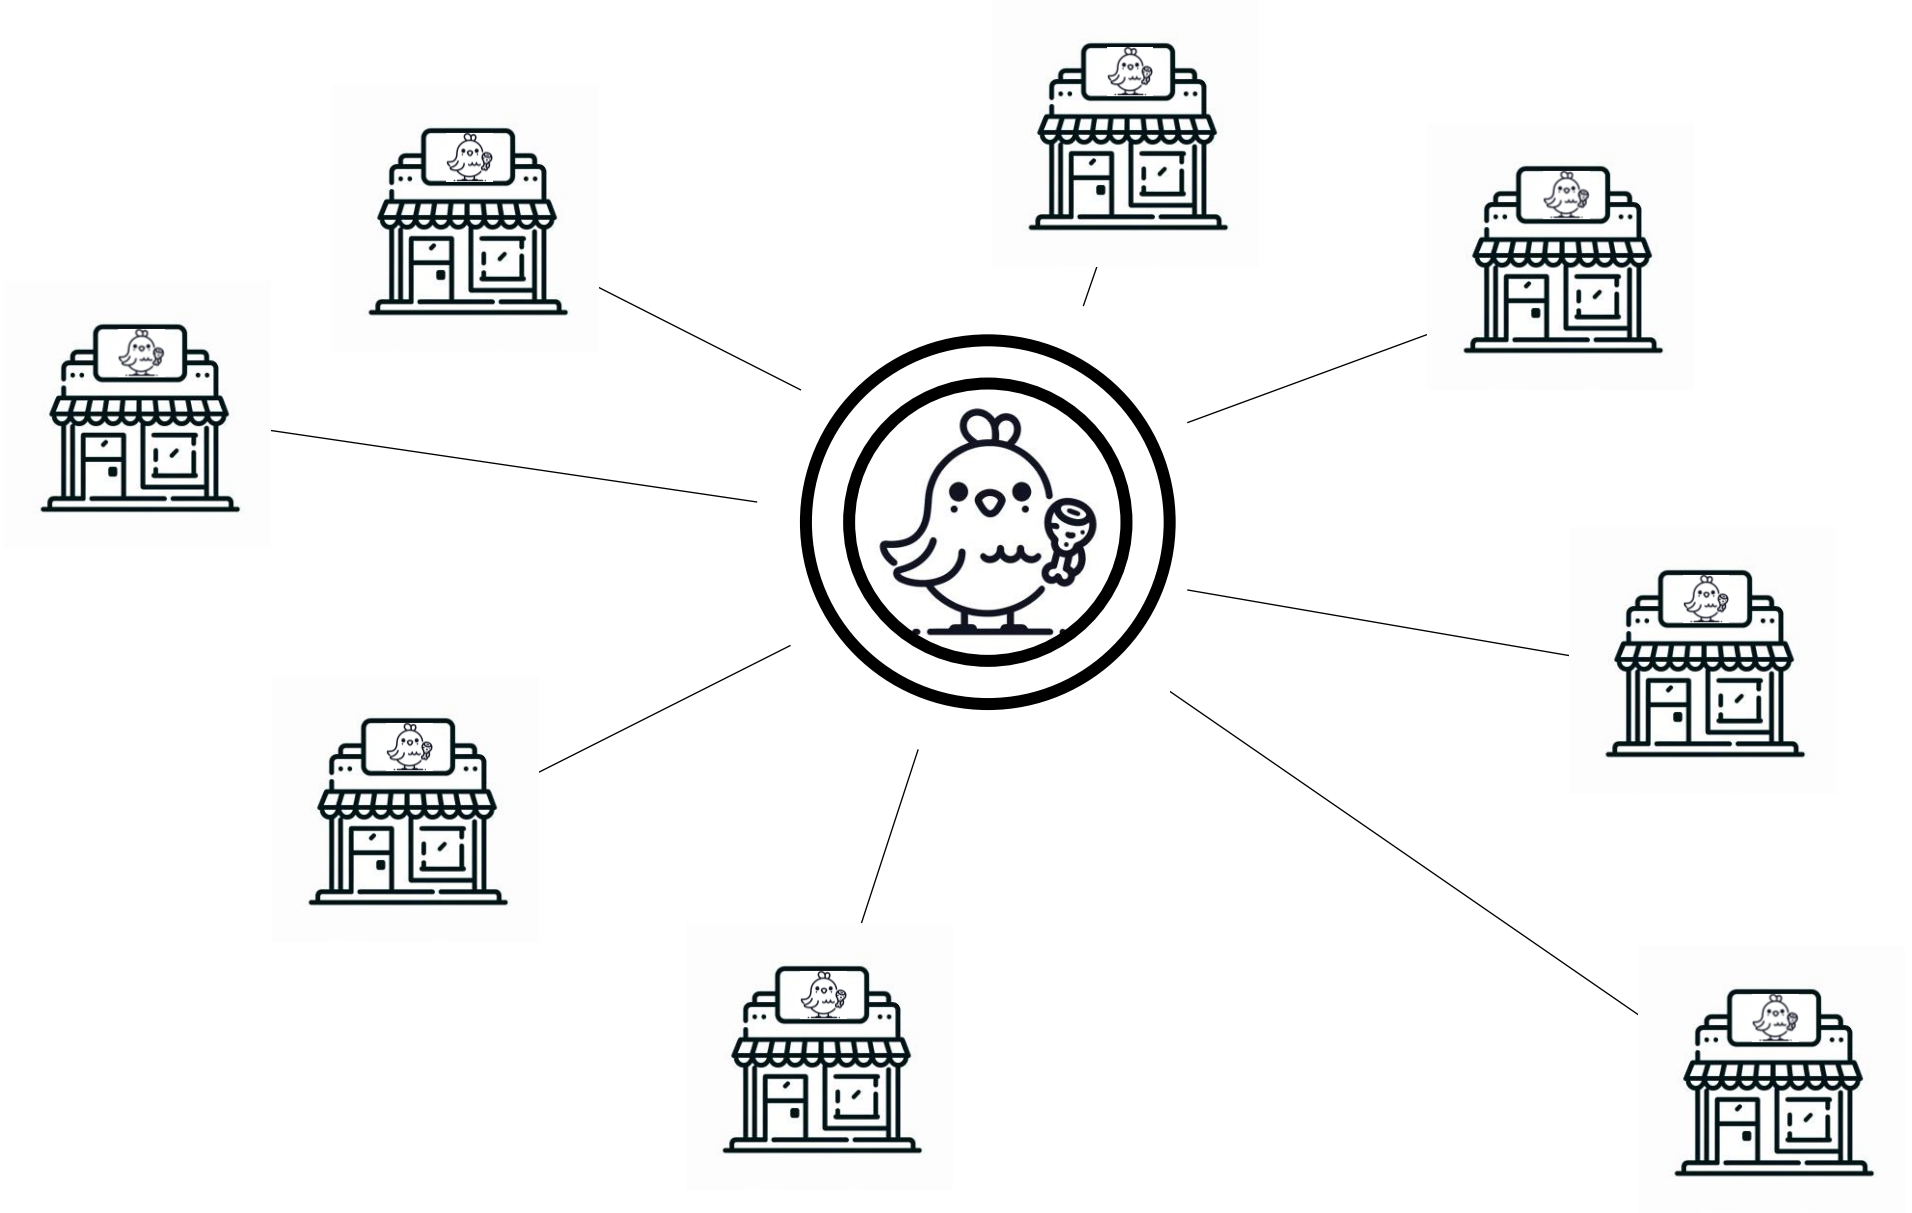

신박AI

치킨의 양념을 만드는 특제 비밀 소스는 오직 본사에서만 제공하기 때문에,

신박AI

가맹점 주인은, 본사에서 시키는 대로 비법 소스를 넣고 그 맛을 그대로 재현해 낼 수만 있습니다.

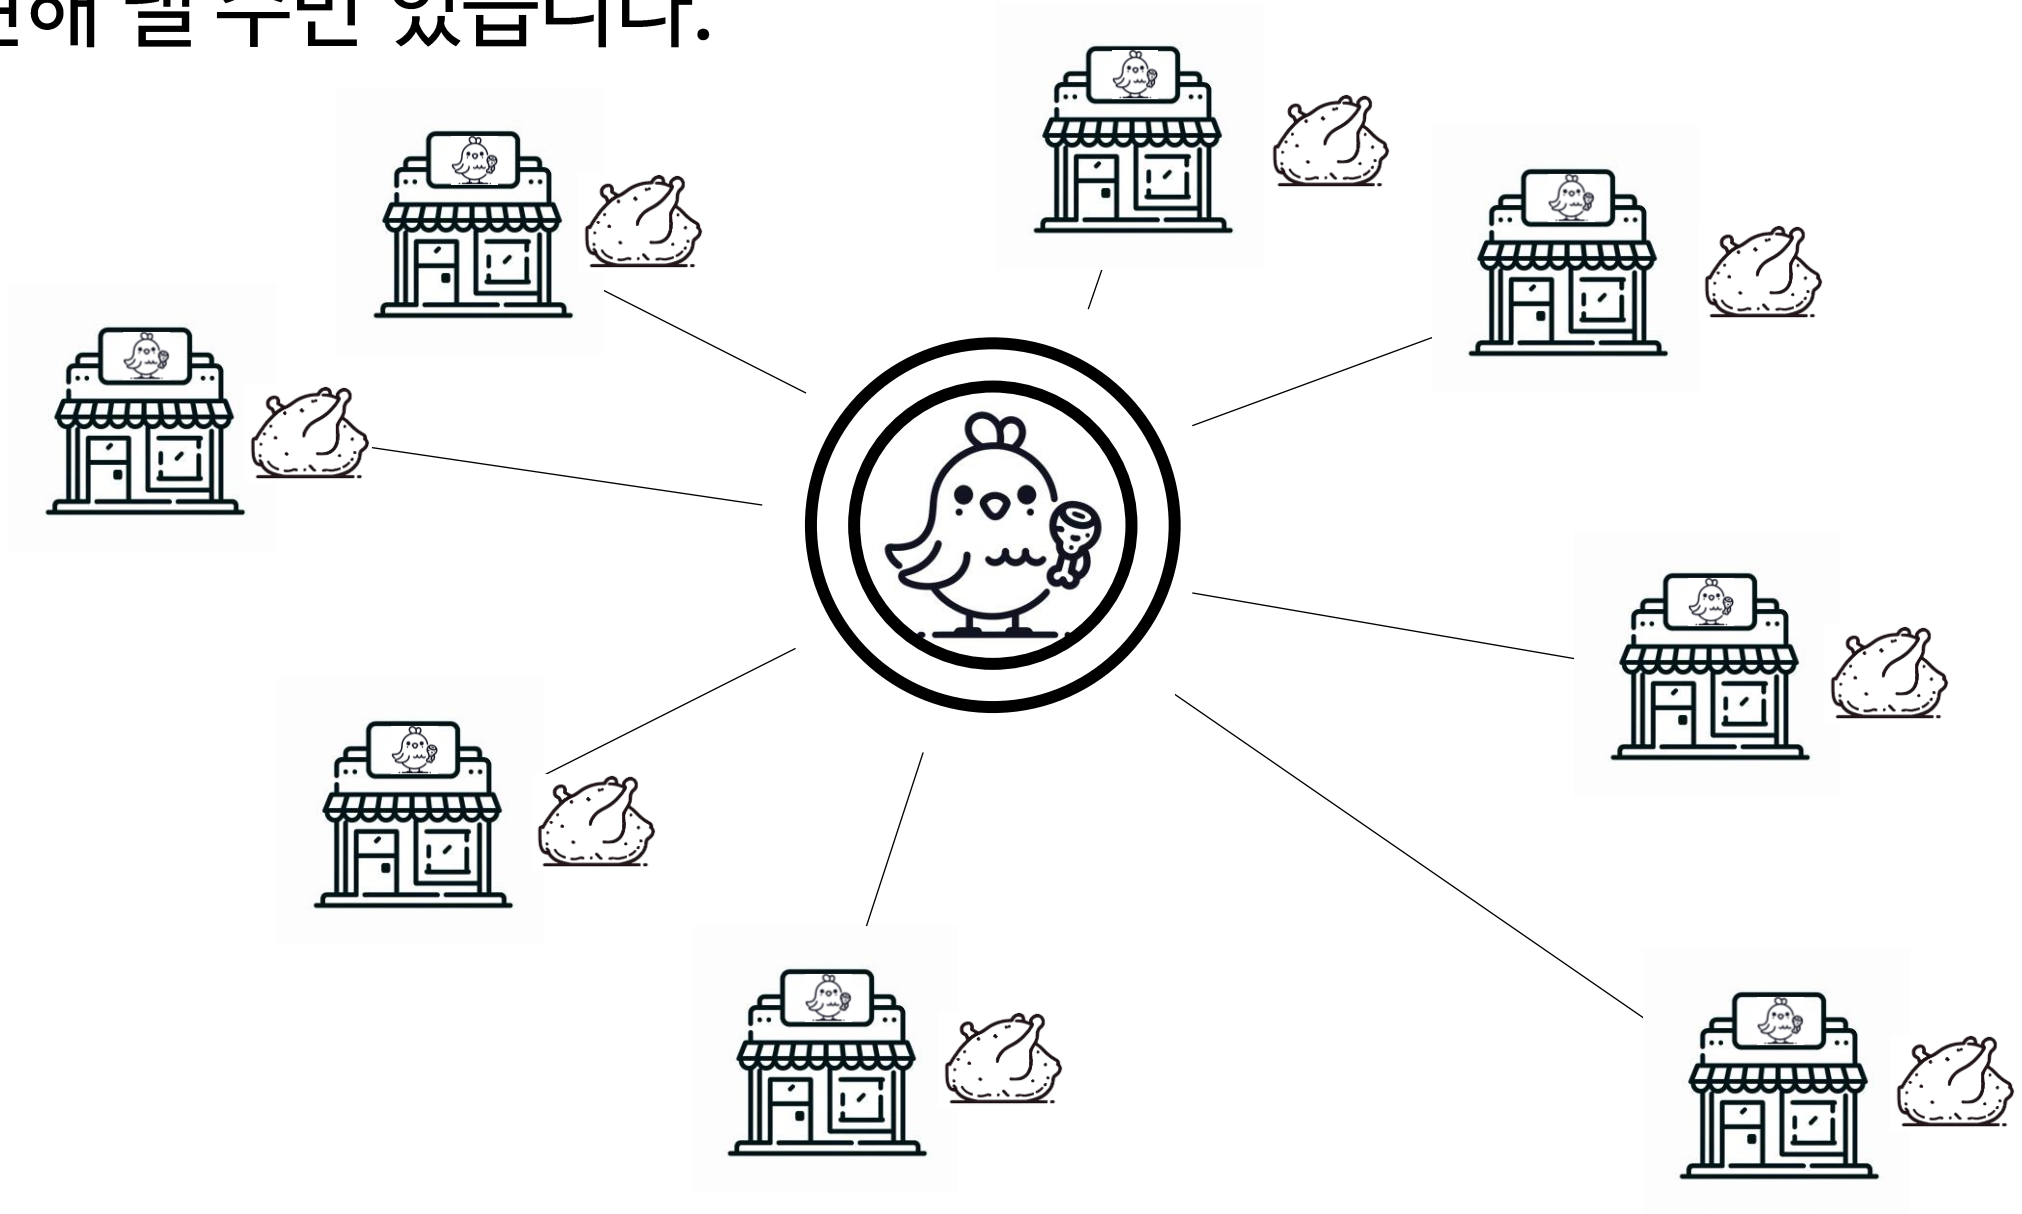

신박AI

하지만 그 어떠한 방법으로도 본사에서 제공하는 특제소스의 비법을 알 수 없기 때문에,

새로운 양념 치킨을 생성해 내지는 못합니다.

신박AI

그러나 세월이 흘러, 본사에서도 특제 비법소스의 비율을 공개하기로 했습니다.

신박AI

그래서 가맹점에서도 특제 소스의 비율을 적절히 변형해서,

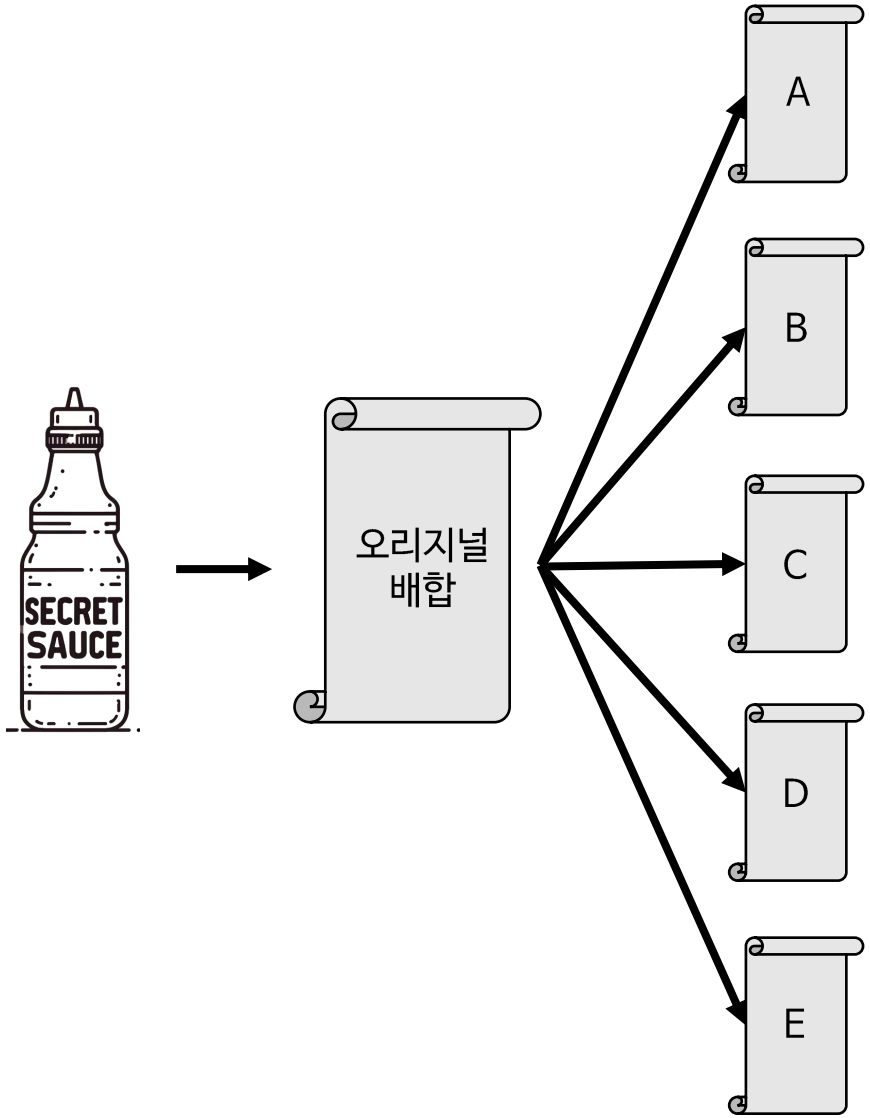

신박AI

더 맛있는 양념치킨, 더 독특한 양념치킨을 마음대로 생성할 수 있습니다.

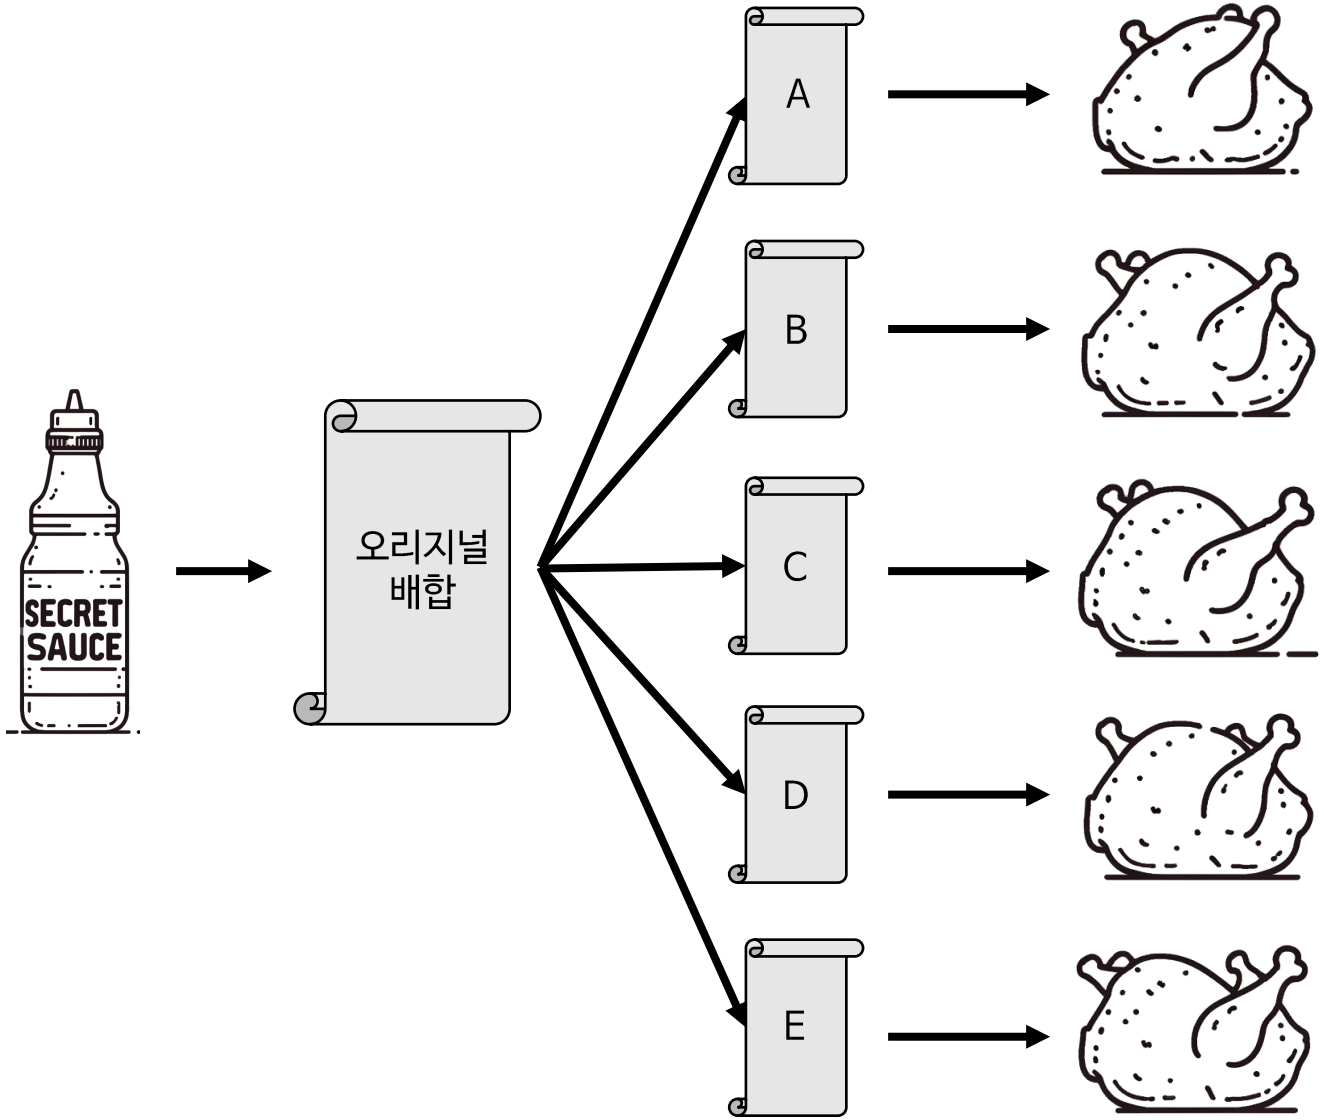

신박AI

오토인코더의 잠재공간은 마치 배합 비율을 모르는 특제비법소스와 같아서,

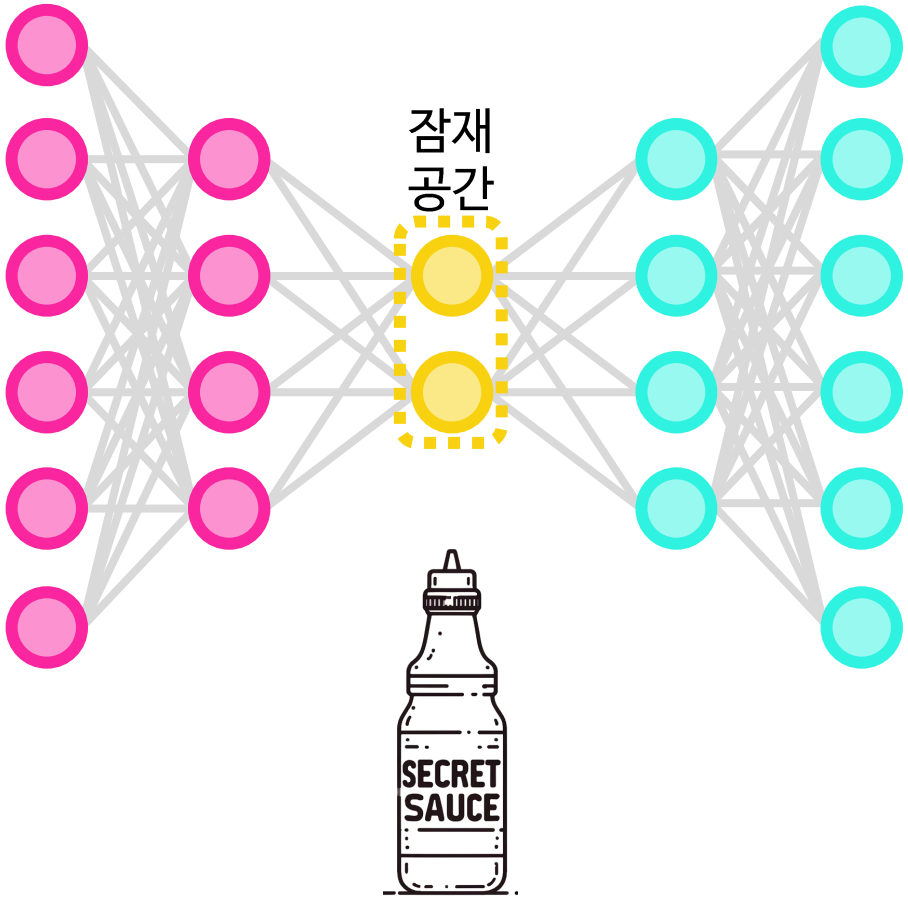

신박AI

오토인코더가 학습한 대로, 어떤 이미지를 넣으면 그대로 복원하는 것은 가능하지만,

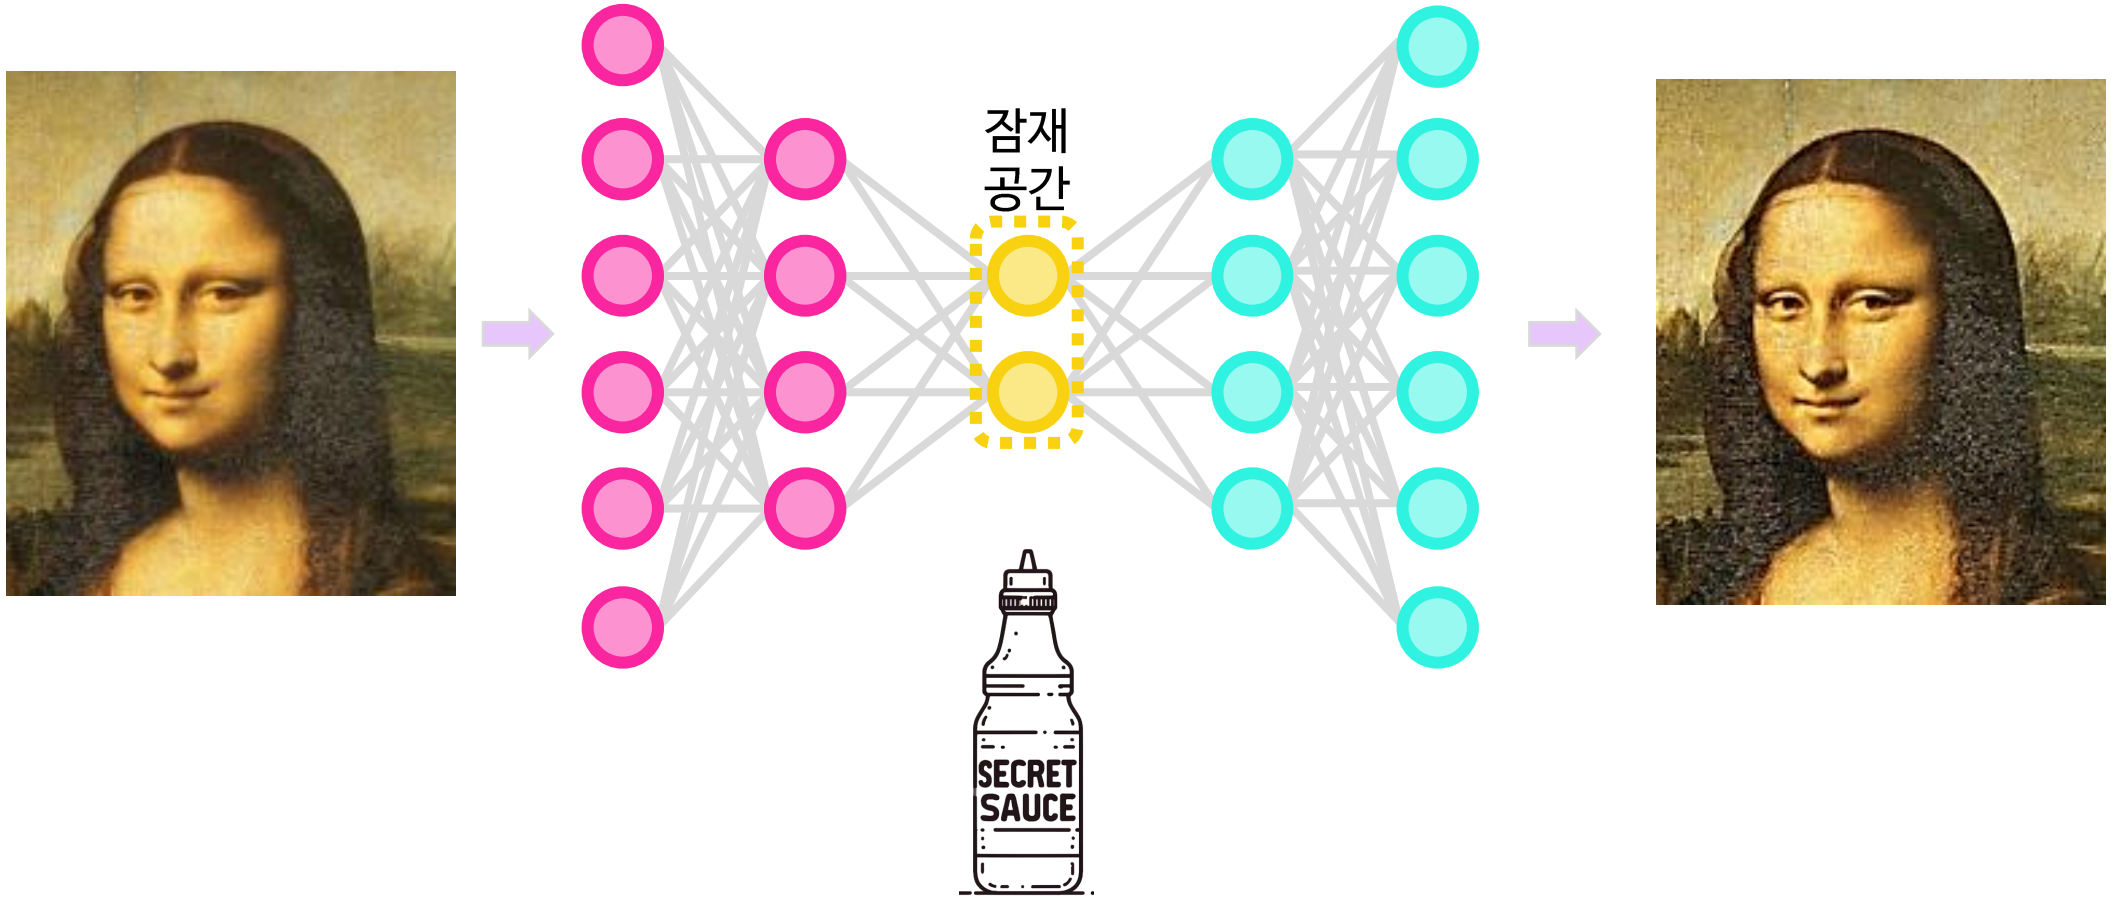

신박AI

잠재공간 벡터를 사용자가 조절해서 새로운 이미지를 생성해내는 데에는 한계가 있었습니다.

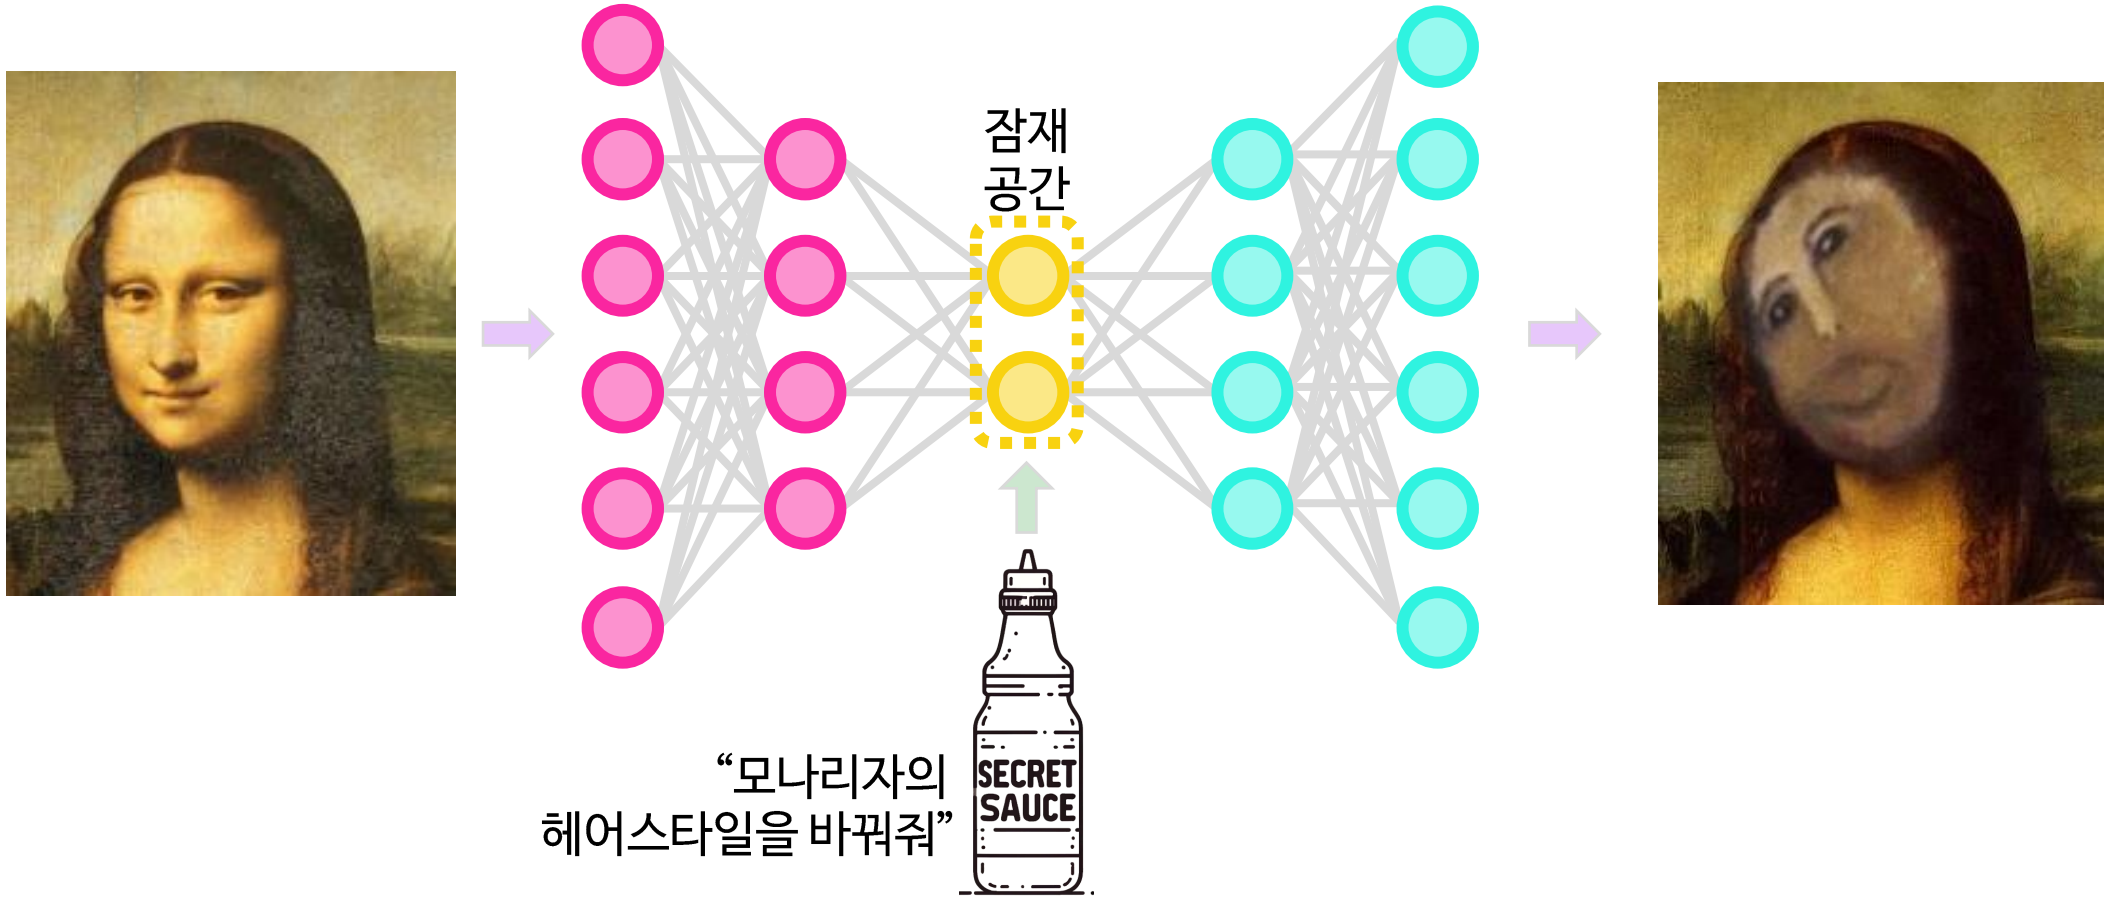

신박AI

잠재공간은 말하자면 블랙박스와도 같아서 내부의 사정을 전혀 알수 없기 때문입니다.

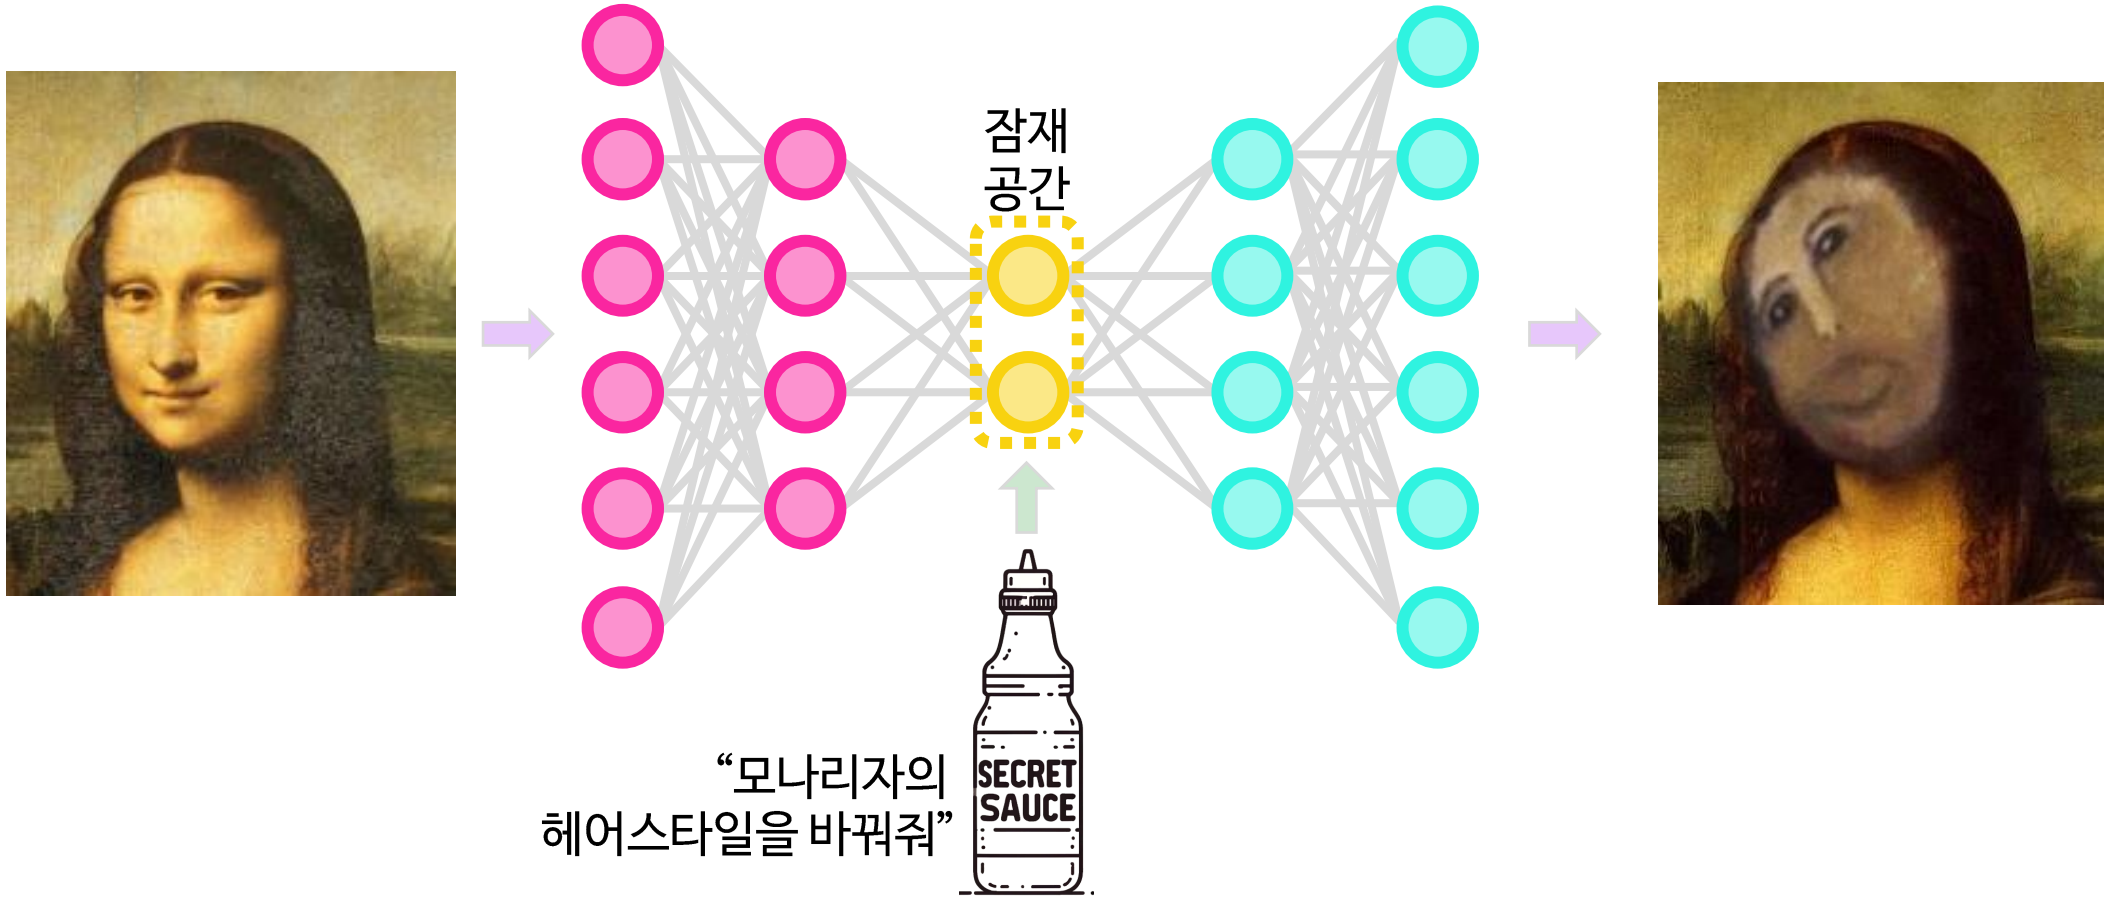

신박AI

하지만, VAE의 경우는 잠재공간을 우리에게 친숙한 정규 분포를 이용해 만들기 때문에,

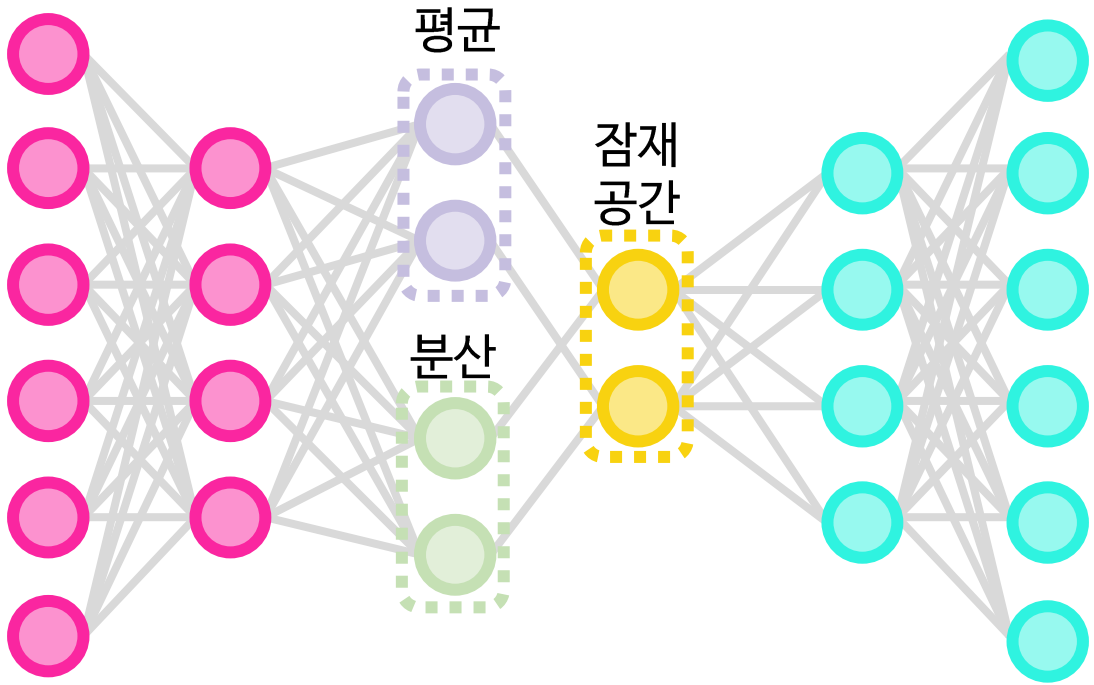

신박AI

주어진 이미지의 숨겨진 특성을 평균과 분산을 통해 잘 이해할 수 있고,

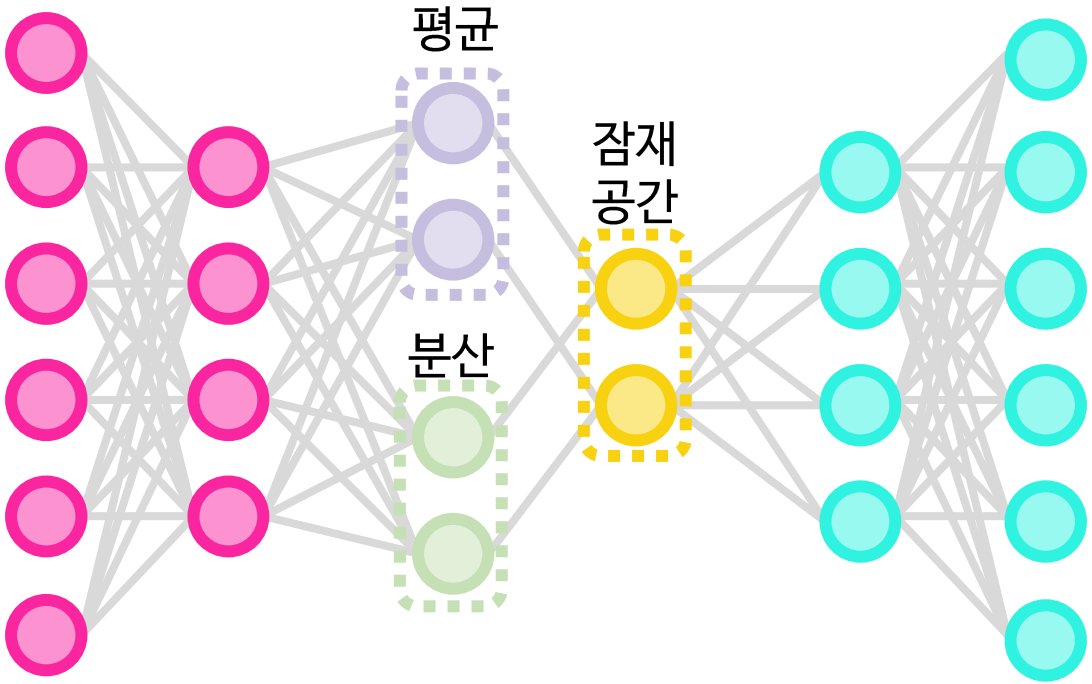

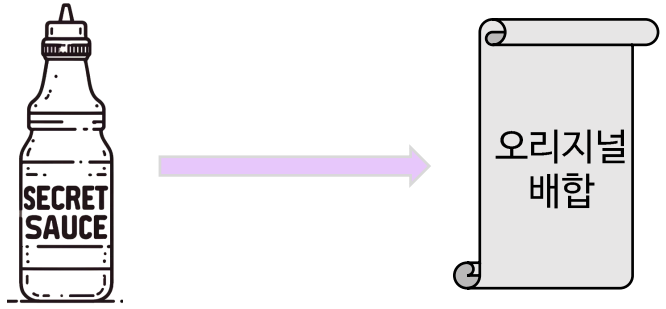

신박AI

그러한 잠재공간 분포를 잘 알고 있기 때문에, 이미지의 특정 형태를 예측하여 생성하는 것 또한 가능합니다.

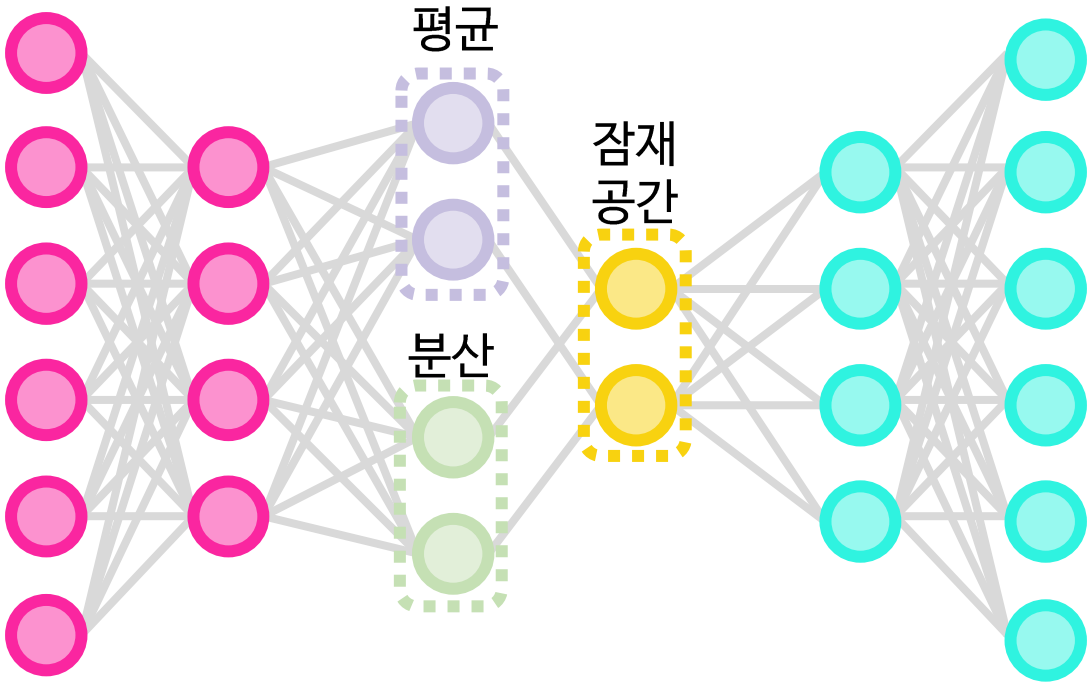

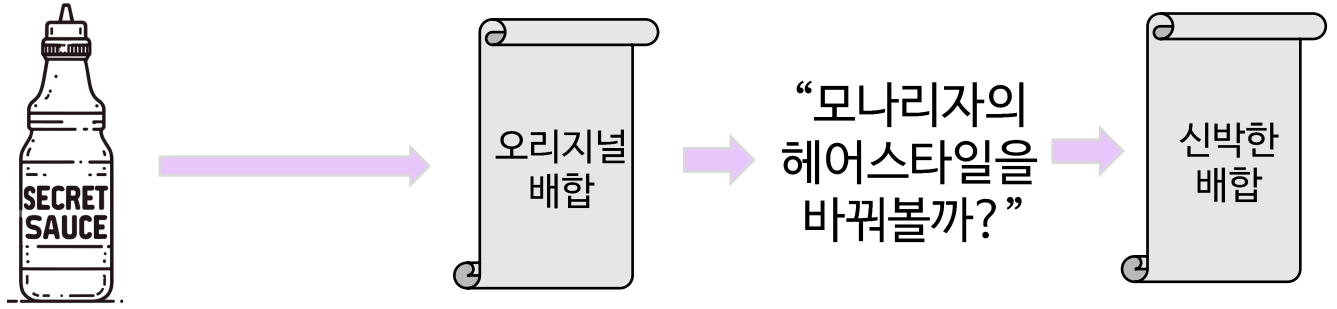

신박AI

그러한 예측을 바탕으로 잠재공간을 새롭게 구성 (샘플링)하여, 새롭게 생성하면 원하는 형태의 이미지를 생성할 수 있습니다.

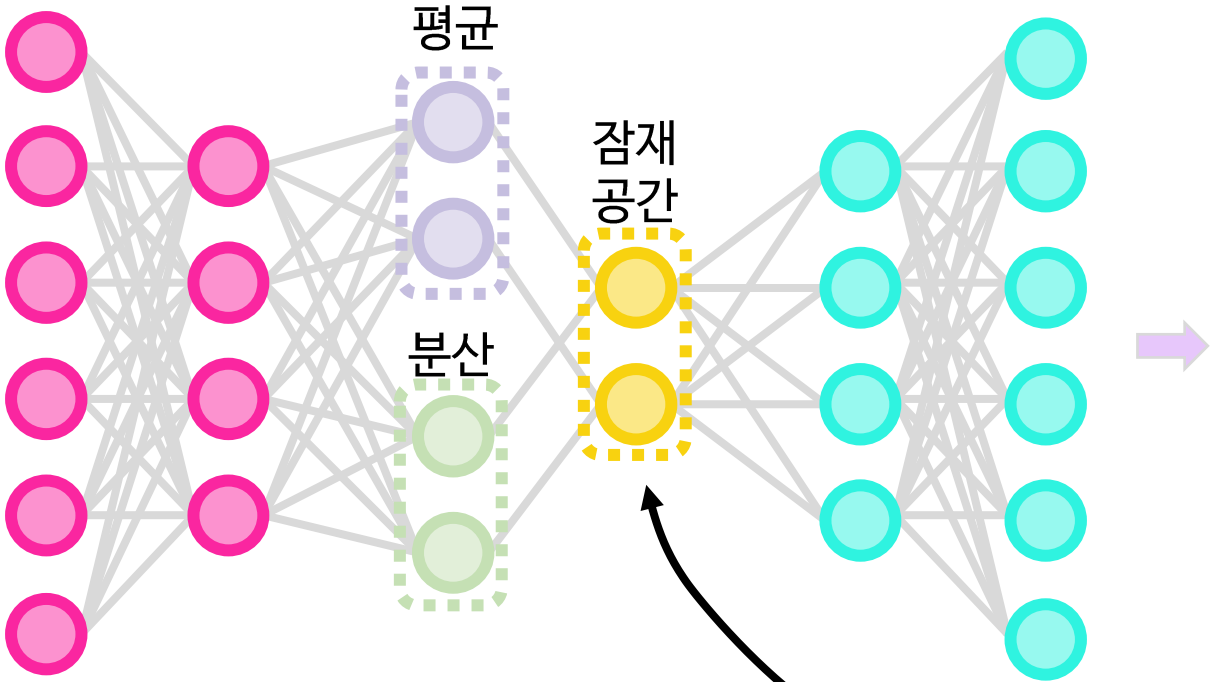

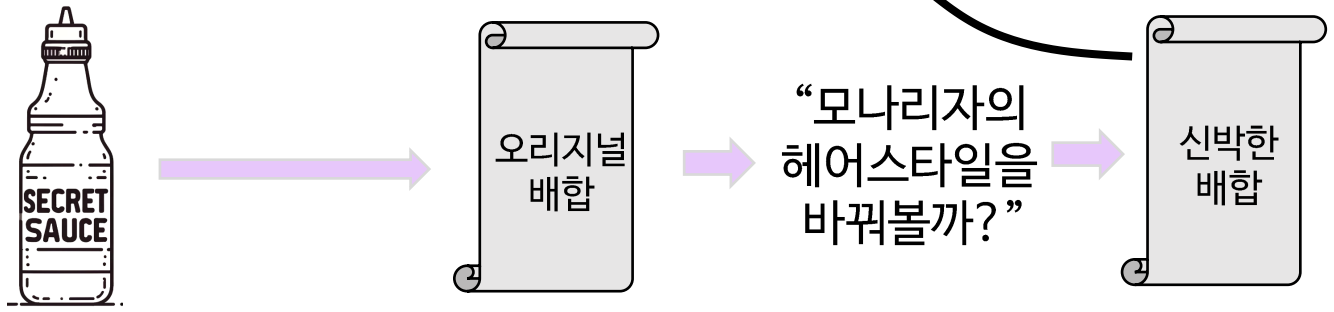

신박AI

마치 특제비법소스의 배합을 알고나면, 그 비율을 적절히 조절하여 새로운 양념치킨을 만들 수 있는 것과 유사하다고 볼 수 있습니다.

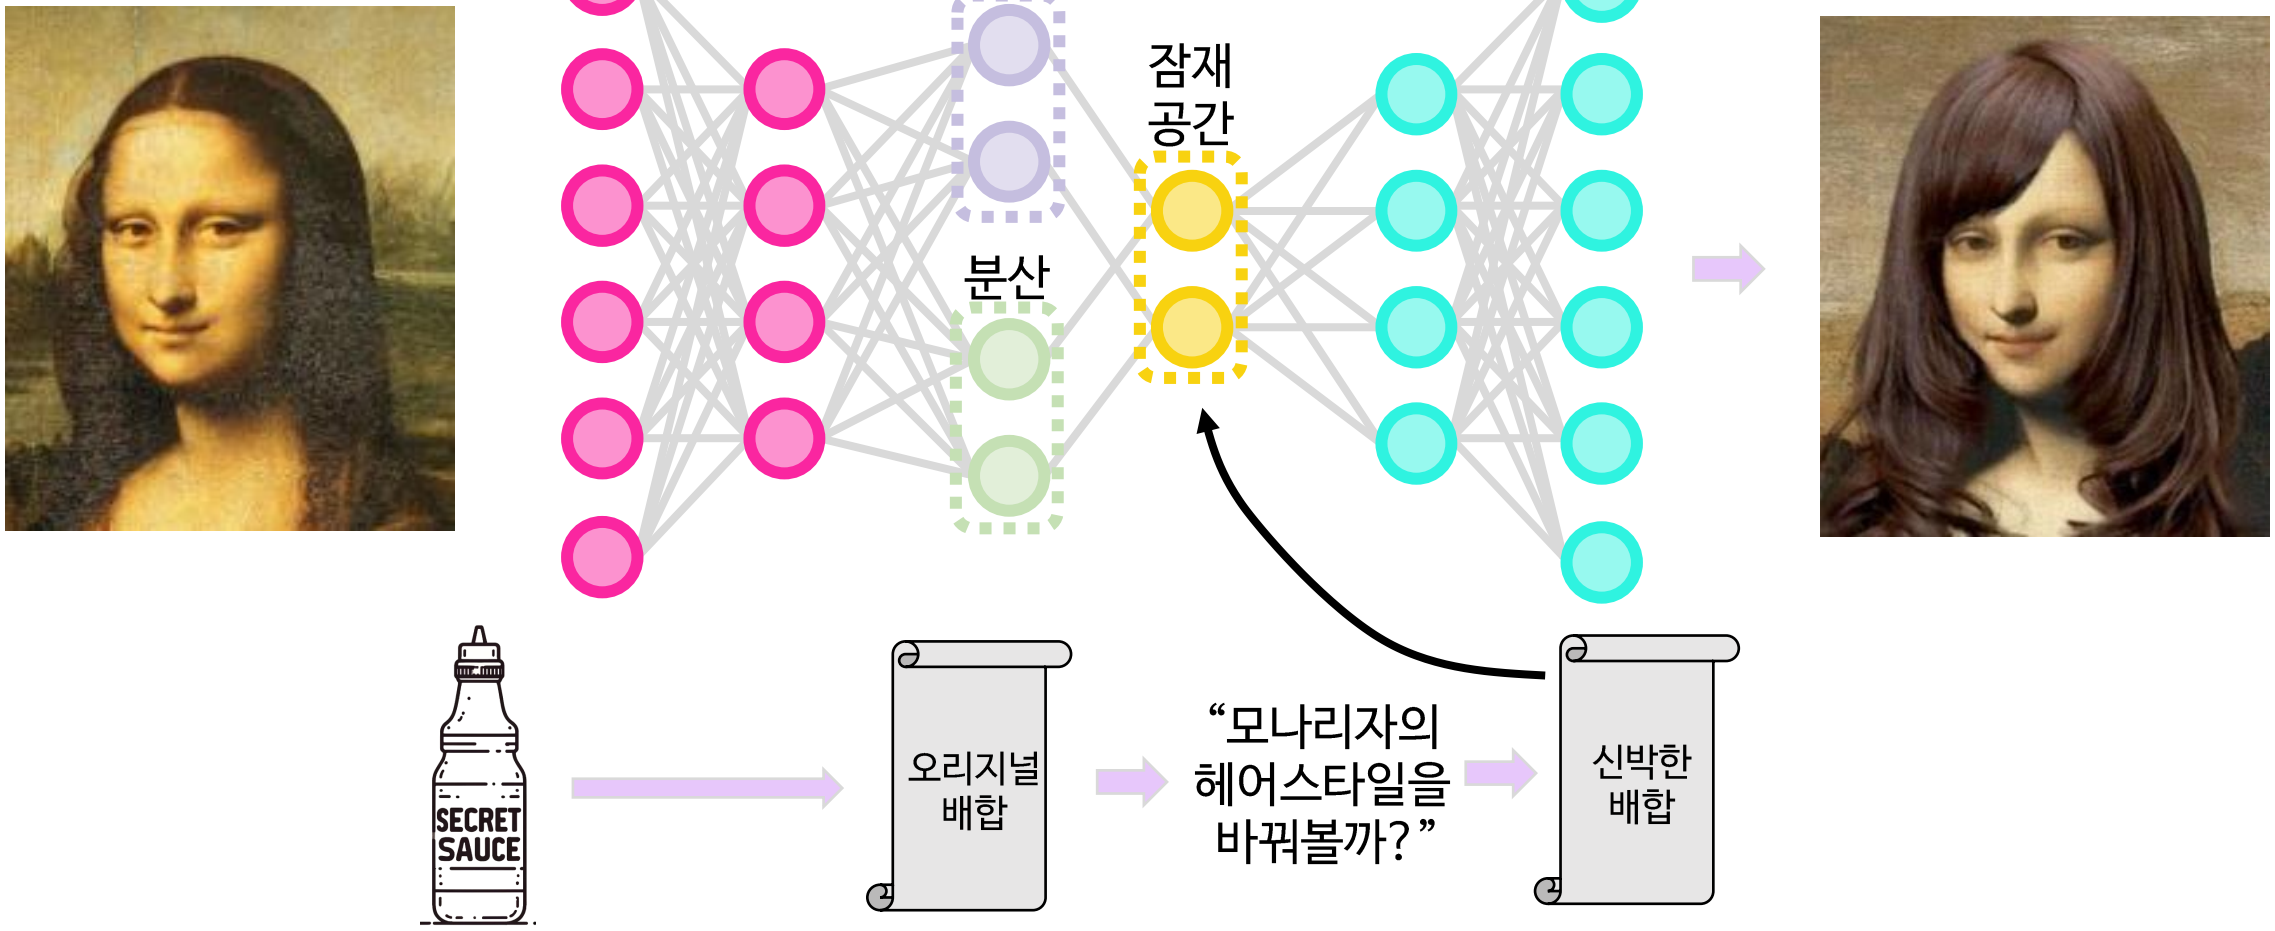

신박AI

물론 오늘 우리가 배우는 VAE가 이러한 이미지 조절이 바로 가능하다는 말은 아닙니다.

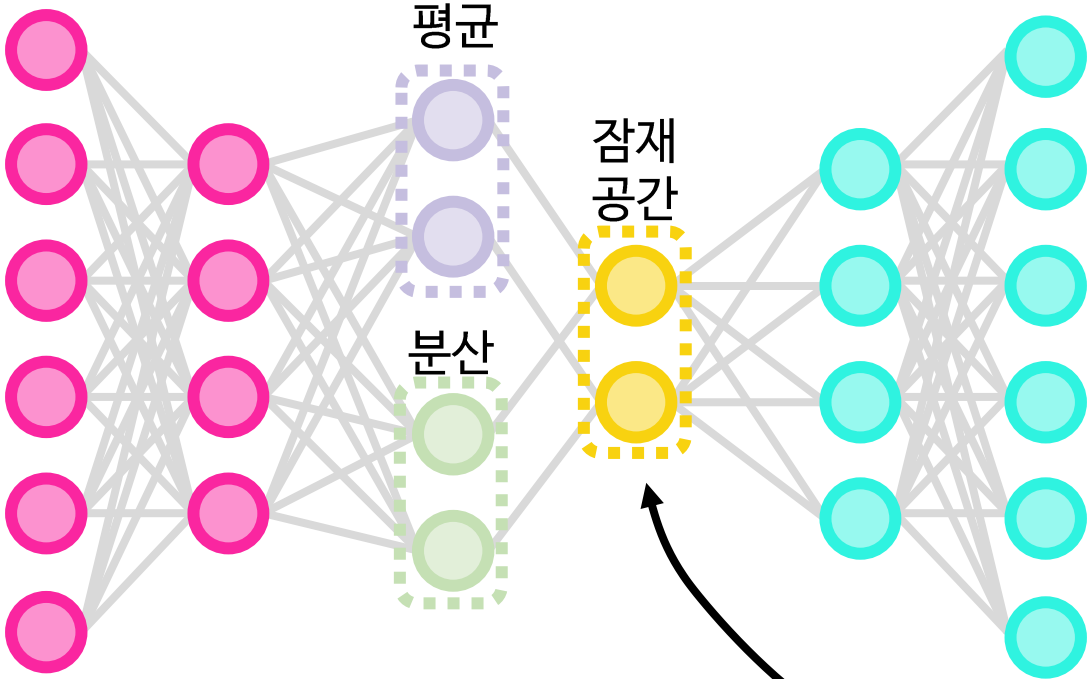

오리지널
배합

“모나리자의
헤어스타일을
바꿔볼까?”

신박한
배합

신박AI

이렇게 언어를 사용하여 이미지를 수월하게 조절하는 단계에까지 이르는 것은,

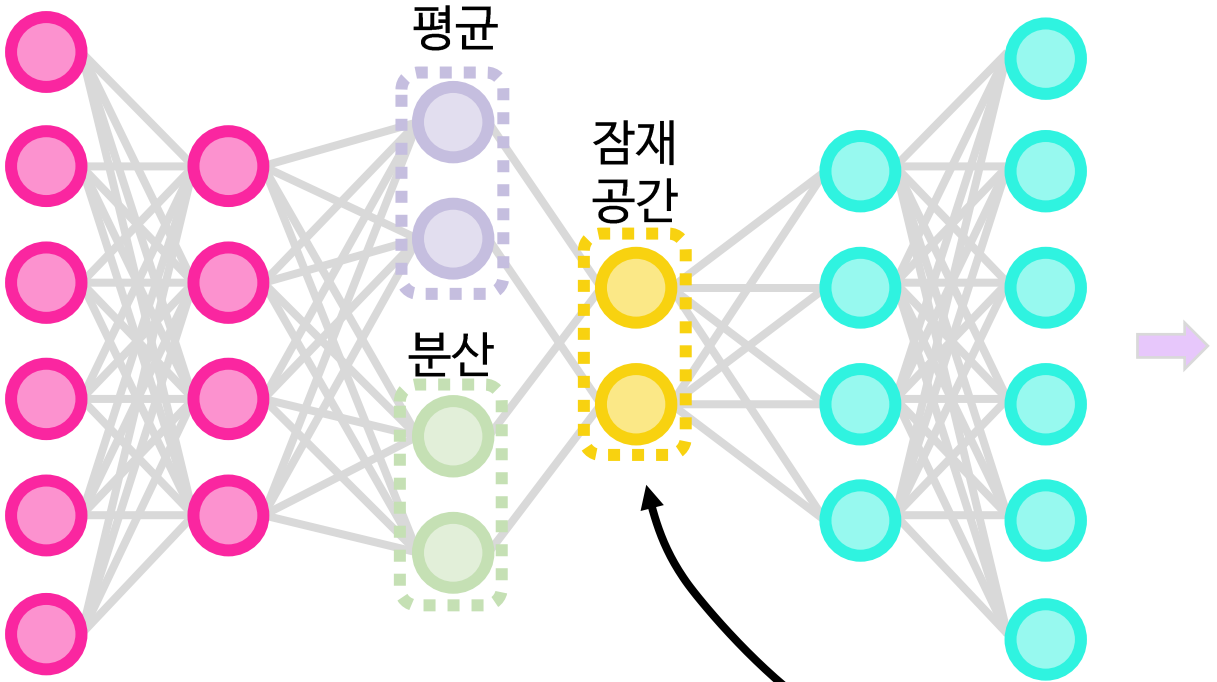

오리지널
배합

“모나리자의
헤어스타일을
바꿔볼까?”

신박한
배합

신박AI

VAE를 활용한 Stable Diffusion 모델까지 이르러야 그런 기능을 수월하게 활용할 수가 있게 됩니다.

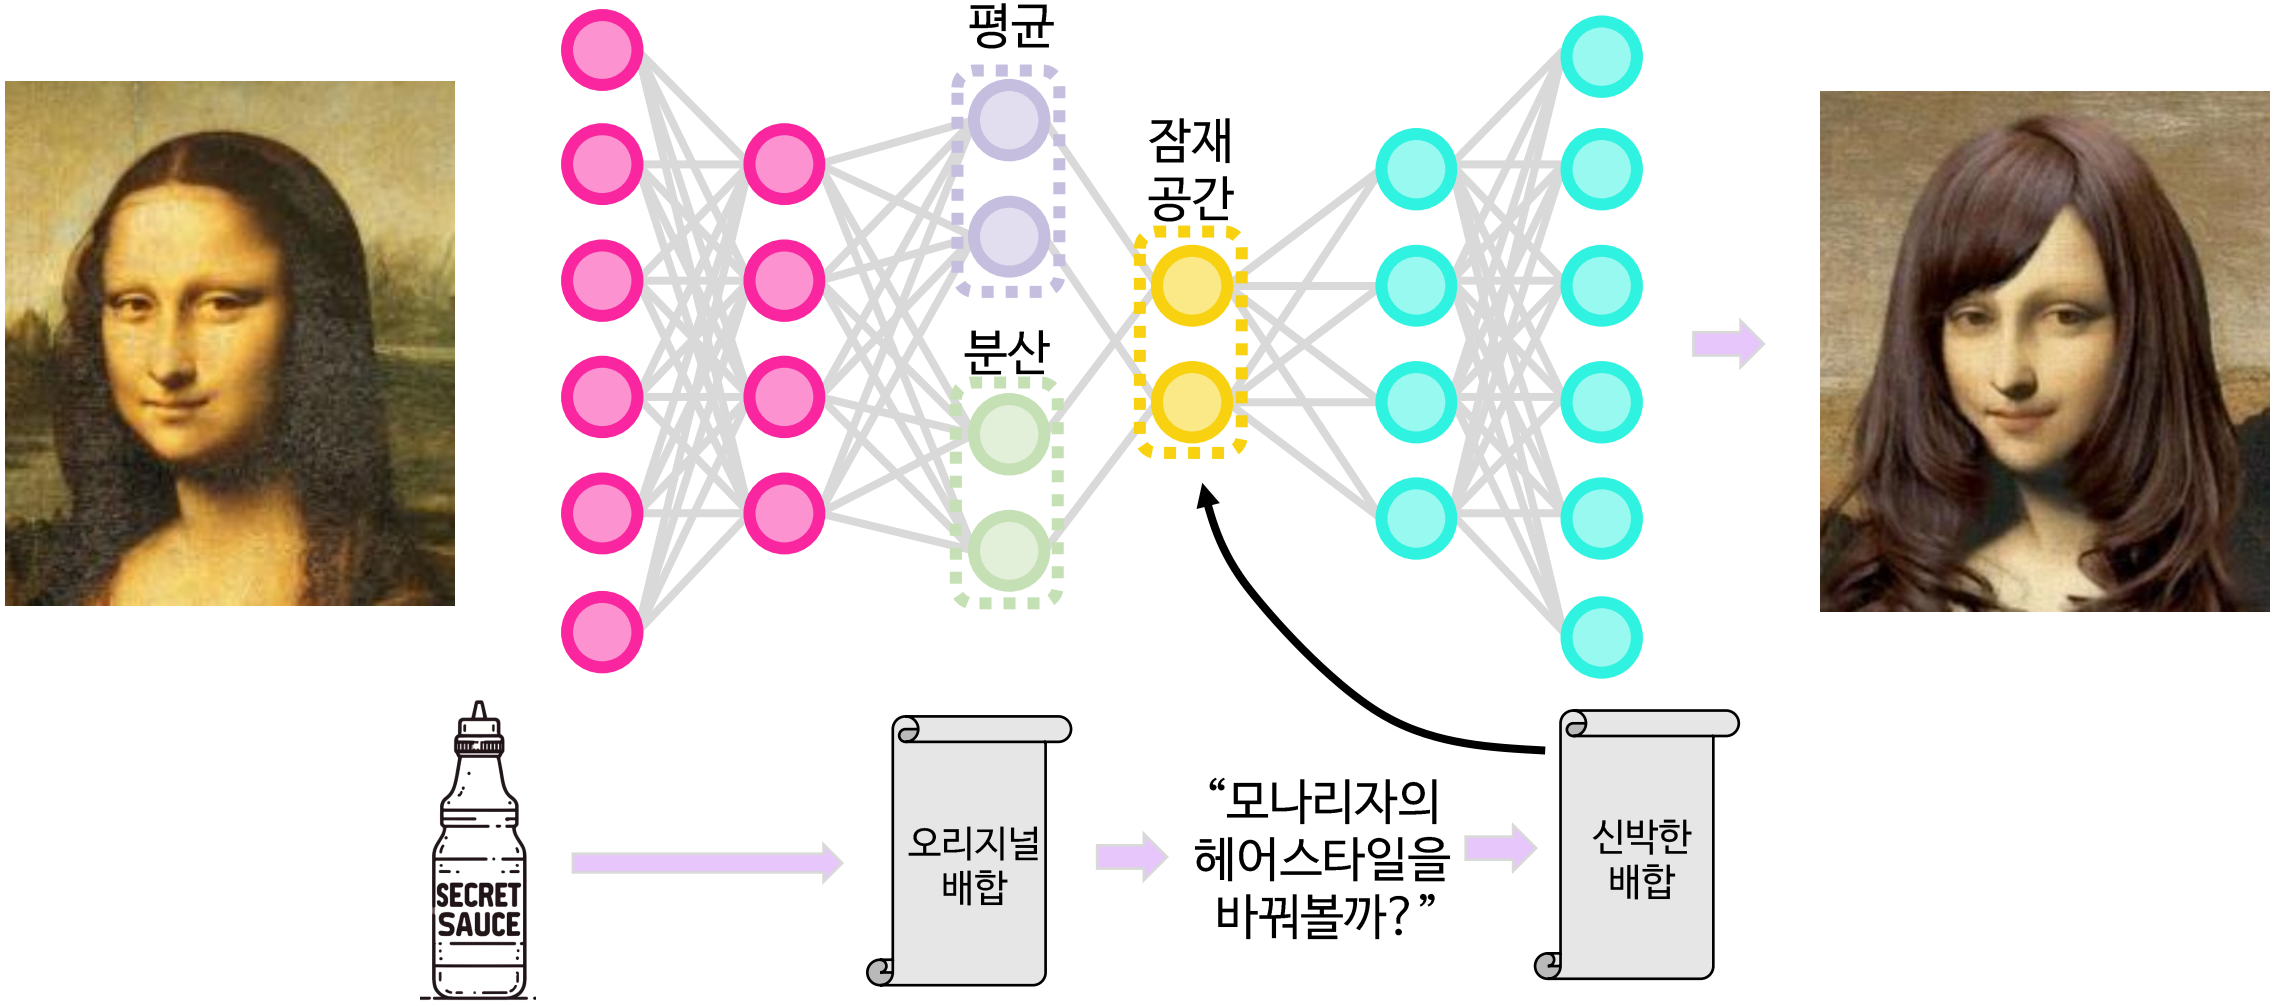

신박AI

아무튼, 오토인코더는 단순히 데이터를 복원하는 것에 그치지만,

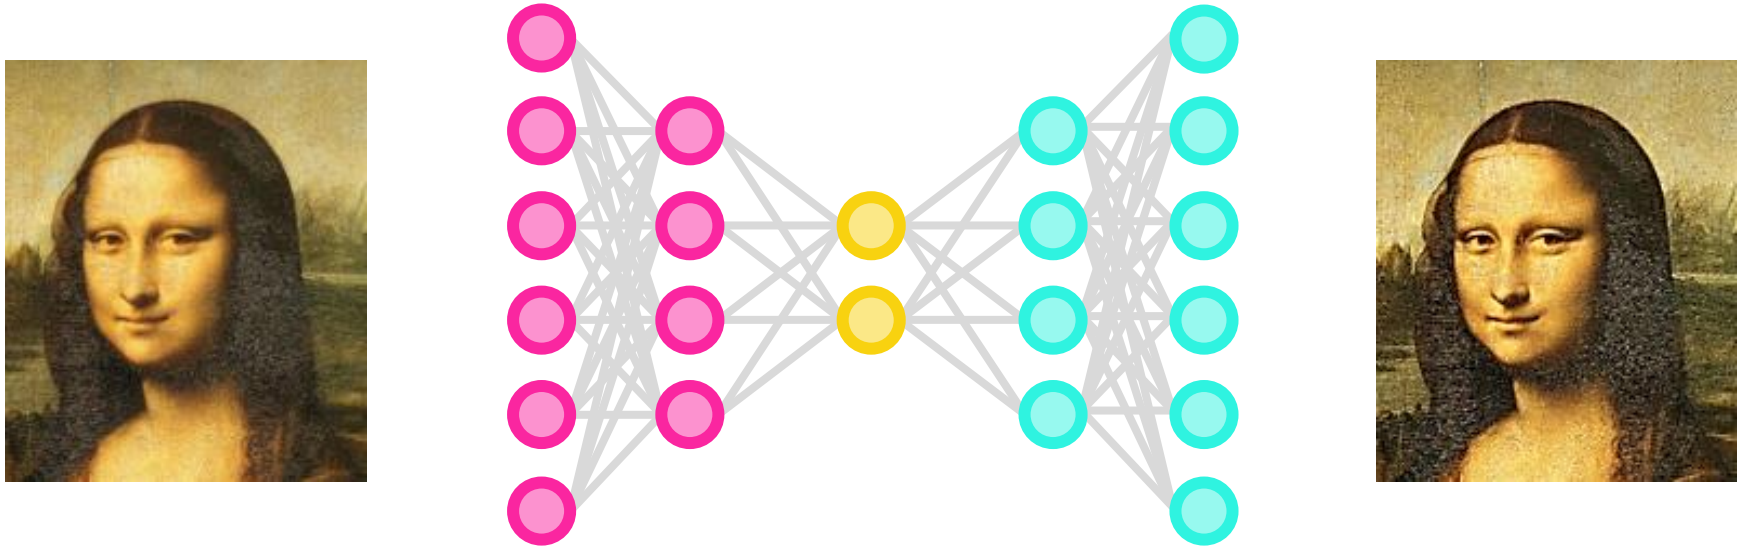

VAE는 새로운 데이터를 생성할 수 있는 능력을 갖추고 있습니다.

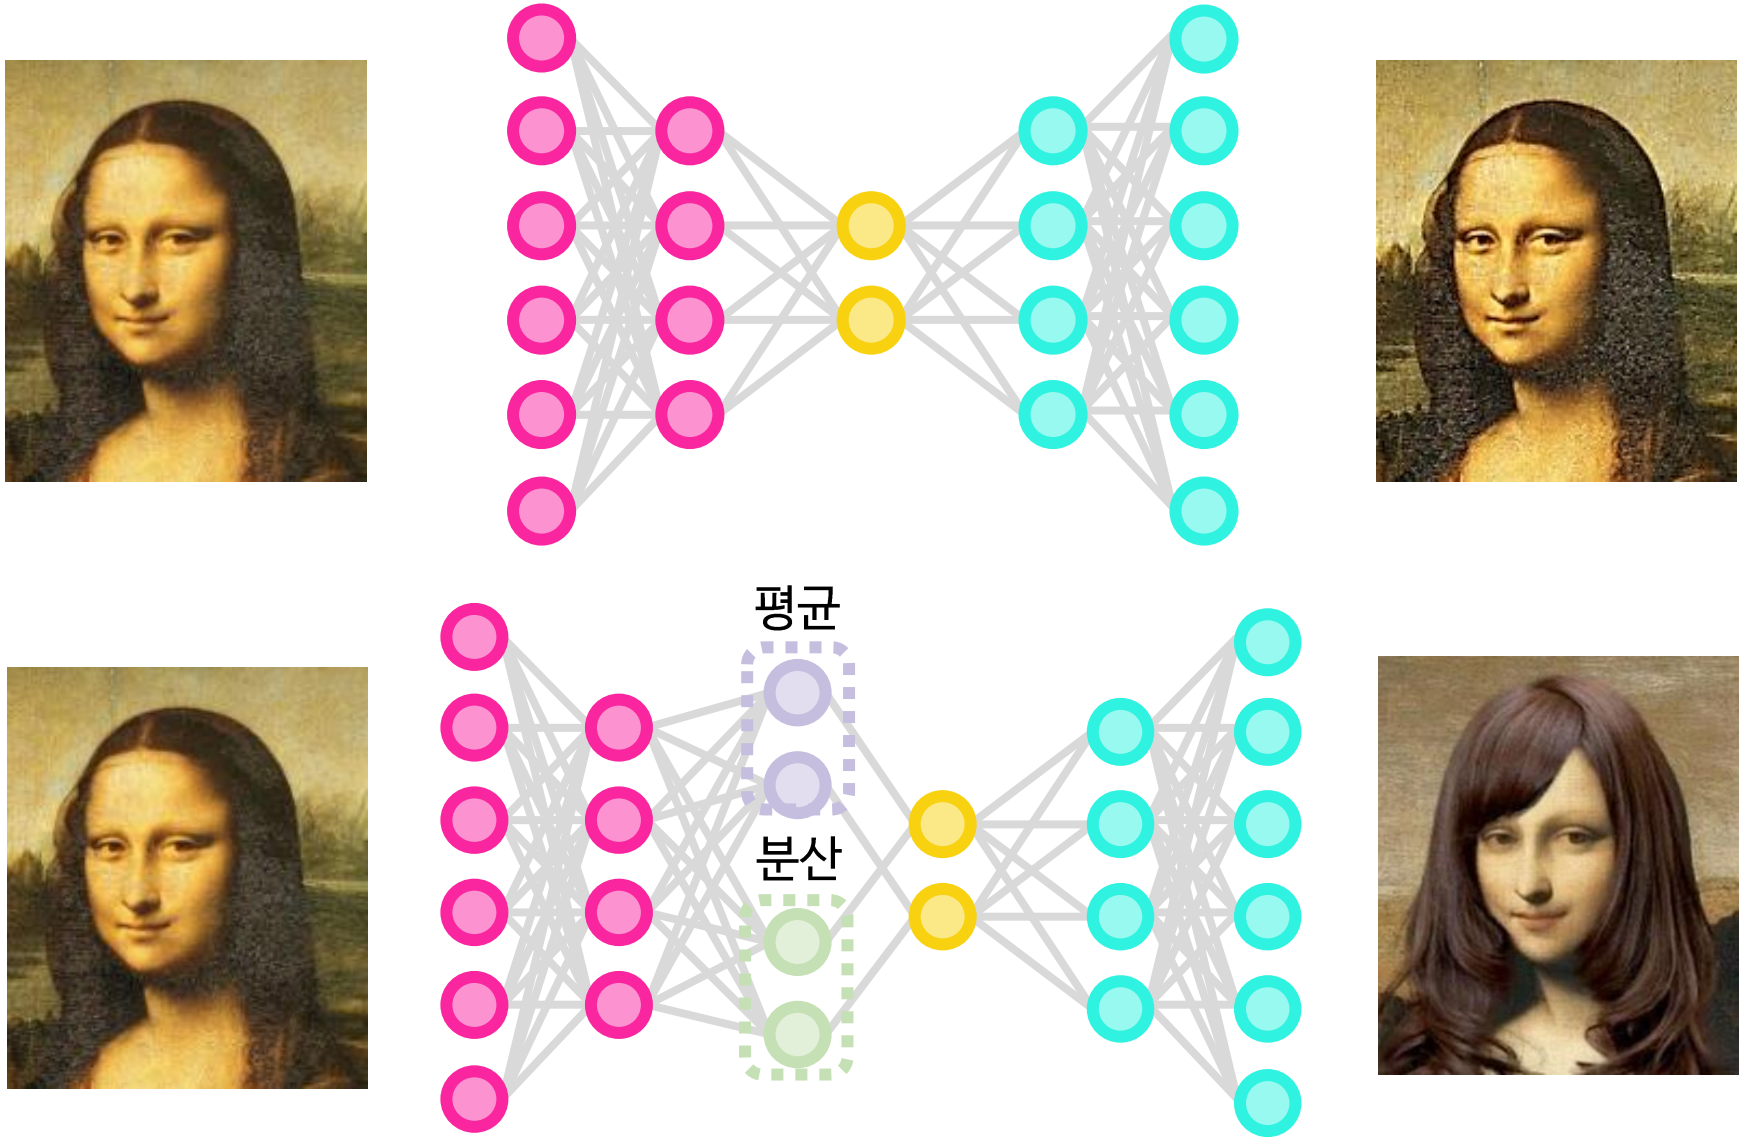

신박AI

이를 통해 VAE는 데이터의 다양성을 보다 잘 반영할 수 있게 됩니다.

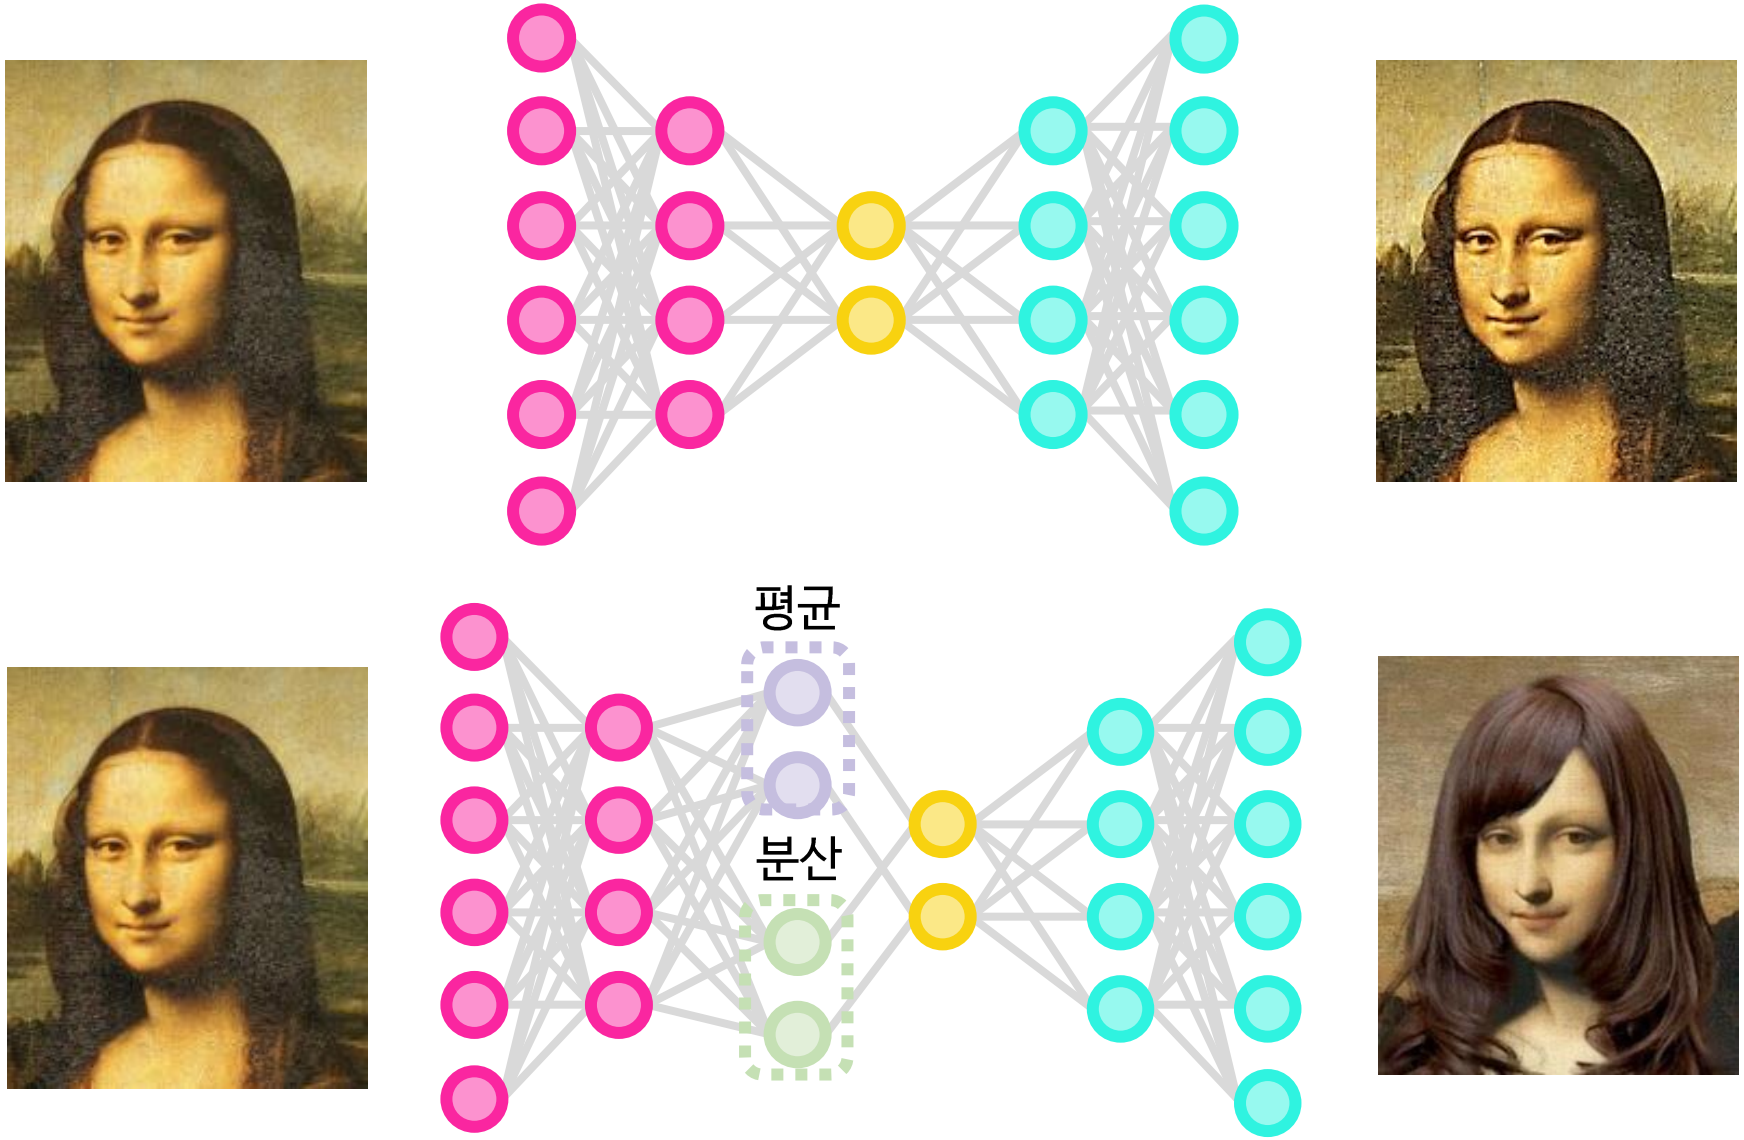

신박AI

이제는 구체적인 숫자와 손계산을 통해 VAE의 작동 방식을 알아보도록 하겠습니다.

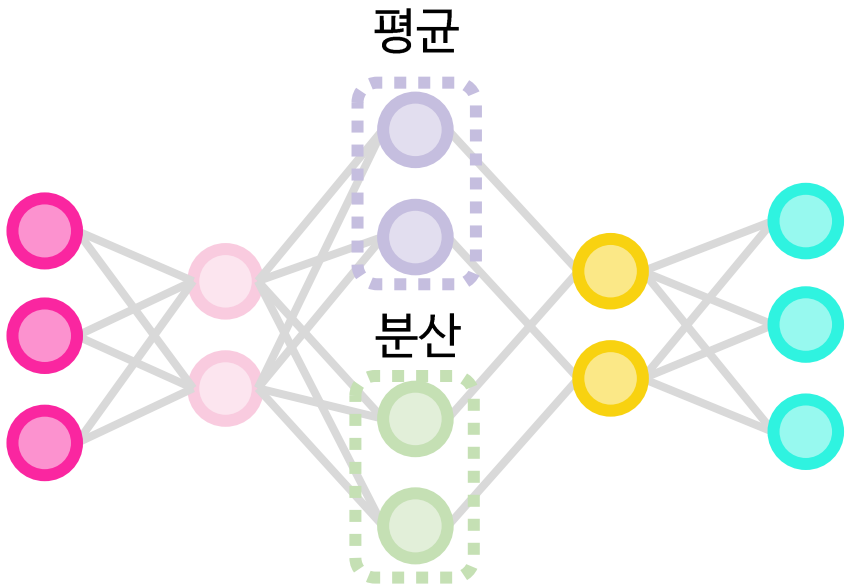

신박AI

먼저, 인코더 부분입니다.

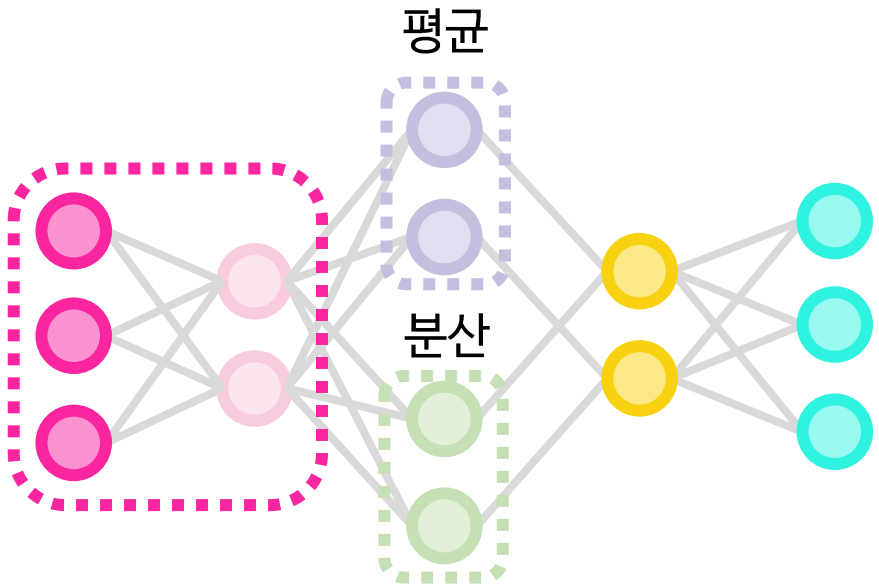

신박AI

인코더는 입력 벡터를 받아서,

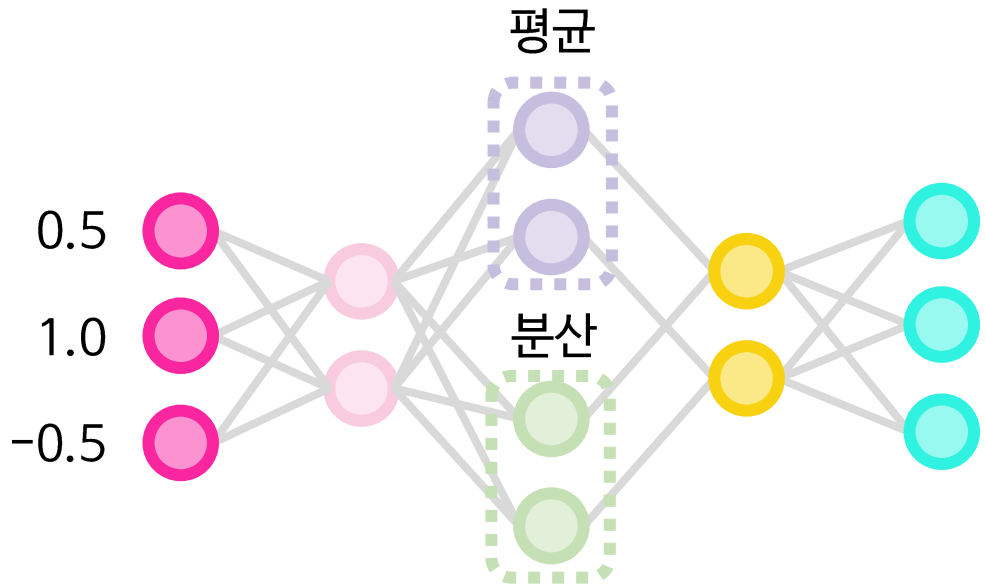

신박AI

은닉층의 크기가 2인 두 개의 평균 μ와 두 개의 로그 분산 $log(\mu^2)$을 계산합니다.

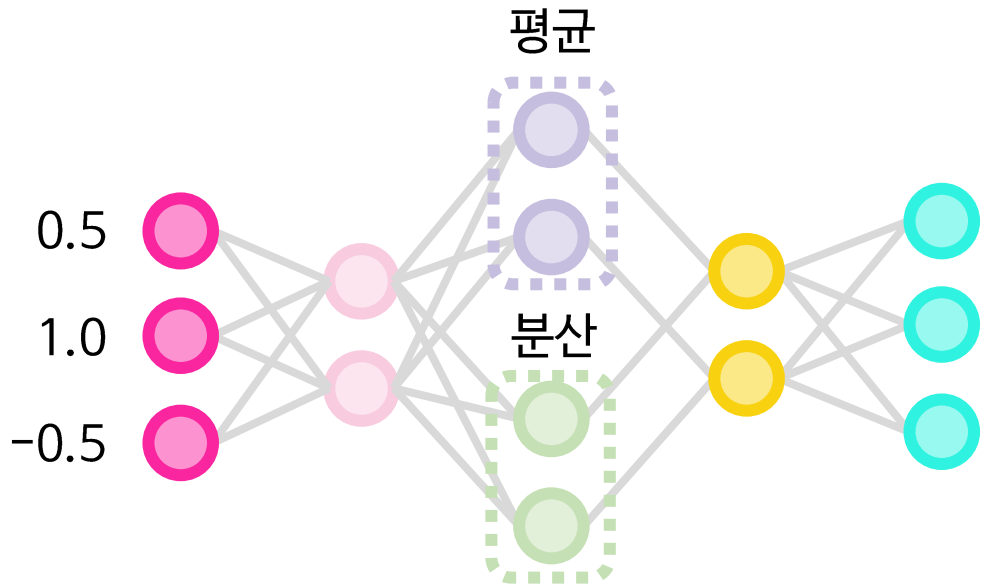

신박AI

인코더의 가중치 W_e와 바이어스 b_e 는 다음과 같이 설정하도록 하겠습니다.

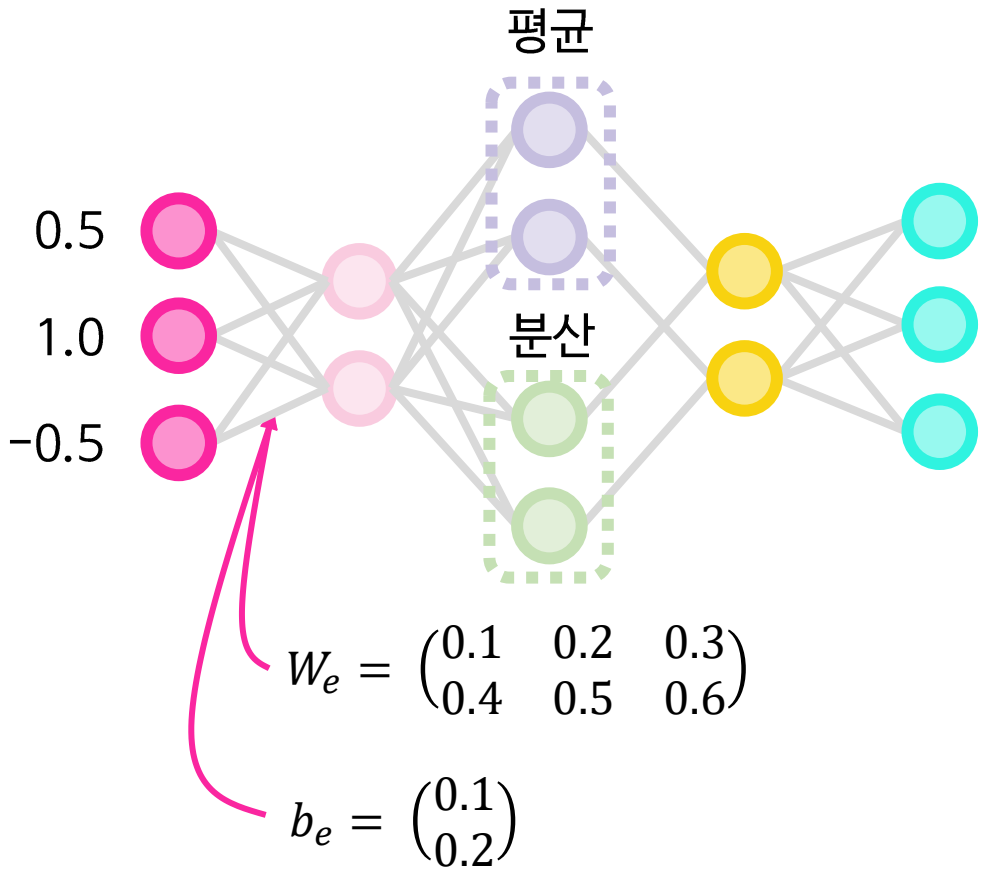

입력 벡터 [0.5,1.0,−0.5]에 대해 은닉층의 활성화 값 h는 다음과 같이 계산됩니다

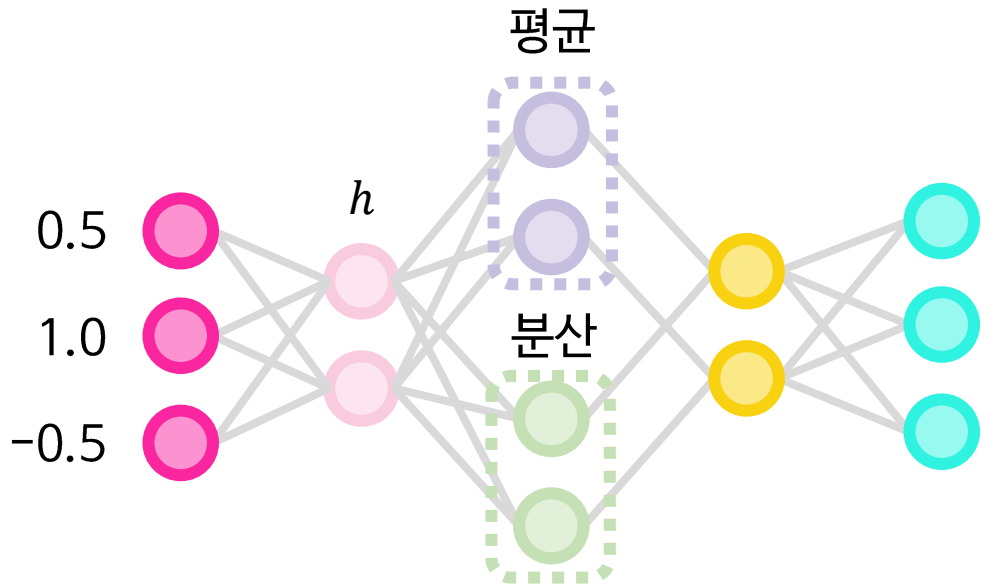

$$h = W_e \cdot x + b_e = \begin{pmatrix} 0.1 & 0.2 & 0.3 \\ 0.4 & 0.5 & 0.6 \end{pmatrix} \cdot \begin{pmatrix} 0.5 \\ 1.0 \\ -0.5 \end{pmatrix} + \begin{pmatrix} 0.1 \\ 0.2 \end{pmatrix}$$

$$= W_e \cdot x + b_e = \begin{pmatrix} 0.1 \cdot 0.5 + 0.2 \cdot 1.0 + 0.3 \cdot (-0.5) + 0.1 \\ 0.4 \cdot 0.5 + 0.5 \cdot 1.0 + 0.6 \cdot (-0.5) + 0.2 \end{pmatrix}$$

$$= \begin{pmatrix} 0.05 + 0.2 - 0.15 + 0.1 \\ 0.2 + 0.5 - 0.3 + 0.2 \end{pmatrix} = \begin{pmatrix} 0.2 \\ 0.6 \end{pmatrix}$$

신박AI

이제 은닉층의 출력 h에서 평균 μ와 로그 분산 $\log(\sigma^2)$를 계산합니다.

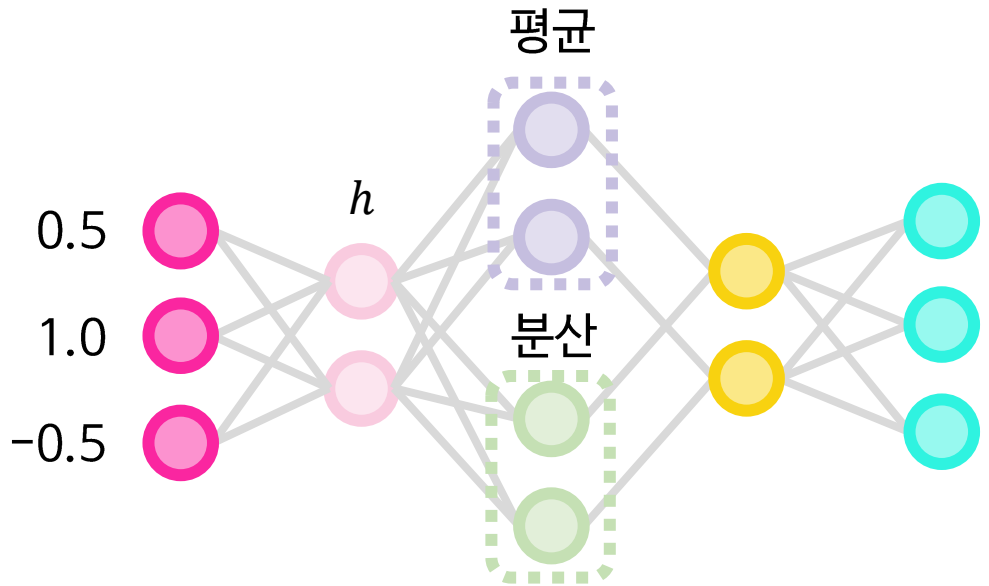

이를 위해 두 개의 선형 변환 W_μ, $W_{\log(\sigma^2)}$ 와 각각의 바이어스를 사용합니다

$$W_\mu = \begin{pmatrix} 0.1 & -0.1 \\ 0.2 & -0.2 \end{pmatrix}$$

$$b_\mu = \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

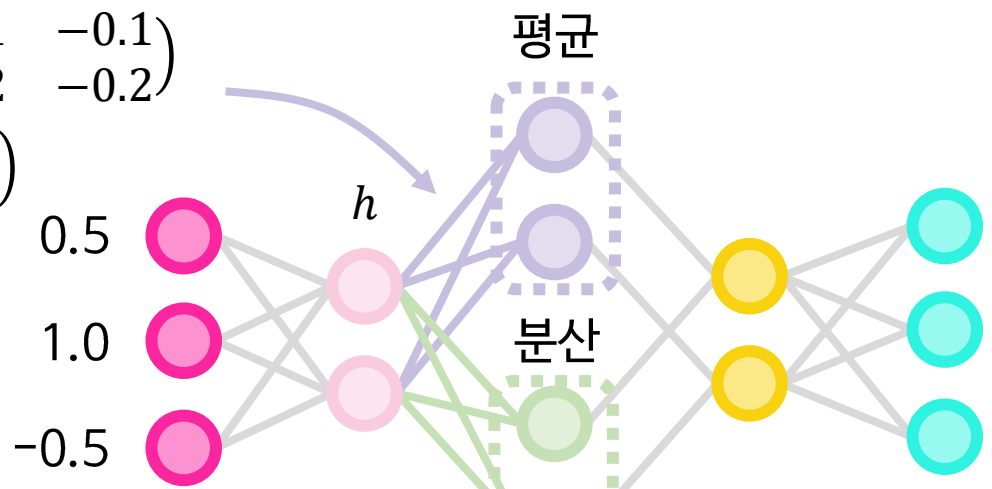

$$W_{\log(\sigma^2)} = \begin{pmatrix} 0.3 & -0.3 \\ 0.4 & -0.4 \end{pmatrix}$$

$$b_{\log(\sigma^2)} = \begin{pmatrix} 0.1 \\ 0.2 \end{pmatrix}$$

평균μ는 다음과 같이 계산됩니다:

$$W_\mu = \begin{pmatrix} 0.1 & -0.1 \\ 0.2 & -0.2 \end{pmatrix}$$

$$b_\mu = \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

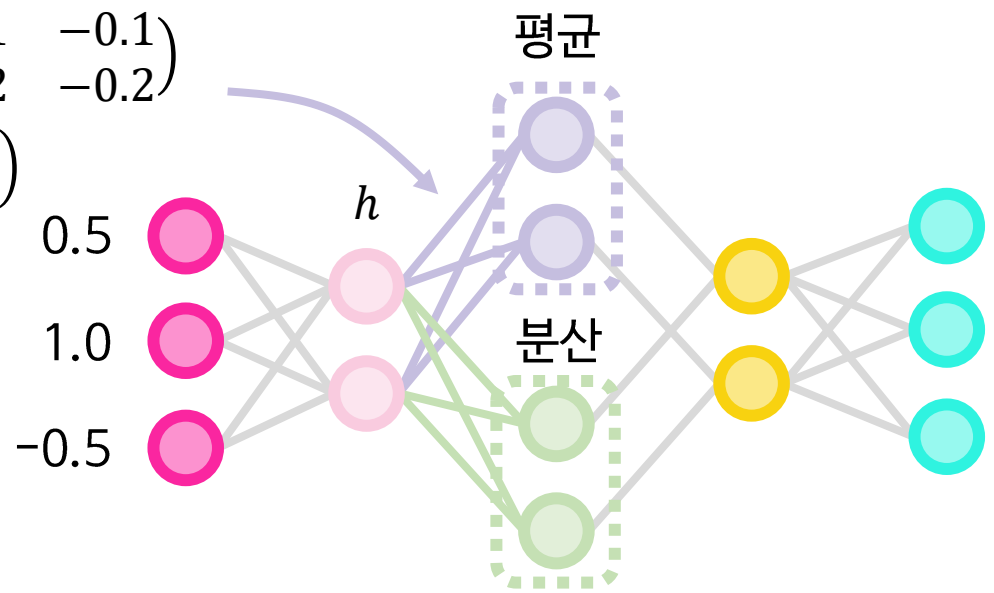

$$\mu = W_\mu \cdot h + b_\mu = \begin{pmatrix} 0.1 & -0.1 \\ 0.2 & -0.2 \end{pmatrix} \cdot \begin{pmatrix} 0.2 \\ 0.6 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

$$= \begin{pmatrix} 0.1 \cdot 0.2 + (-0.1) \cdot 0.6 \\ 0.2 \cdot 0.2 + (-0.2) \cdot 0.6 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

$$= \begin{pmatrix} 0.02 - 0.06 \\ 0.04 - 0.12 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

$$= \begin{pmatrix} -0.04 \\ -0.08 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix} = \begin{pmatrix} -0.04 \\ 0.02 \end{pmatrix}$$

평균μ는 다음과 같이 계산됩니다:

$$W_\mu = \begin{pmatrix} 0.1 & -0.1 \\ 0.2 & -0.2 \end{pmatrix}$$

$$b_\mu = \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

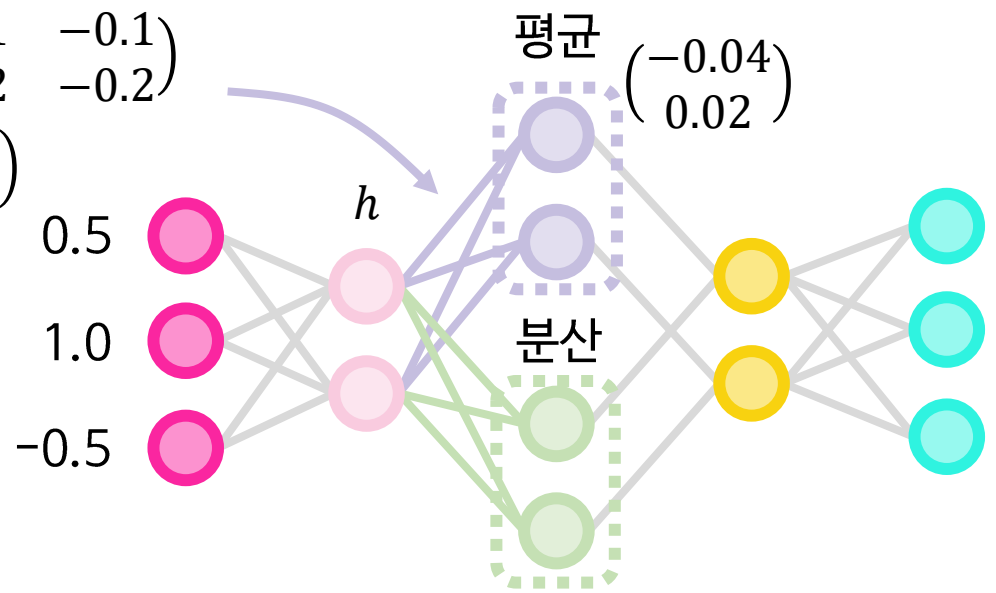

$$\mu = W_\mu \cdot h + b_\mu = \begin{pmatrix} 0.1 & -0.1 \\ 0.2 & -0.2 \end{pmatrix} \cdot \begin{pmatrix} 0.2 \\ 0.6 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

$$= \begin{pmatrix} 0.1 \cdot 0.2 + (-0.1) \cdot 0.6 \\ 0.2 \cdot 0.2 + (-0.2) \cdot 0.6 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

$$= \begin{pmatrix} 0.02 - 0.06 \\ 0.04 - 0.12 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix}$$

$$= \begin{pmatrix} -0.04 \\ -0.08 \end{pmatrix} + \begin{pmatrix} 0.0 \\ 0.1 \end{pmatrix} = \begin{pmatrix} -0.04 \\ 0.02 \end{pmatrix}$$

로그 분산 $\log(\sigma^2)$는 다음과 같이 계산됩니다:

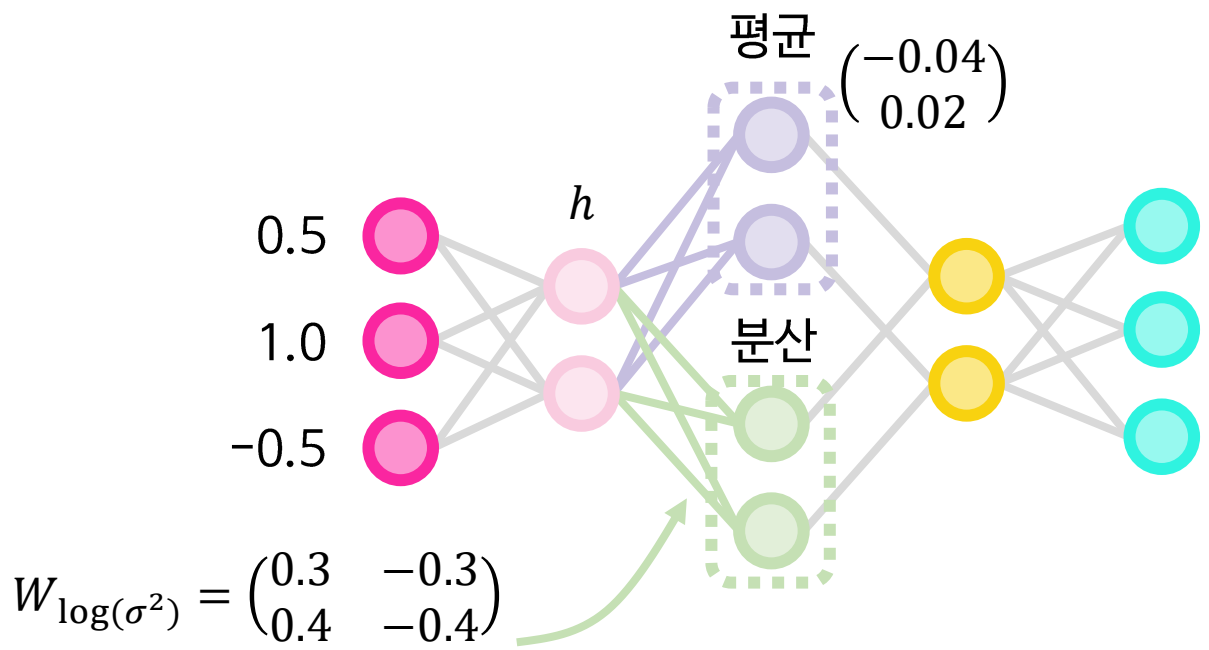

$$W_{\log(\sigma^2)} = \begin{pmatrix}0.3 & -0.3\\0.4 & -0.4\end{pmatrix}$$

$$b_{\log(\sigma^2)} = \begin{pmatrix}0.1\\0.2\end{pmatrix}$$

$$\mu = W_{\log(\sigma^2)} \cdot h + b_{\log(\sigma^2)} = \begin{pmatrix}0.3 & -0.3\\0.4 & -0.4\end{pmatrix} \cdot \begin{pmatrix}0.2\\0.6\end{pmatrix} + \begin{pmatrix}0.1\\0.2\end{pmatrix}$$

$$= \begin{pmatrix}0.3 \cdot 0.2 + (-0.3) \cdot 0.6\\0.4 \cdot 0.2 + (-0.4) \cdot 0.6\end{pmatrix} + \begin{pmatrix}0.1\\0.2\end{pmatrix}$$

$$= \begin{pmatrix}0.06 - 0.18\\0.08 - 0.24\end{pmatrix} + \begin{pmatrix}0.1\\0.2\end{pmatrix}$$

$$= \begin{pmatrix}-0.12\\-016\end{pmatrix} + \begin{pmatrix}0.1\\0.2\end{pmatrix} = \begin{pmatrix}-0.02\\0.04\end{pmatrix}$$

신박AI

로그 분산 $\log(\sigma^2)$는 다음과 같이 계산됩니다:

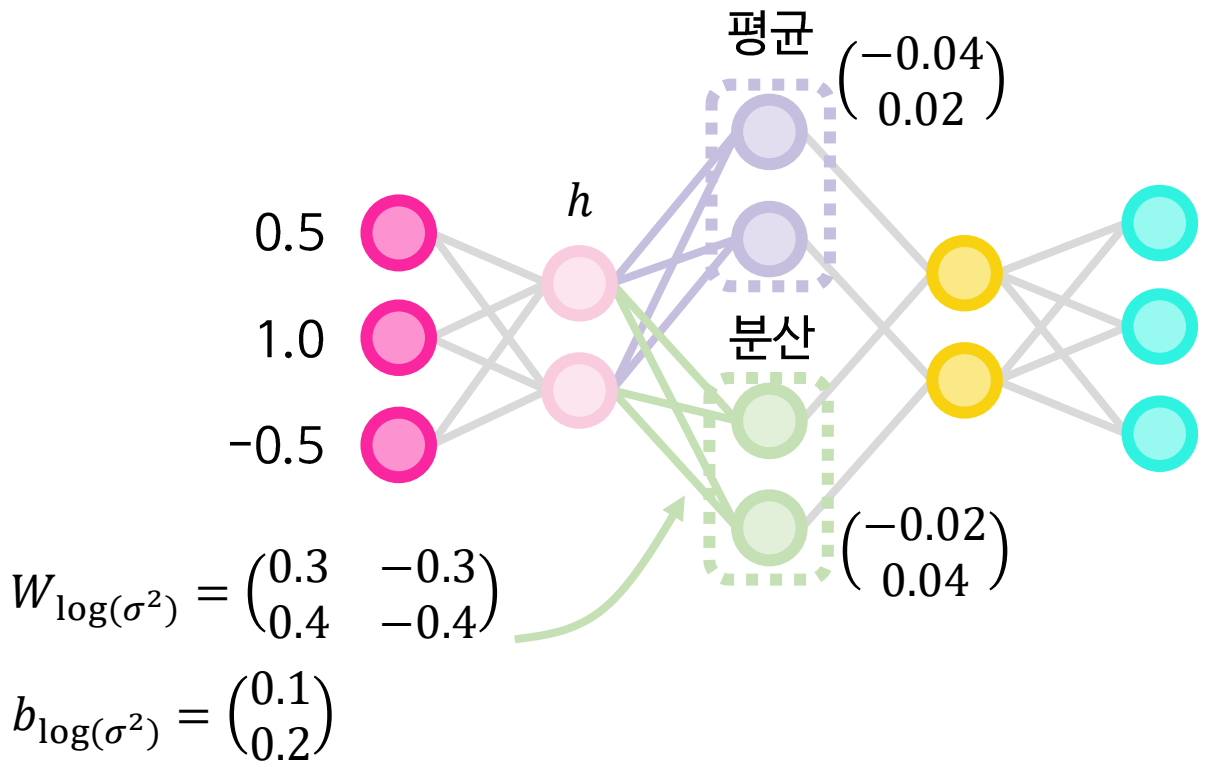

신박AI

이제 재파라미터화 트릭을 사용하여 잠재 변수 z 를 샘플링 하도록 하겠습니다.

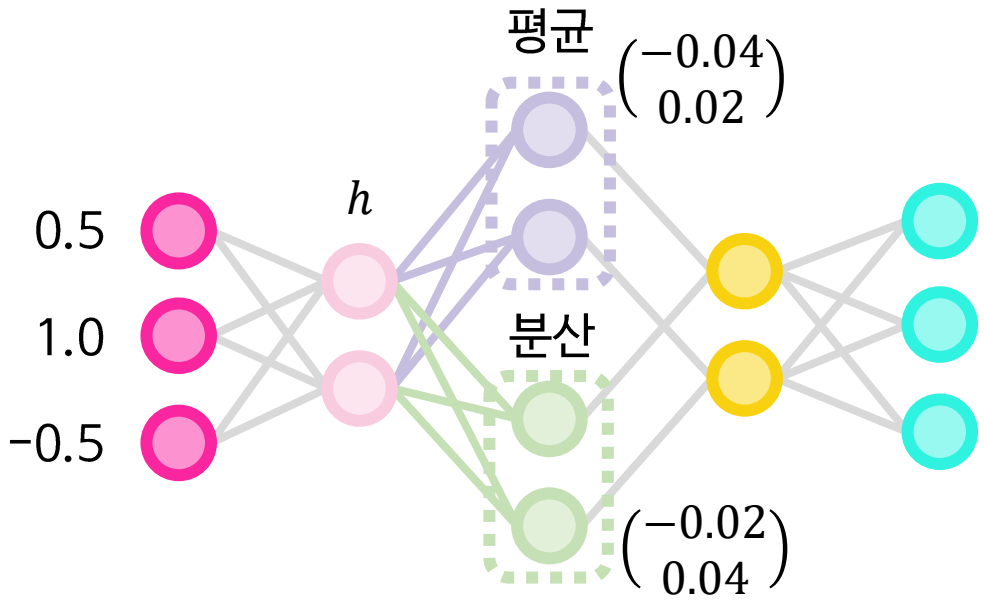

재파라미터화 트릭이란, 정규분포화 된 (평균과 분산) 잠재변수의 분포를 사용하여 잠재 변수 z 를 재구성 하는 것입니다.

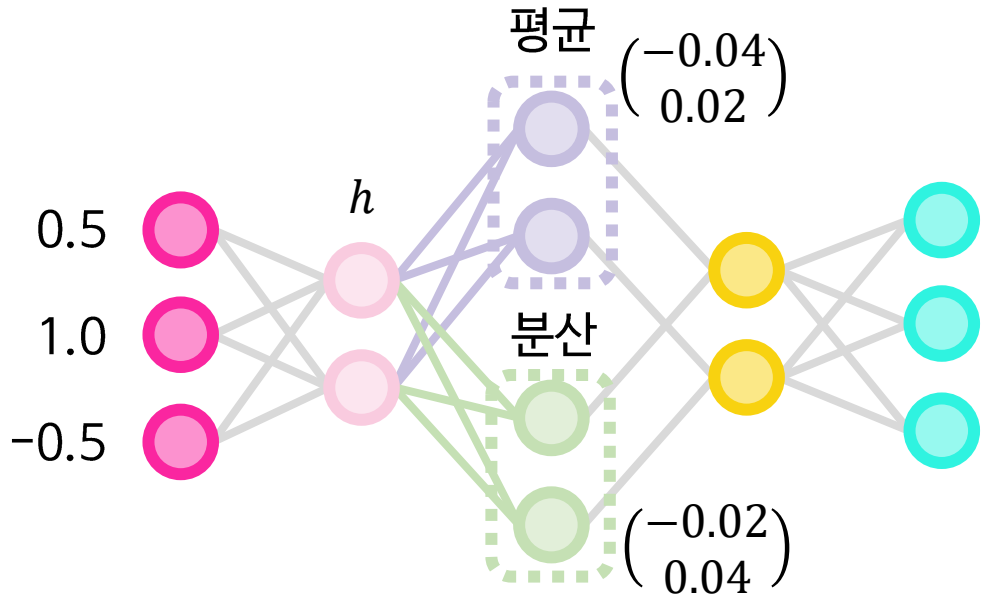

신박AI

이를 위해 표준 정규 분포에서 샘플링된 ϵ을 사용하여 $z = \mu + \sigma \cdot \epsilon$을 계산합니다.

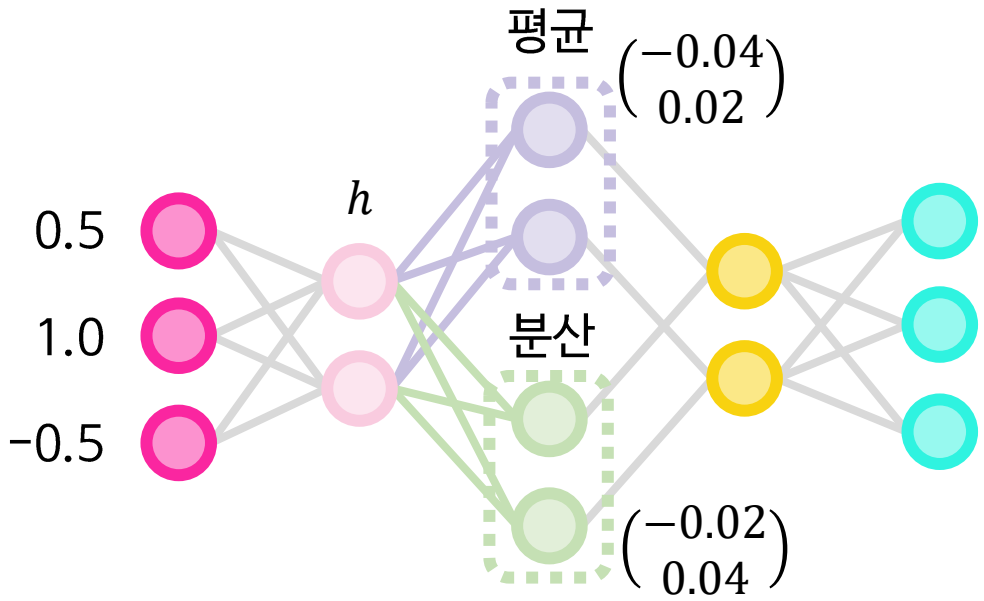

$$z = \mu + \sigma \cdot \epsilon$$

여기서 ϵ은 표준 정규 분포에서 샘플링된 무작위 값입니다.

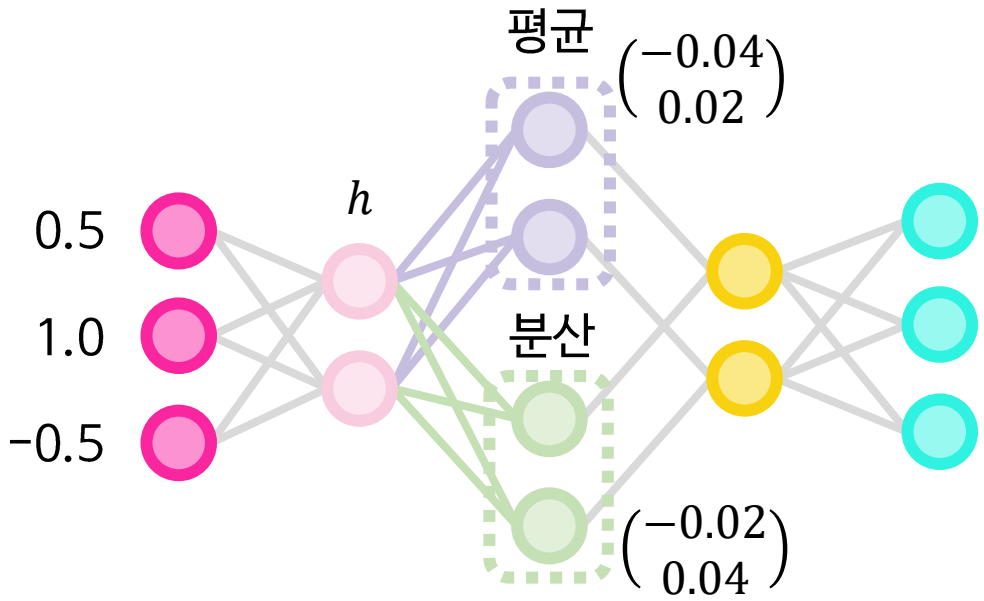

$$z = \mu + \sigma \cdot \epsilon$$

예를 들어 ϵ를 다음과 같다고 가정하겠습니다.

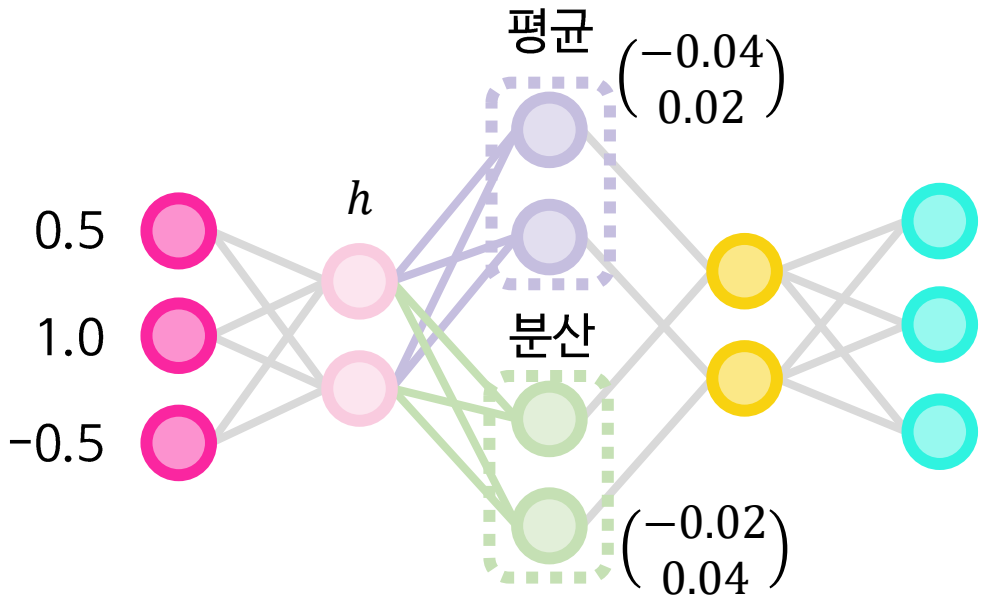

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

먼저, 표준 편차 σ를 계산하도록 하겠습니다.

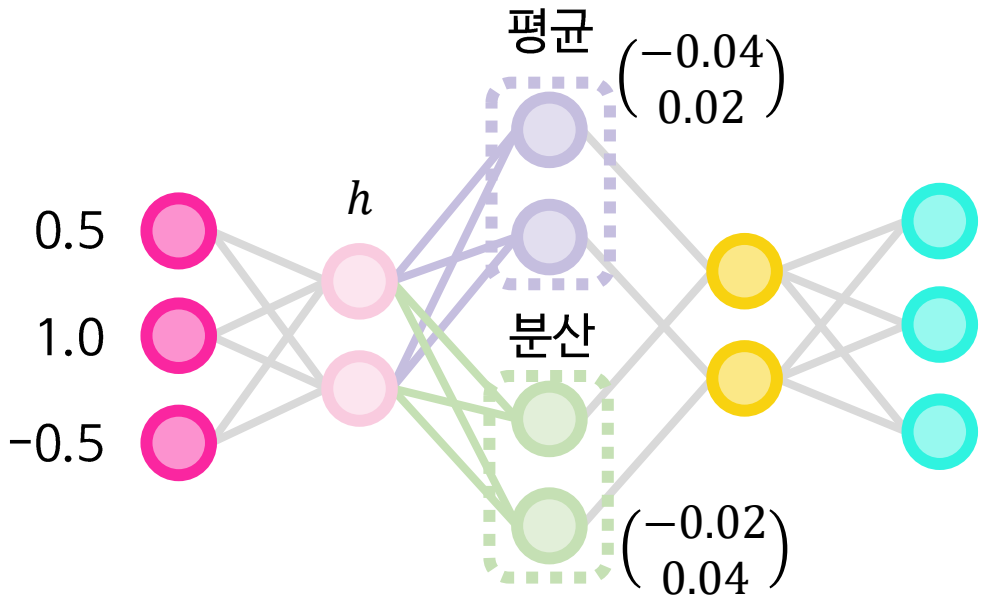

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

우선 VAE에서 사용하는 분산은, 엄밀히 말하면 로그 분산입니다.

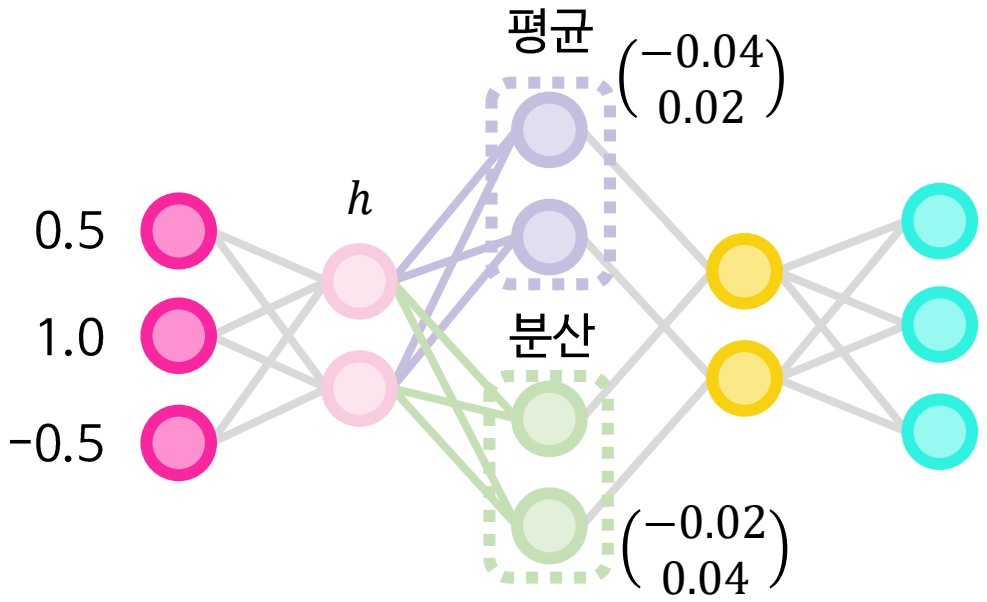

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

로그 분산을 사용하는 이유는
수치적으로 안정적이고 계산하기
쉽기 때문이라고 합니다!

신박AI

로그분산 $(\log(\sigma^2))$은 분산 (σ^2)의 로그 값이므로, 분산으로 바꾸려면 지수 함수를 사용해야 합니다.

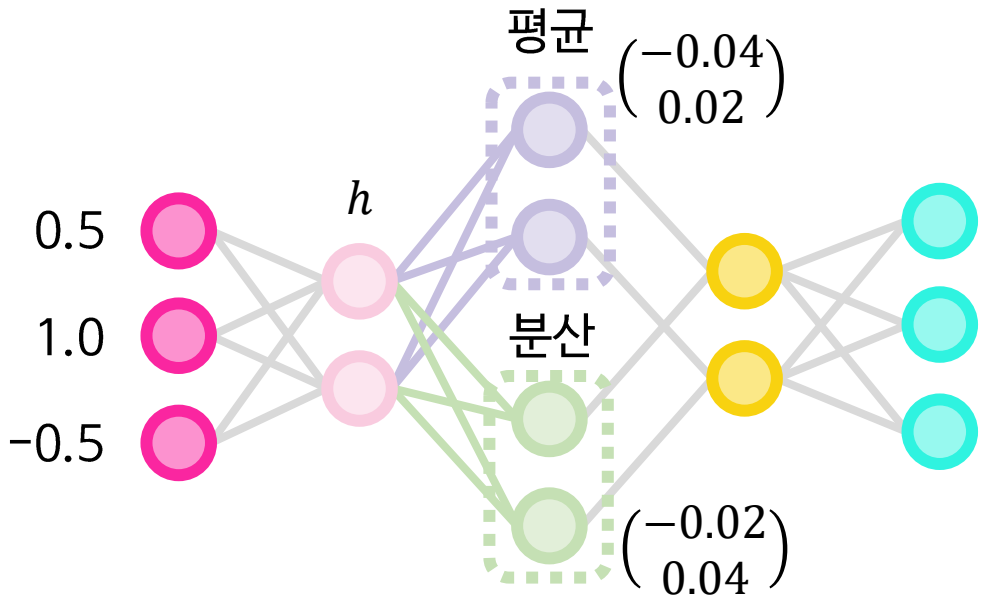

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

$$\sigma^2 = \exp(log(\sigma^2))$$

표준편차(σ)은 분산의 제곱근입니다. 따라서 다음과 같이 바꾸어 쓸수가 있습니다.

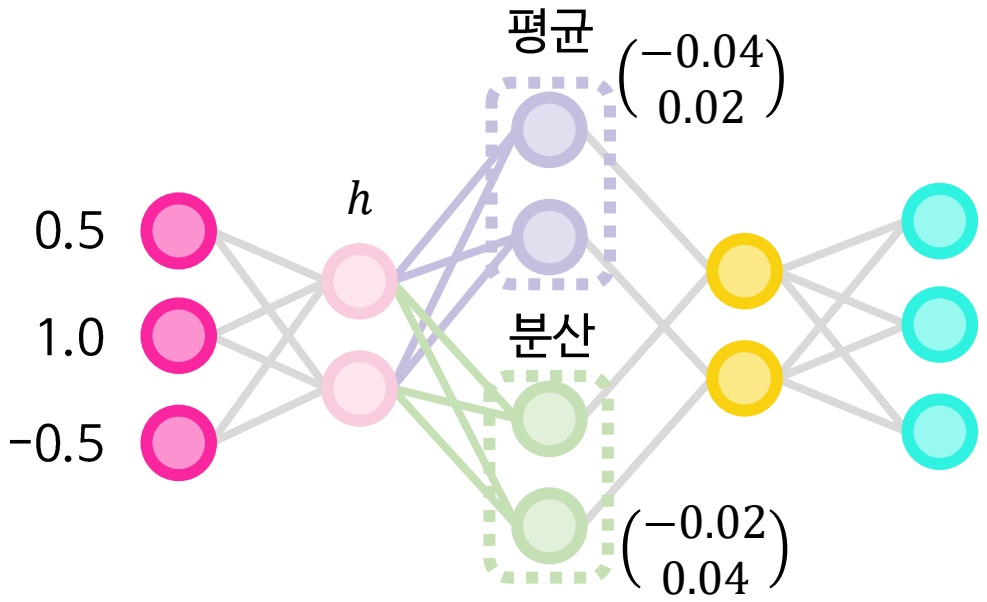

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

$$\sigma^2 = \exp(log(\sigma^2))$$

$$\sigma = \sqrt{\sigma^2} = \sqrt{\exp(log(\sigma^2))}$$

신박AI

표준편차(σ)은 분산의 제곱근입니다. 따라서 다음과 같이 바꾸어 쓸수가 있습니다.

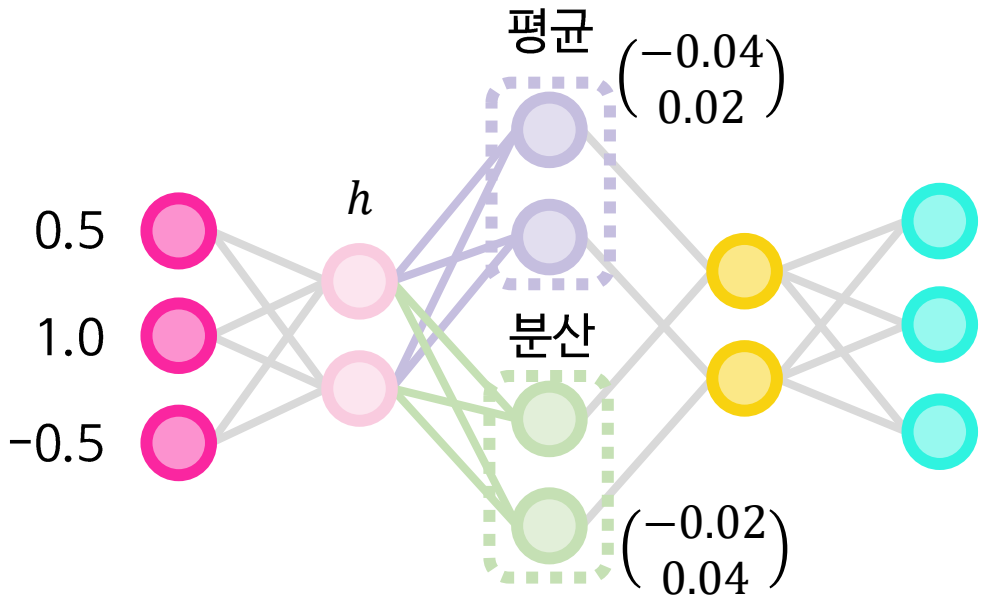

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

$$\sigma^2 = \exp(log(\sigma^2))$$

$$\sigma = \sqrt{\sigma^2} = \sqrt{\exp(log(\sigma^2))}$$

$$= \exp(\frac{1}{2} log\sigma^2)$$

신박AI

그러면, 표준 편차 σ 는 다음과 같이 계산할 수 있습니다.

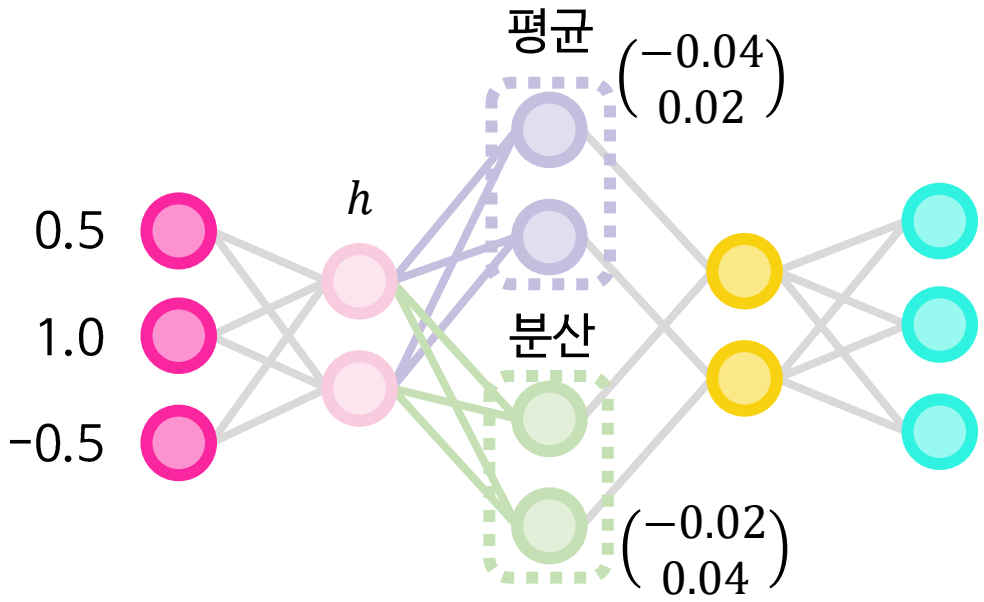

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

$$\sigma^2 = \exp(log(\sigma^2))$$

$$\sigma = \sqrt{\sigma^2} = \sqrt{\exp(log(\sigma^2))}$$

$$= \exp(\frac{1}{2} log\sigma^2) = \exp\left(0.5 \cdot \begin{pmatrix}-0.02\\0.04\end{pmatrix}\right) = \begin{pmatrix}\exp(-0.01)\\\exp(0.02)\end{pmatrix} \approx \begin{pmatrix}0.99\\1.02\end{pmatrix}$$

신박AI

이제 잠재 변수 z를 샘플링합니다:

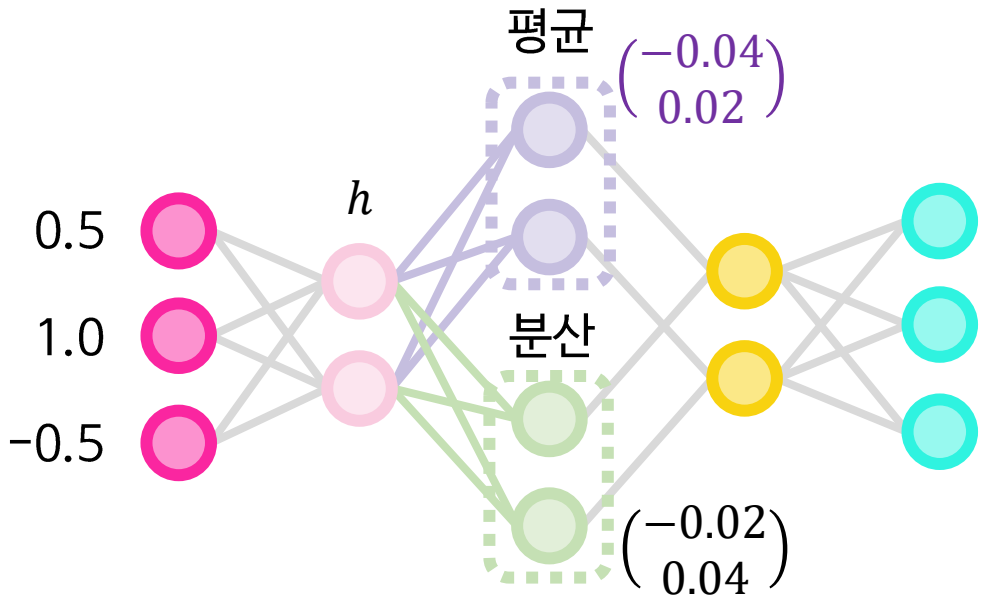

$$z = \mu + \sigma \cdot \epsilon \qquad \epsilon = \begin{pmatrix}0.5\\-0.5\end{pmatrix} \qquad \sigma = \begin{pmatrix}0.99\\1.02\end{pmatrix}$$

$$z = \mu + \sigma \cdot \epsilon = \begin{pmatrix}-0.04\\0.02\end{pmatrix} + \begin{pmatrix}0.99\\1.02\end{pmatrix} \cdot \begin{pmatrix}0.5\\-0.5\end{pmatrix}$$

$$= \begin{pmatrix}-0.04 + 0.99 \cdot 0.5\\0.02 + 1.02 \cdot (-0.5)\end{pmatrix}$$

$$= \begin{pmatrix}-0.04 + 0.495\\0.02 - 0.51\end{pmatrix} = \begin{pmatrix}0.455\\-0.49\end{pmatrix}$$

신박AI

이제 잠재 변수 z를 샘플링합니다:

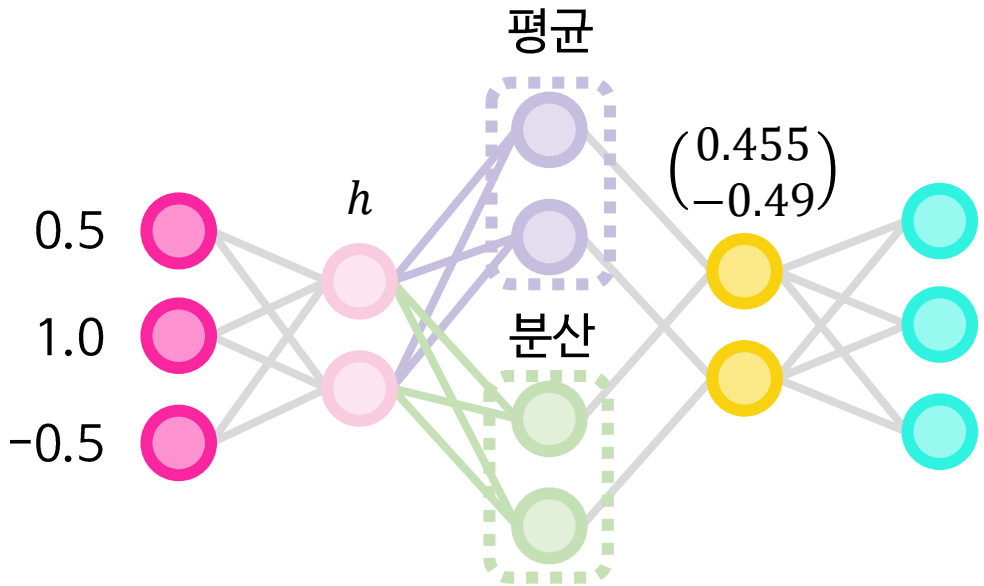

신박AI

이 잠재 변수 z는 디코더의 입력값이 됩니다.

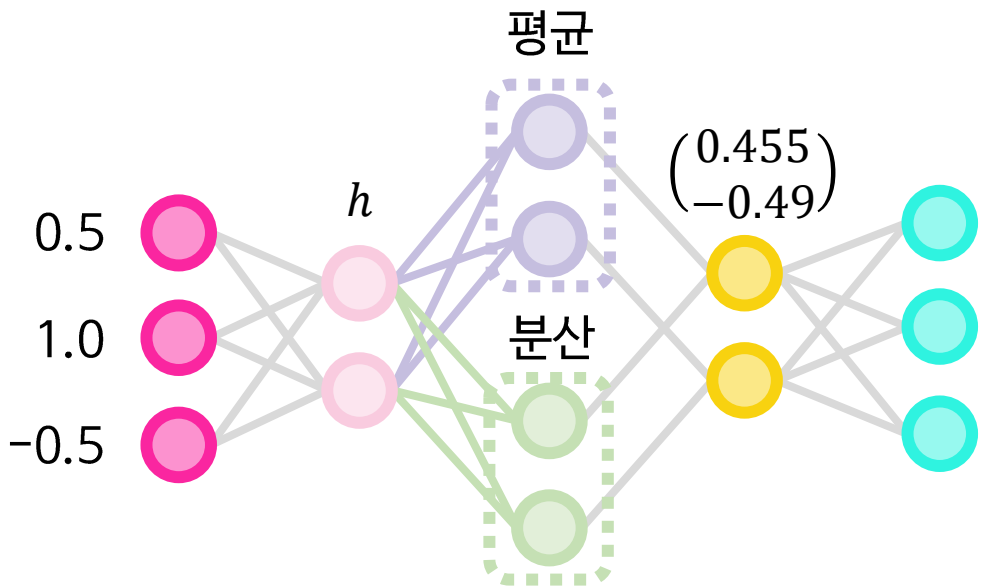

이제 디코더 부분입니다.

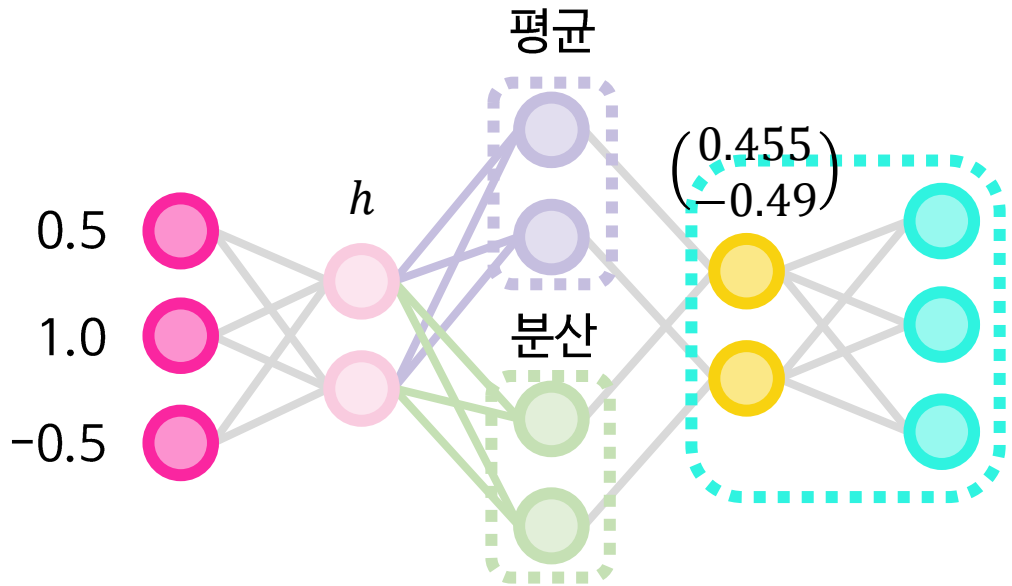

신박AI

디코더의 가중치 W_d와 바이어스 b_d 는 다음과 같이 설정하도록 하겠습니다.

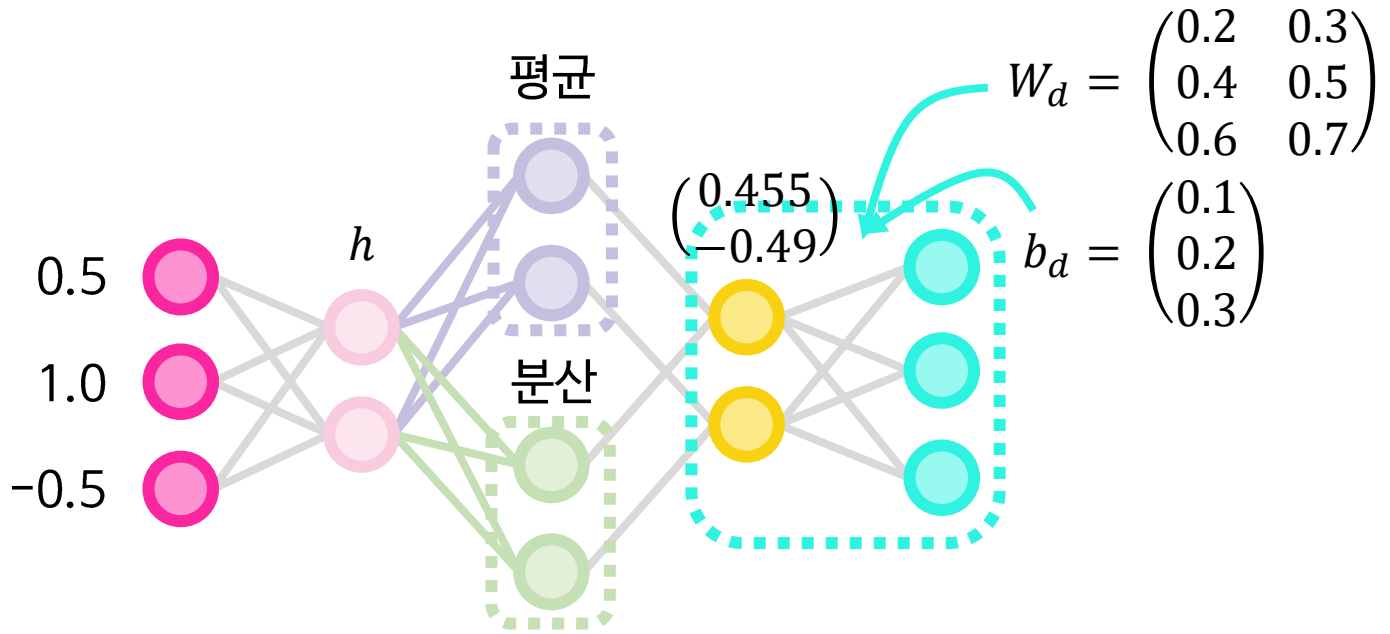

잠재변수 z를 디코더에 입력하여 출력벡터 x'를 계산합니다.

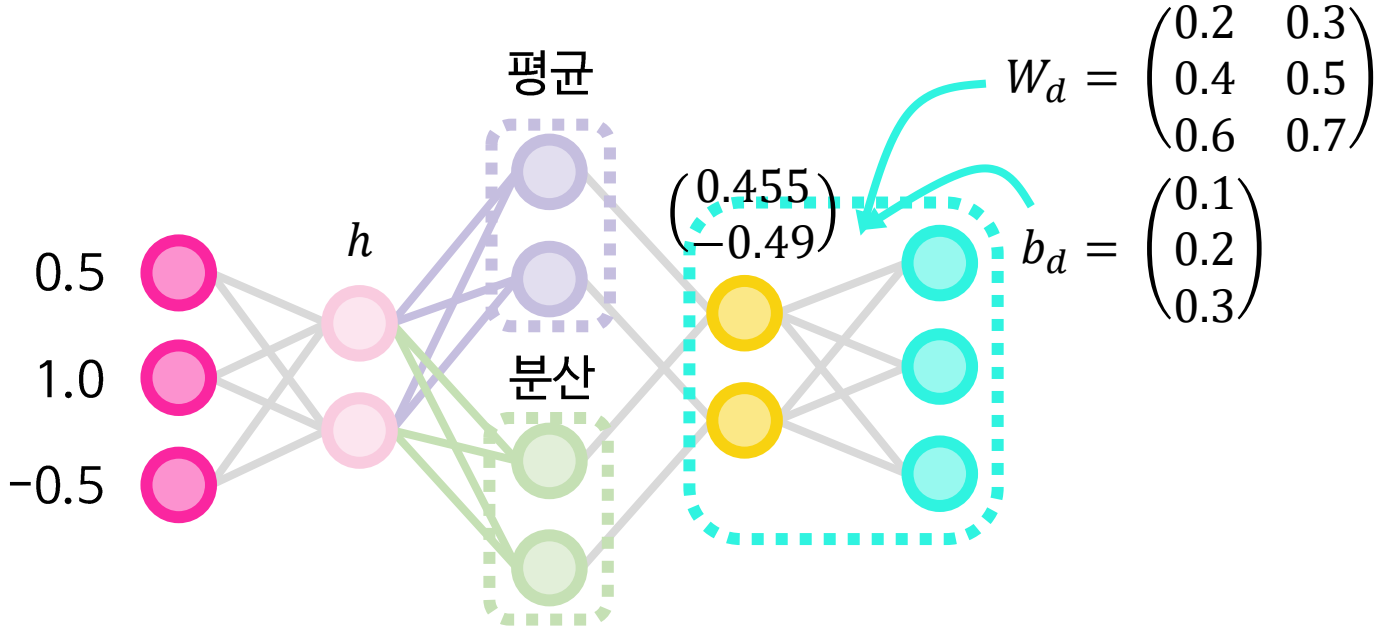

$$x' = W_d \cdot z + b_d = \begin{pmatrix}0.2 & 0.3\\0.4 & 0.5\\0.6 & 0.7\end{pmatrix} \cdot \begin{pmatrix}0.455\\-0.49\end{pmatrix} + \begin{pmatrix}0.1\\0.2\\0.3\end{pmatrix}$$

$$= \begin{pmatrix}0.2 \cdot 0.455 + 0.3 \cdot (-0.49)\\0.4 \cdot 0.455 + 0.5 \cdot (-0.49)\\0.6 \cdot 0.455 + 0.7 \cdot (-0.49)\end{pmatrix} + \begin{pmatrix}0.1\\0.2\\0.3\end{pmatrix}$$

$$= \begin{pmatrix}0.091 - 0.147\\0.182 - 0.245\\0.273 - 0.343\end{pmatrix} + \begin{pmatrix}0.1\\0.2\\0.3\end{pmatrix} = \begin{pmatrix}0.044\\0.137\\0.23\end{pmatrix}$$

이 출력벡터 x'가 VAE의 최종 출력값이 됩니다.

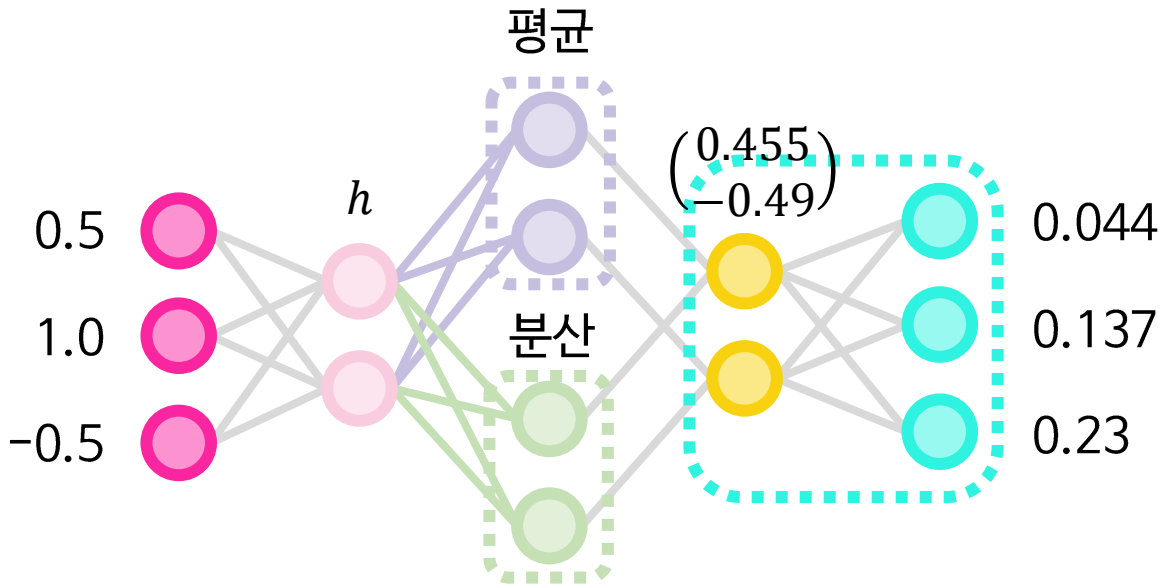

$$x' = W_d \cdot z + b_d = \begin{pmatrix}0.2 & 0.3\\0.4 & 0.5\\0.6 & 0.7\end{pmatrix} \cdot \begin{pmatrix}0.455\\-0.49\end{pmatrix} + \begin{pmatrix}0.1\\0.2\\0.3\end{pmatrix}$$

$$= \begin{pmatrix}0.2 \cdot 0.455 + 0.3 \cdot (-0.49)\\0.4 \cdot 0.455 + 0.5 \cdot (-0.49)\\0.6 \cdot 0.455 + 0.7 \cdot (-0.49)\end{pmatrix} + \begin{pmatrix}0.1\\0.2\\0.3\end{pmatrix}$$

$$= \begin{pmatrix}0.091 - 0.147\\0.182 - 0.245\\0.273 - 0.343\end{pmatrix} + \begin{pmatrix}0.1\\0.2\\0.3\end{pmatrix} = \begin{pmatrix}0.044\\0.137\\0.23\end{pmatrix} = x'$$

신박AI

이제 재구성손실과 KL Divergence를 계산해 보겠습니다.

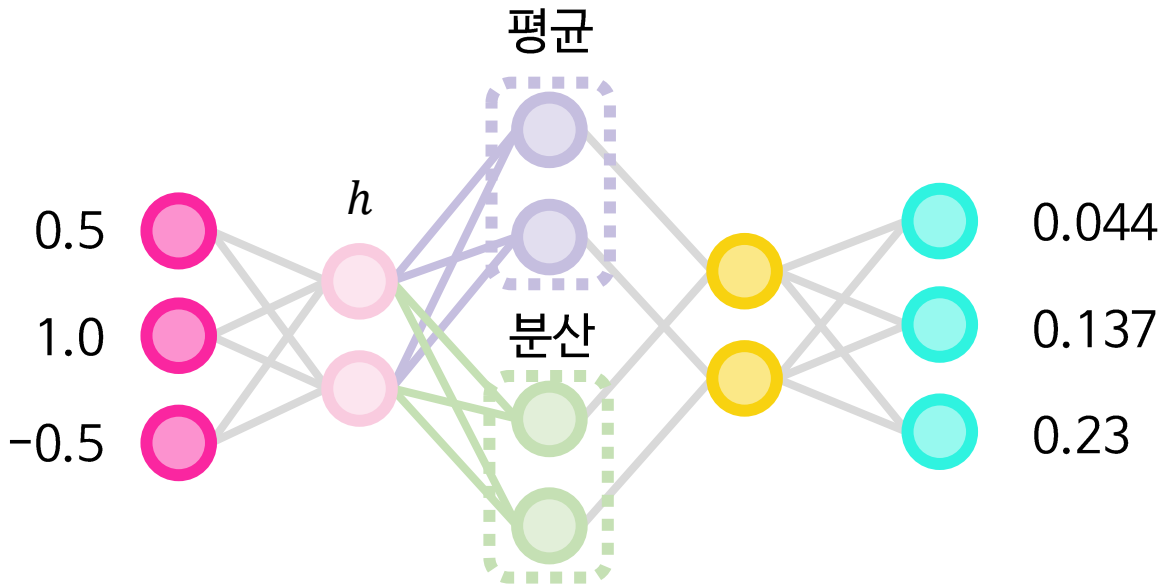

신박AI

재구성손실은 다음과 같이 계산할 수 있습니다.

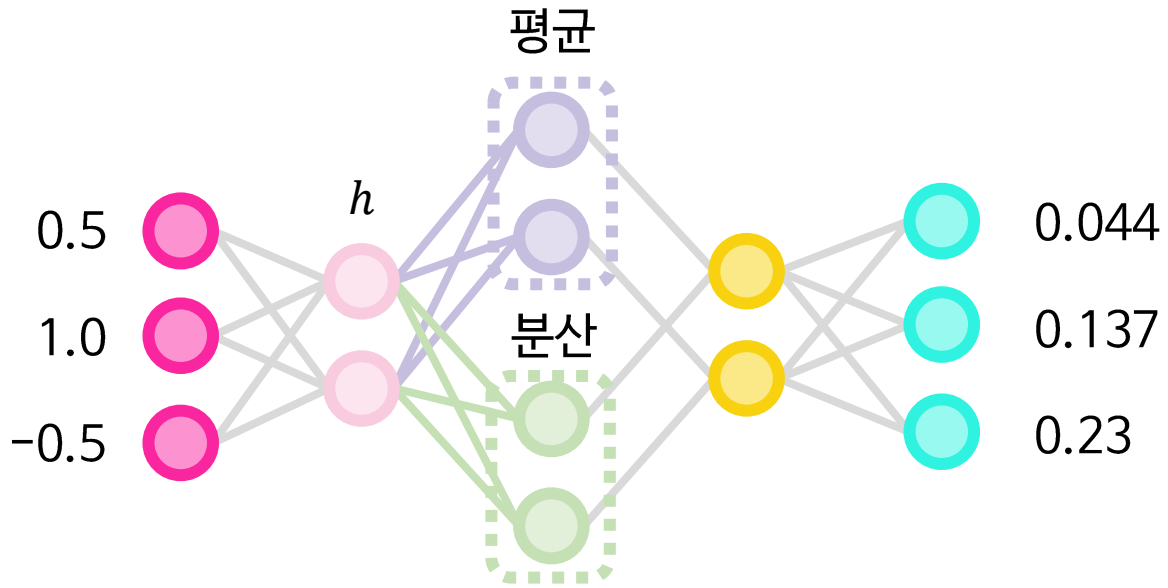

$$\text{재구성손실} = (0.5 - 0.044)^2 + (1.0 - 0.137)^2 + (-0.5 - 0.23)^2$$

$$= 0.207936 + 0.744769 + 0.5329$$

$$= 1.485605$$

신박AI

KL Divergence는 다음과 같이 계산됩니다.

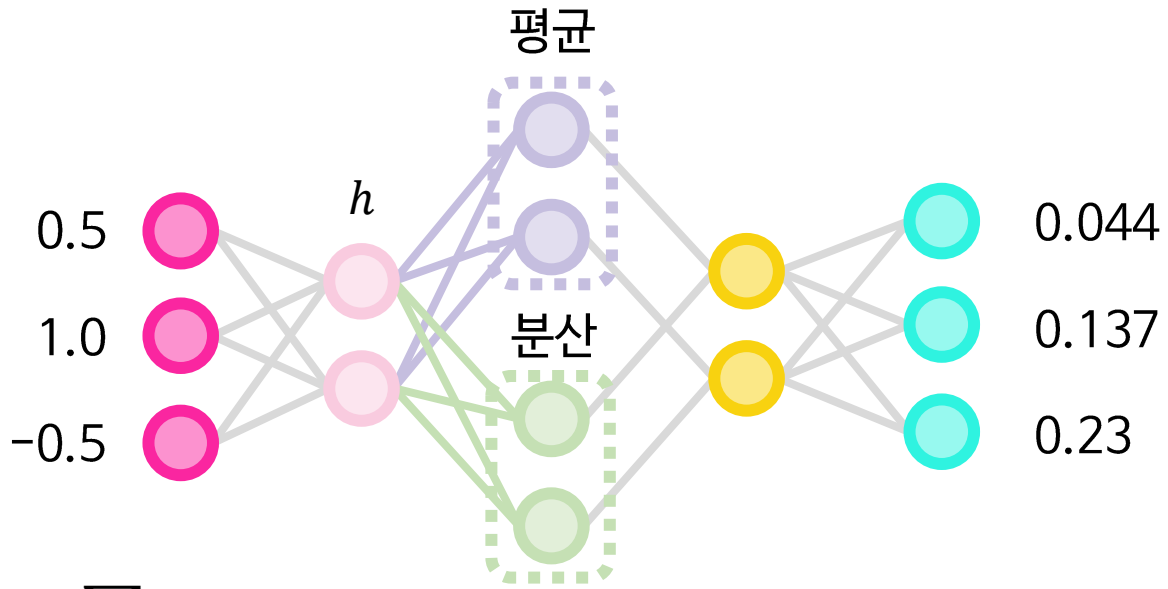

재구성손실 = 1.485605

$$KL\ Divergence = 0.5 \sum (1 + \log(\sigma^2) - \mu^2 - \sigma^2)$$

신박AI

이 KL Divergence 공식은, 잠재변수 z의 분포와 평균이 0인 정규분포와의 차이를 분산과 평균으로 표현한 것입니다.

재구성손실 = 1.485605

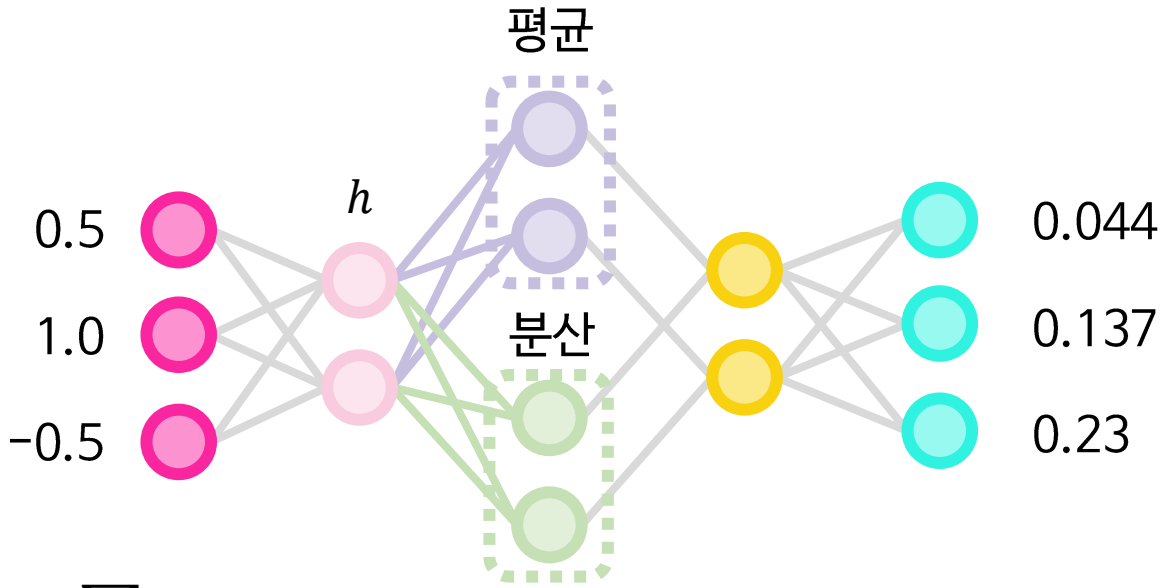

$$KL\ Divergence = 0.5 \sum (1 + \log(\sigma^2) - \mu^2 - \sigma^2)$$

$$D_{KL}(P \parallel Q) = \sum P(x) \log\left(\frac{P(x)}{Q(x)}\right)$$

신박AI

전개과정은 다소 까다롭고 수학적인 부분이라 여기서는 생략하도록 하겠습니다.

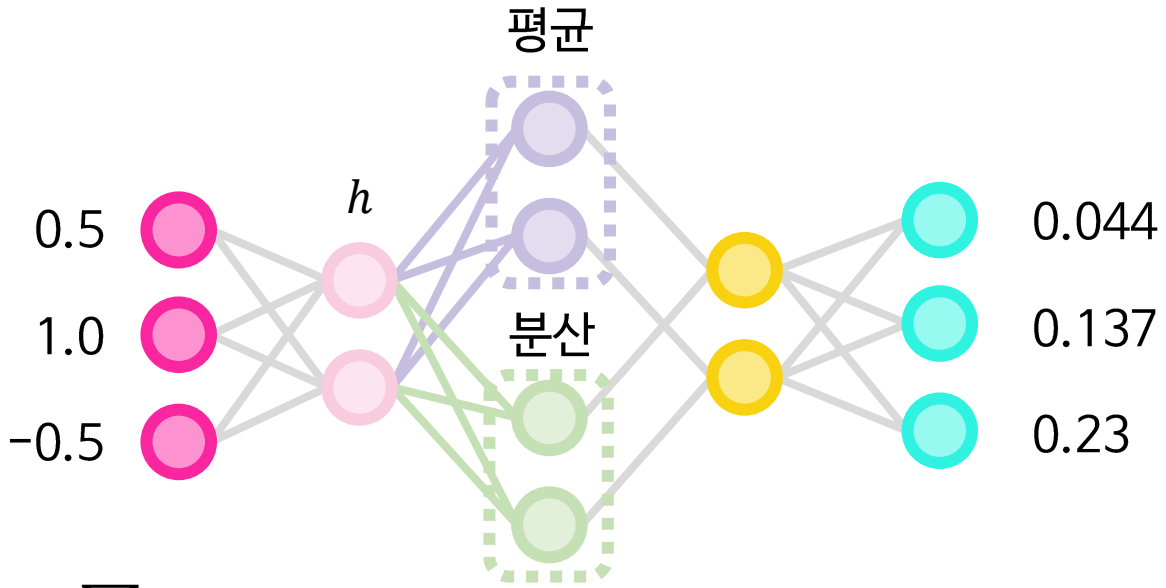

재구성손실 = 1.485605

$$KL\ Divergence = 0.5 \sum (1 + \log(\sigma^2) - \mu^2 - \sigma^2)$$

$$D_{KL}(P \parallel Q) = \sum P(x) \log\left(\frac{P(x)}{Q(x)}\right)$$

신박AI

그래서 KL Divergence는 다음과 같이 계산됩니다.

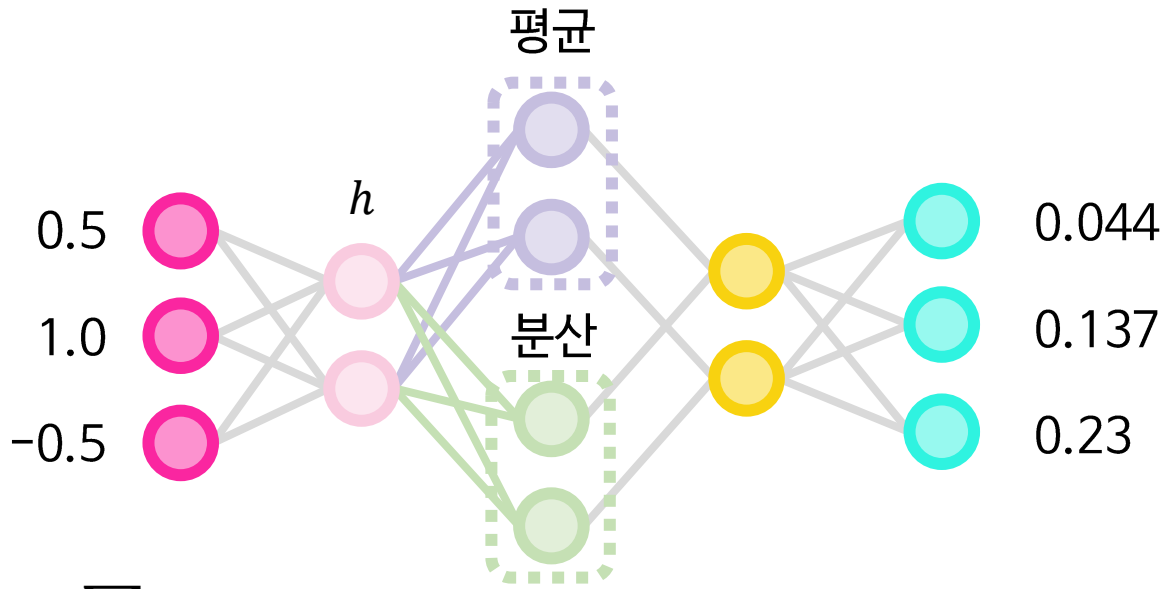

재구성손실 = 1.485605

$$KL\ Divergence = 0.5\sum(1 + \log(\sigma^2) - \mu^2 - \sigma^2)$$

$$= 0.5[(1 + (-0.02) - (-0.04)^2 - 0.99^2) + (1 + 0.04 - 0.02^2 - 1.02^2)]$$

$$= 0.5[(1 - 0.02 - 0.0016 - 0.9801) + (1 + 0.04 - 0.0004 - 1.0404)]$$

$$= 0.5[0.9964 - 0.9817 + 1.0396 - 1.0408]$$

$$= 0.5[0.0147 - 0.0012]$$

$$= 0.5 \times 0.0135 = 0.00675$$

신박AI

따라서 총손실은 재구성 손실과 KL divergence를 합한 값입니다:

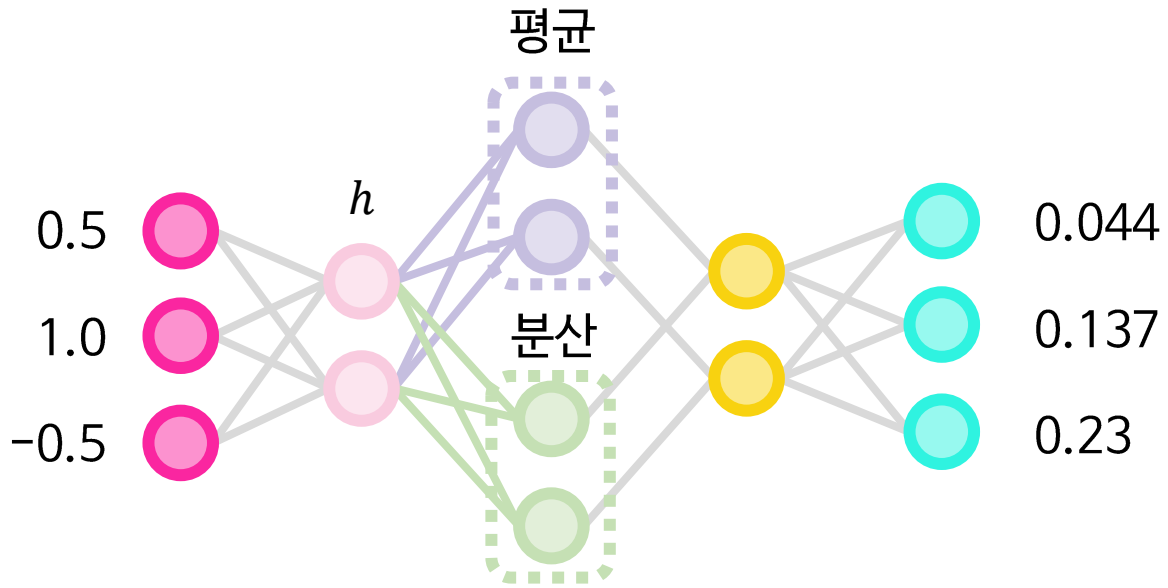

재구성손실 $= 1.485605$

$KL\ Divergence = 0.00675$

$$\text{총 손실} = 1.485605 + 0.00675 = 1.492355$$

신박AI

이 총손실값을 바탕으로, 역전파를 통해 각 가중치값들을 수정하고,

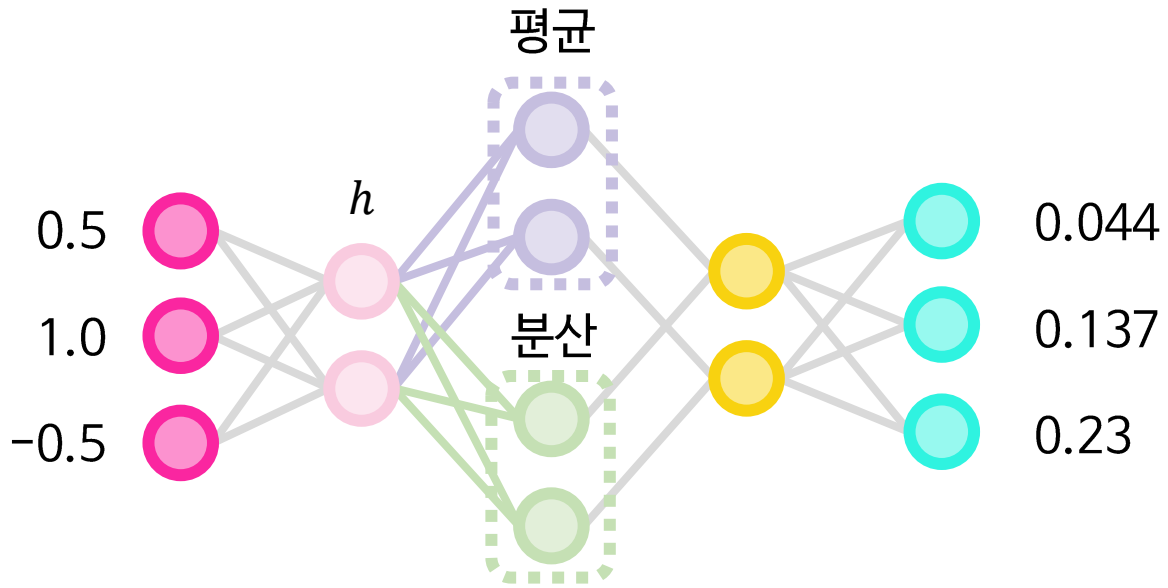

재구성손실 $= 1.485605$

$KL\ Divergence = 0.00675$

$$\text{총 손실} = 1.485605 + 0.00675 = 1.492355$$

신박AI

이 VAE가 수렴할 때까지 같은 과정을 반복하면 되겠습니다.

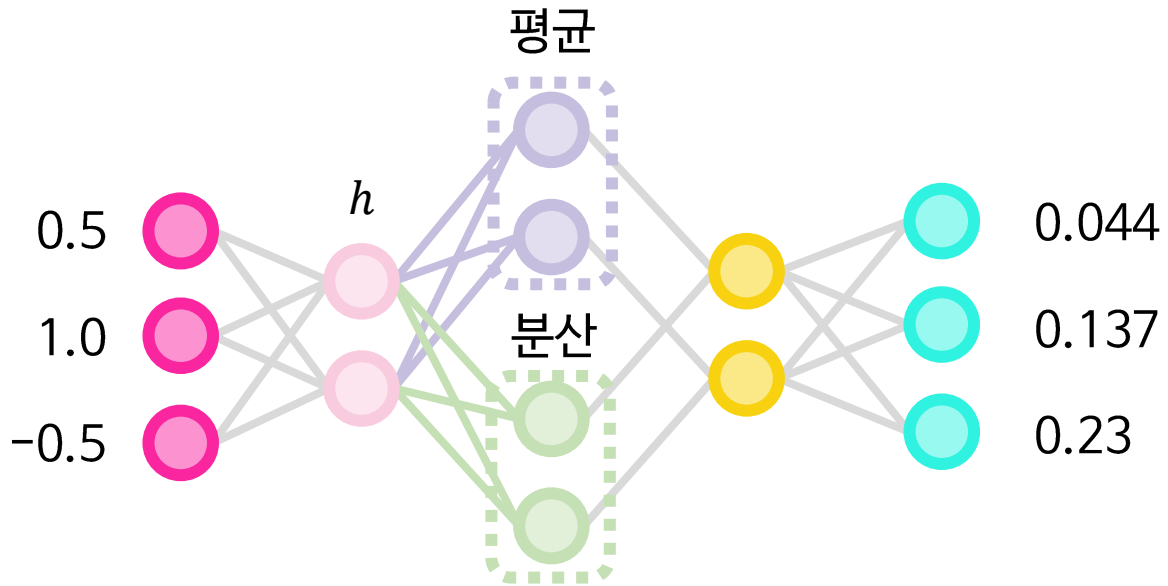

재구성손실 $= 1.485605$

$KL\ Divergence = 0.00675$

$$\text{총 손실} = 1.485605 + 0.00675 = 1.492355$$

신박AI

오늘 제가 준비한 VAE 영상은
여기까지 입니다.

신박AI

제가 생각하는 변분 오토인코더,
VAE의 가장 중요한 부분은

그저 블랙박스로만 여겨졌던 신경망
내부의 잠재공간을 조절할 수 있다는
가능성을 열어준 모델로서,

추후 언어모델과 합하여 오늘날
Stable Diffusion과 같은 모델도
가능하게 한 데에 의의가 있다고 할 수
있겠습니다.

영상 끝까지 시청해 주셔서 감사합니다.
그럼 다음 시간에 또 만나요!

신박AI

감사합니다!

좋은 하루 되세요!!

이 채널은 여러분의 관심과 사랑이 필요합니다

신박AI

‘좋아요’와 ‘구독’버튼은 강의 준비에 큰 힘이 됩니다!

신박AI

그리고 영상 자료를 사용하실때는
출처 '신박AI'를 밝혀주세요

신박AI

신박AI