


Deep Learning 101

L1, L2 Regularization

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$



안녕하세요 여러분! 신박AI입니다




오늘은 딥러닝의 중요한 개념 중 하나인
'regularization'에 대해 알아보겠습니다.


보통 우리는 regularization을 정규화로 번역하지만,

regularization  정규화

이 뿐만 아니라, normalization이나 standardization도 정규화로 번역이 되기 때문에,




이 영상에서는 정규화라는 단어보다는 regularization이라는 표현을 쓰도록 하겠습니다.



Regularization란, 간단히 말해서 딥러닝 모델이 ‘과적합overfitting’을 피하도록 돕는 방법입니다


과적합이란, 예를들어 어떤 학생은 모의고사에 나오는 문제 유형에만
너무 깊이 학습한 나머지,




실제 수능에서 나오는 새로운 유형의 문제를 잘 풀지 못하는 경향이 있을 수 있습니다.




이와 같이 과적합은 딥러닝 모델이 학습 데이터에 너무 정확하게 맞춰져
있어서,




새로운 데이터에 대한 예측 성능이 오히려 떨어지는 현상을 말합니다.




이러한 과적합의 특징과 원인으로서는,



이러한 과적합의 특징과 원인으로서는,



이러한 과적합의 특징과 원인으로서는,



이런 과적합 문제를 해결하기 위해 다음과 같은 방안이 있을 수 있는데요,

데이터 증가: 더 많은 훈련 데이터를 사용하면 모델이 더 일반화된 패턴을 학습하는 데 도움이 됩니다.

모델 복잡도 줄이기: 더 단순한 모델을 사용하거나, 모델의 파라미터 수를 줄이는 것이 과적합을 방지하는 데 도움이 될 수 있습니다.

Regularization 기법 사용: L1, L2 정규화와 같은 기법을 사용하여 모델이 훈련 데이터에 과적합되는 것을 방지합니다.

교차 검증(Cross-validation): 데이터를 여러 부분집합으로 나누고, 이 중 일부를 훈련에, 나머지를 검증에 사용하여 모델의 일반화 능력을 평가합니다.

조기 종료(Early Stopping): 훈련 과정에서 검증 세트의 성능이 더 이상 개선되지 않을 때 훈련을 조기에 중단합니다.

오늘은 이 중, Regularization 기법에 대해 소개해 드리고자 합니다

데이터 증가: 더 많은 훈련 데이터를 사용하면 모델이 더 일반화된 패턴을 학습하는 데 도움이 됩니다.

모델 복잡도 줄이기: 더 단순한 모델을 사용하거나, 모델의 파라미터 수를 줄이는 것이 과적합을 방지하는 데 도움이 될 수 있습니다.


Regularization 기법 사용: L1, L2 정규화와 같은 기법을 사용하여 모델이 훈련 데이터에 과적합되는 것을 방지합니다.

교차 검증(Cross-validation): 데이터를 여러 부분집합으로 나누고, 이 중 일부를 훈련에, 나머지를 검증에 사용하여 모델의 일반화 능력을 평가합니다.


조기 종료(Early Stopping): 훈련 과정에서 검증 세트의 성능이 더 이상 개선되지 않을 때 훈련을 조기에 중단합니다.

우선 Regularization의 개념을 살펴보겠습니다.


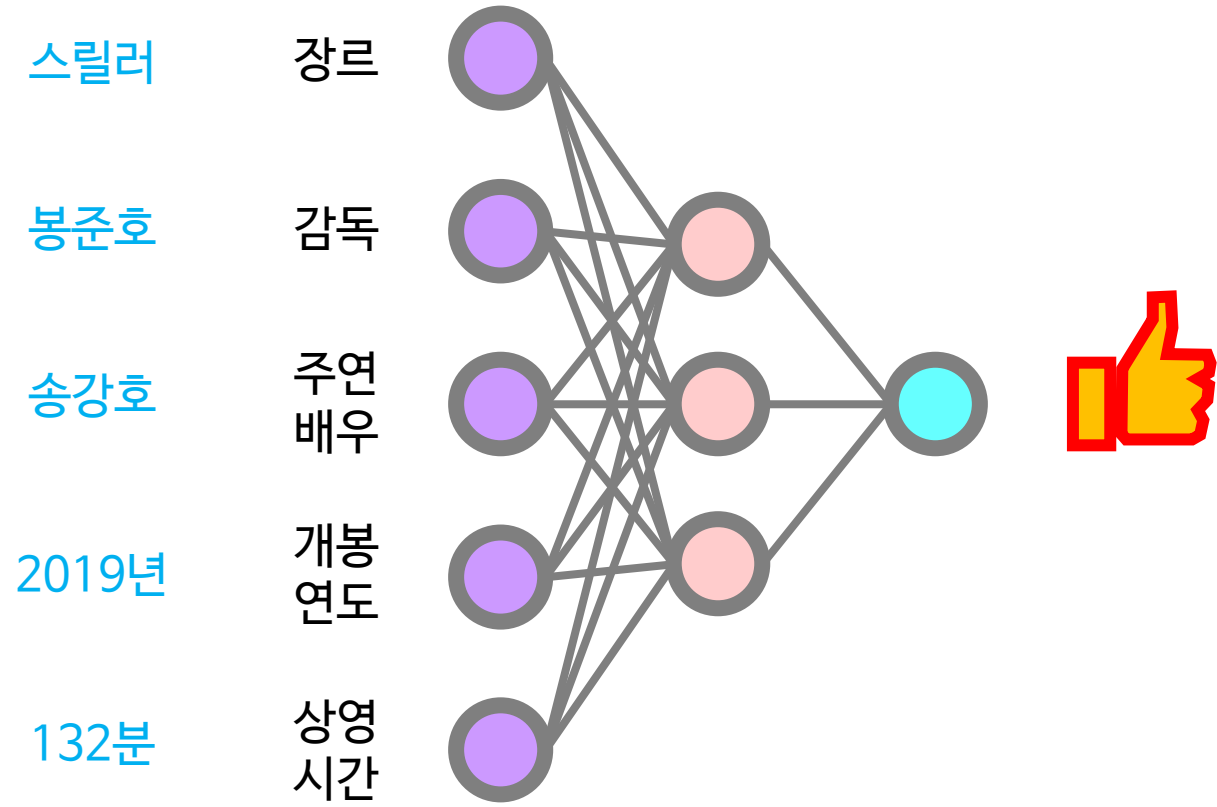
전체 개념을 살펴보기 위해 영화를 추천하는 시스템을 가정해보겠습니다




영화 추천 시스템은 사용자의 취향과 관심사에 맞는 영화를 자동으로 추천해주는 모델입니다.



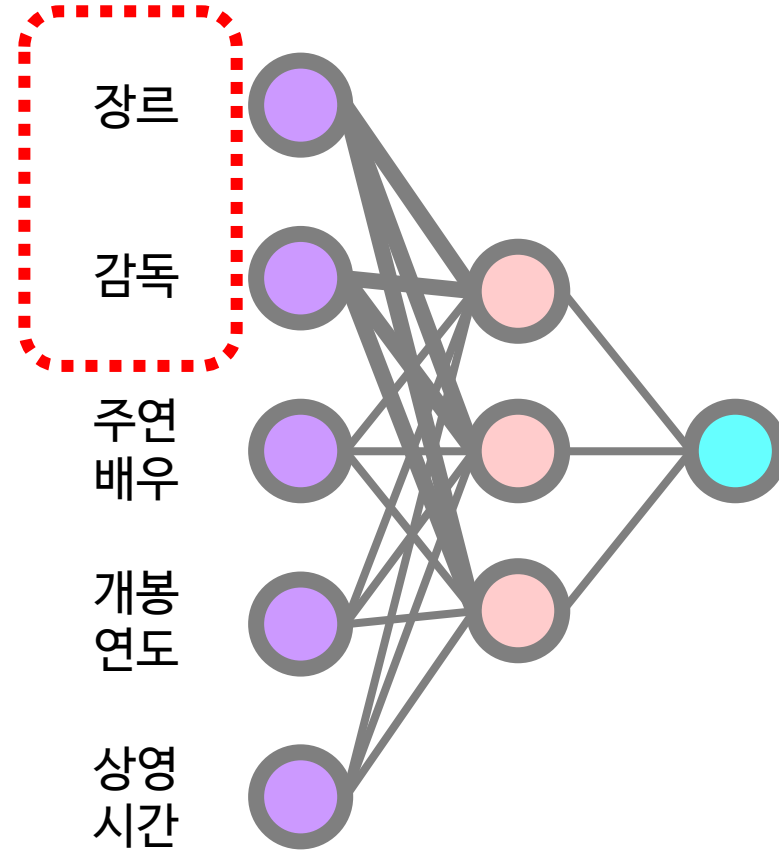
다음과 같이 5개의 특성 (feature)을 입력으로 받아서 평점이 높으면 추천하는 시스템이라고 가정해봅시다.



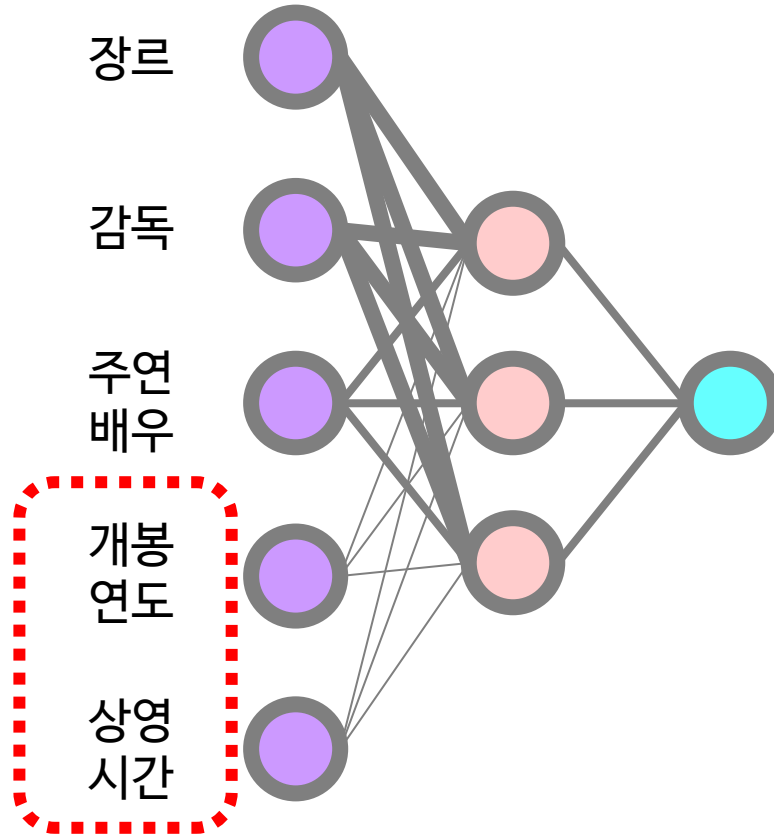
그런데 모든 특성이 사용자의 선택에 중요한 것은 아닐 수 있습니다.




예를들면, 이 사용자에게 있어서 장르나 감독은 중요한 요인이 될 수 있지만,




개봉연도나 상영시간은 크게 고려하지 않을 수도 있습니다




물론 모든 특성을 다 고려한다면, 주어진 학습 데이터에서는 가장 정확한 예측력을 보일 수는 있지만,



딥러닝 모델의 강력한 학습능력 때문에, 오히려 주어진 데이터 내의 불필요한 정보까지 학습이 되는 경우로 인해,

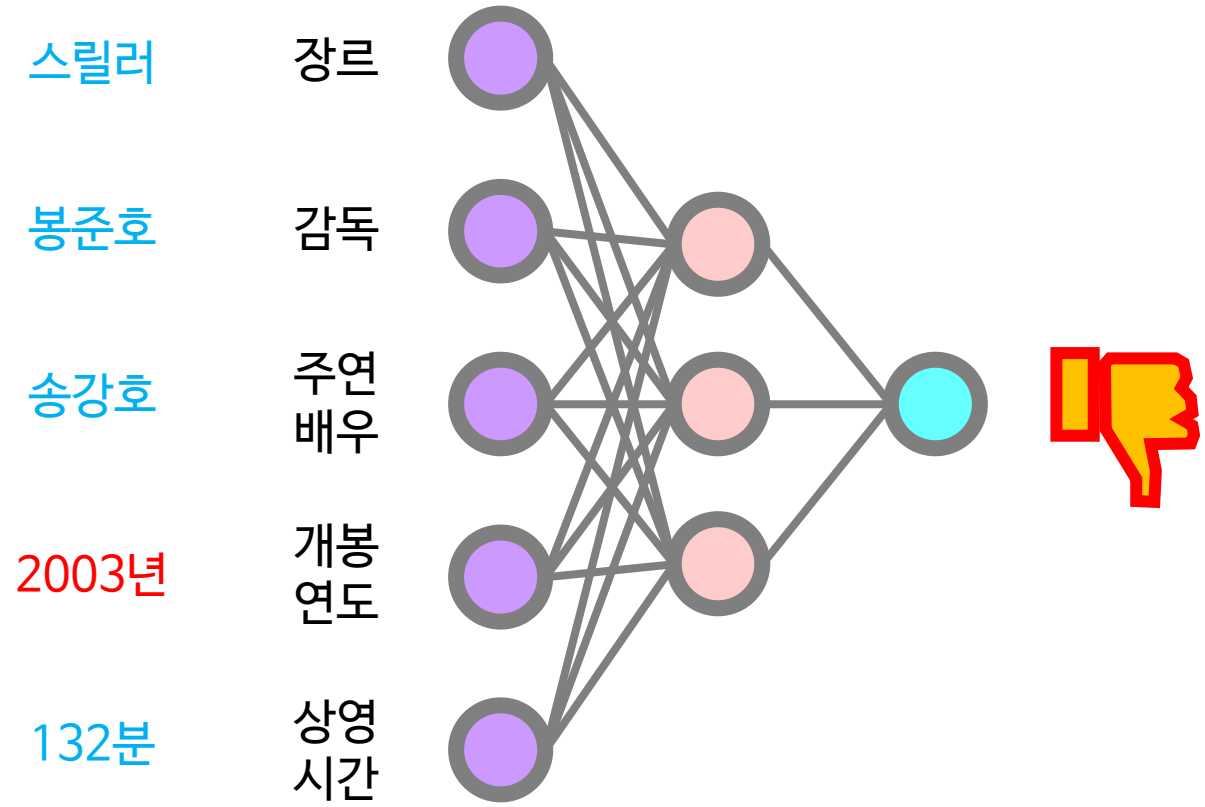


실제 환경에서는 오히려 예측력이 떨어지는 아이러니한 경우도 생기게 됩니다.

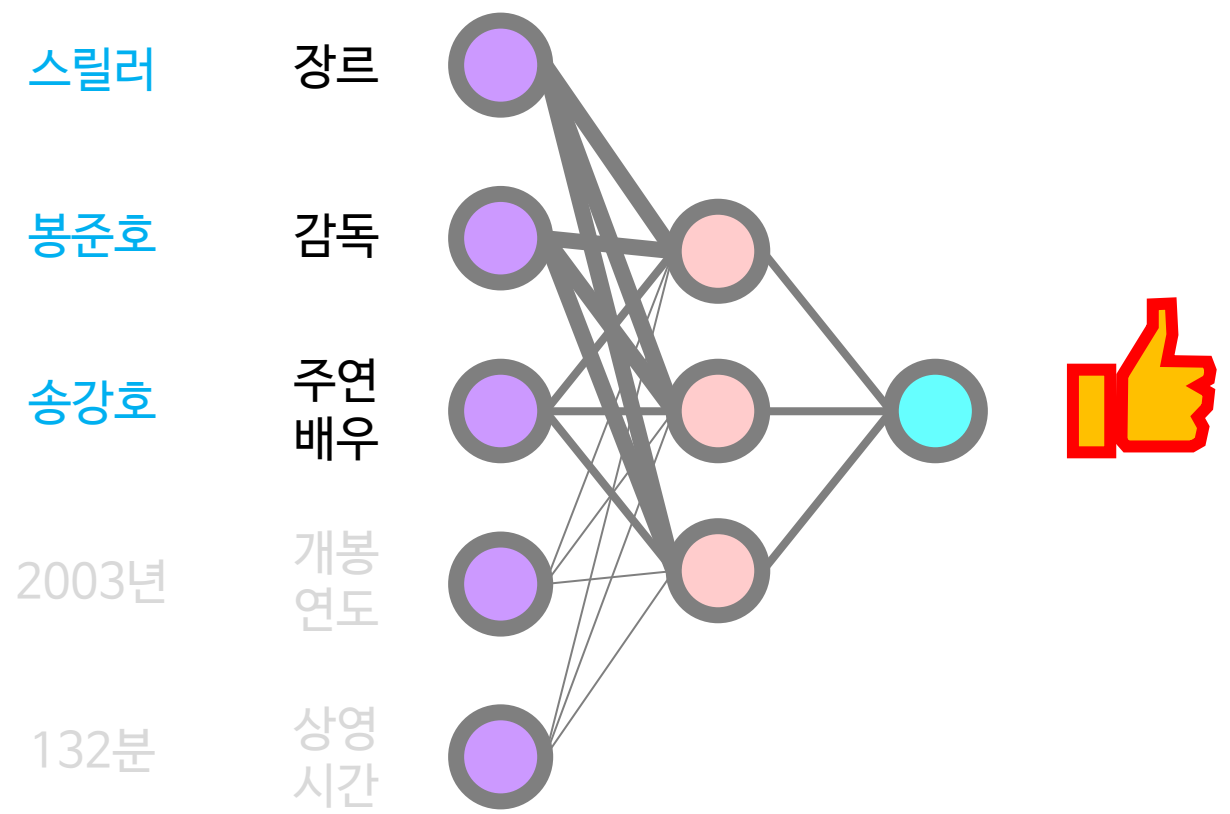


이것이 바로 overfitting의 문제이지요.


여기서 Regularization 이 중요한 역할을 합니다.




Regularization은 모델이 학습하는 동안 중요하지 않은 특성의 영향을 줄이거나 제거하는 기법입니다.




쉽게 말해, 영화 추천 시스템에서 '정말 중요한 특성'만을 골라내는 것이죠.



정규화의 작동 원리는 다음과 같습니다




예를들어 다음과 같은 모델을 학습 시킬 경우,




손실함수를 MSE (Mean Squared Error)를 사용할 수 있습니다

Loss: MSE




그런데, 과적합의 문제는 모델이 주어진 데이터를 너무 과도하게 학습할 때 발생하는 문제이기 때문에,

Loss: MSE




모델이 학습을 너무 잘 하지 않도록 적당히 방해하도록 하겠습니다.

Loss: MSE




방해하는 방법은 손실함수에 페널티를 더하는 방식으로,

Loss: MSE




이렇게 손실함수에 regularization 항을 더하는 방식으로 휘방을
놓습니다

$$Loss: MSE + \textit{regularization term}$$




이렇게 하면 손실이 더 커져서 학습에 방해가 될 것 같지만,

$Loss: MSE + regularization\ term$




신기하게도 불필요한 가중치는 감소하고 필요한 가중치는 더 부각이 되어,

$Loss: MSE + \text{regularization term}$




전체적인 모델의 성능이 개선되는 효과를 가져오는 것이 regularization의 효과입니다.

$Loss: MSE + \text{regularization term}$




L1 regularization은 regularization 항이 다음과 같습니다



Loss: MSE + regularization term

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$


공식만 보서는 어려워 보이지만 사실 하나도 어려운 것이 아닙니다.



Loss: MSE + regularization term

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

간단하게 말하면 결국 모든 가중치들의 절대값들의 합을 regularization 항으로 사용한다는 뜻입니다




$Loss: MSE + regularization\ term$

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda(|w_1| + |w_2| + \cdots + |w_{n-1}| + |w_n|)$$

여기 λ 값은 regularization의 정도를 조절해주는 상수값 정도로 보시면 됩니다.




Loss: MSE + regularization term

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda (|w_1| + |w_2| + \cdots + |w_{n-1}| + |w_n|)$$

그러면 모든 가중치들의 절대값들의 합을 더하는 것이 어떻게 과적합을 방지하고 모델의 성능을 개선할 수 있는 말일까요?




$Loss: MSE + \text{regularization term}$

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda(|w_1| + |w_2| + \dots + |w_{n-1}| + |w_n|)$$

구체적인 수학적식을 들여다 보기 전에 직관적인 아이디어를 가져보았으면 합니다.




Loss: $MSE + regularization\ term$

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda(|w_1| + |w_2| + \cdots + |w_{n-1}| + |w_n|)$$

손실함수라는 것은 결국 손실이 최소가 되는 것이 학습의 목표입니다.

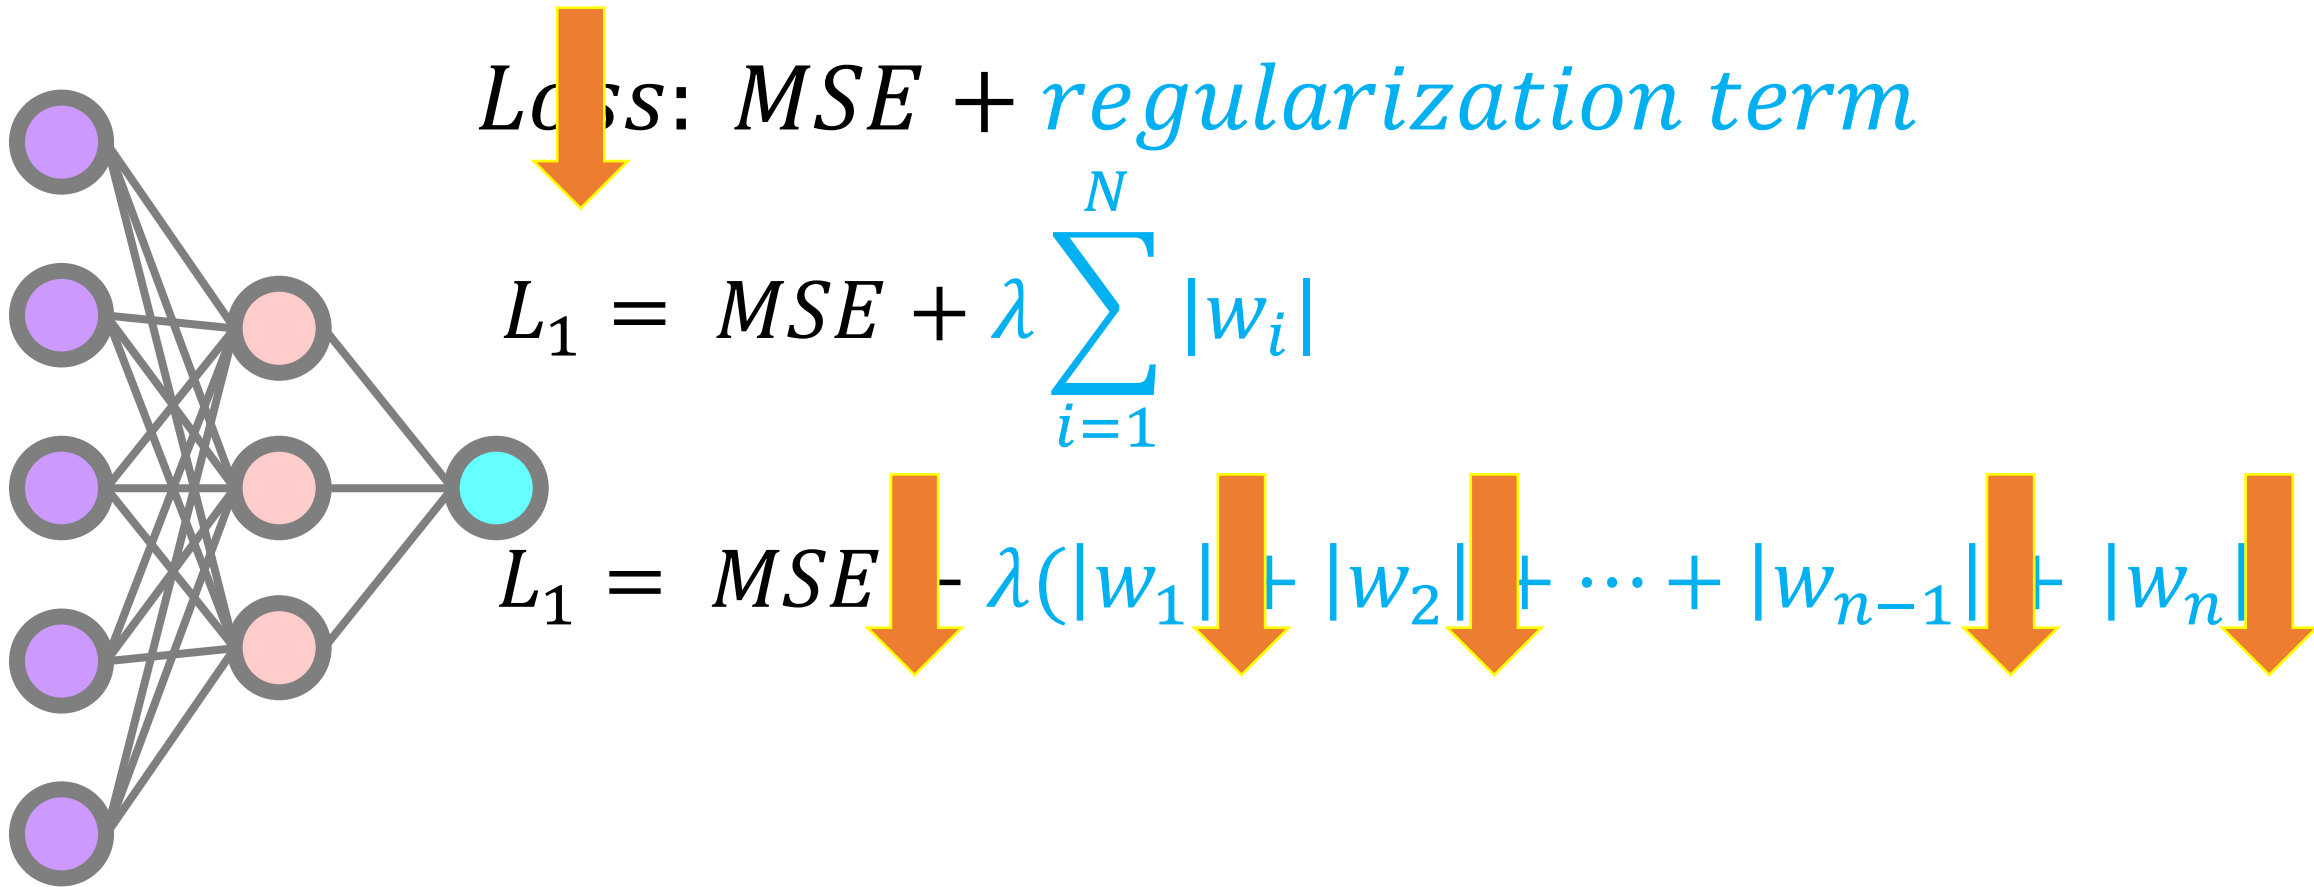


↓
 $Loss: MSE + regularization\ term$

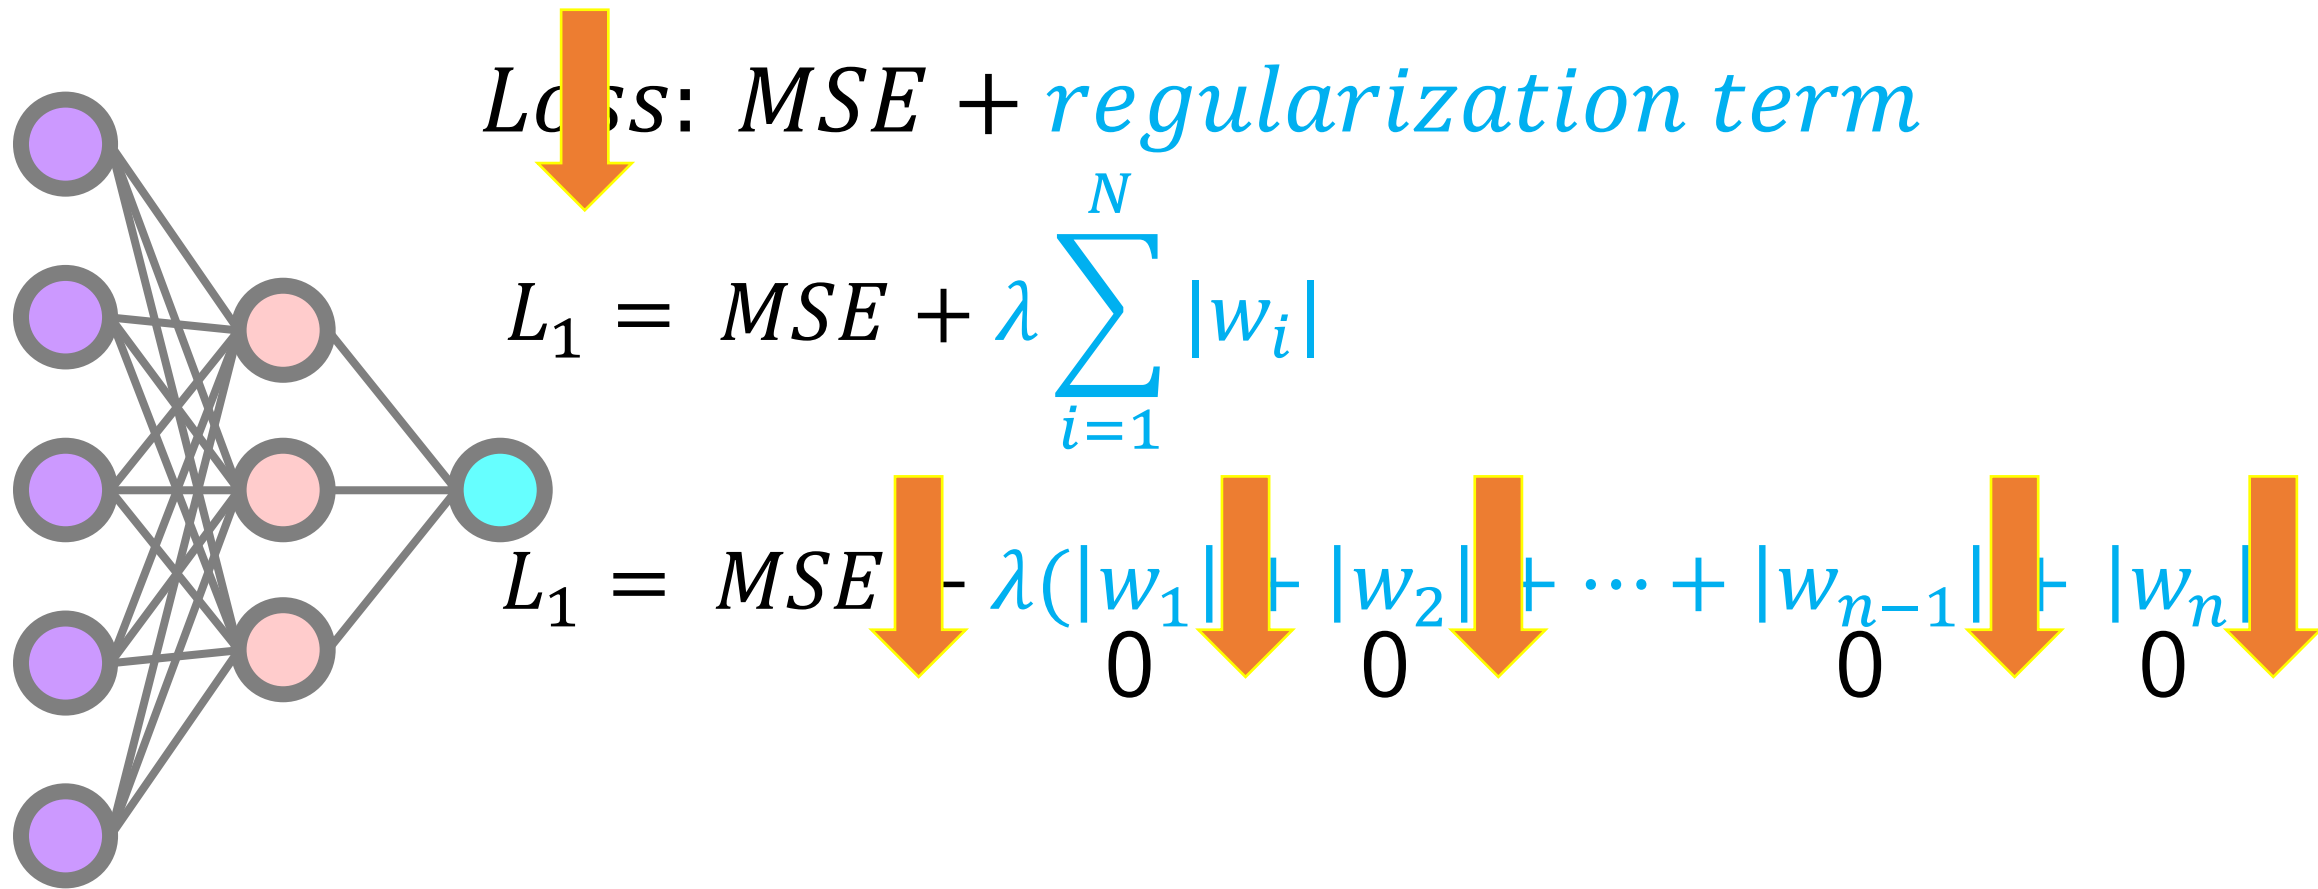
$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda(|w_1| + |w_2| + \cdots + |w_{n-1}| + |w_n|)$$

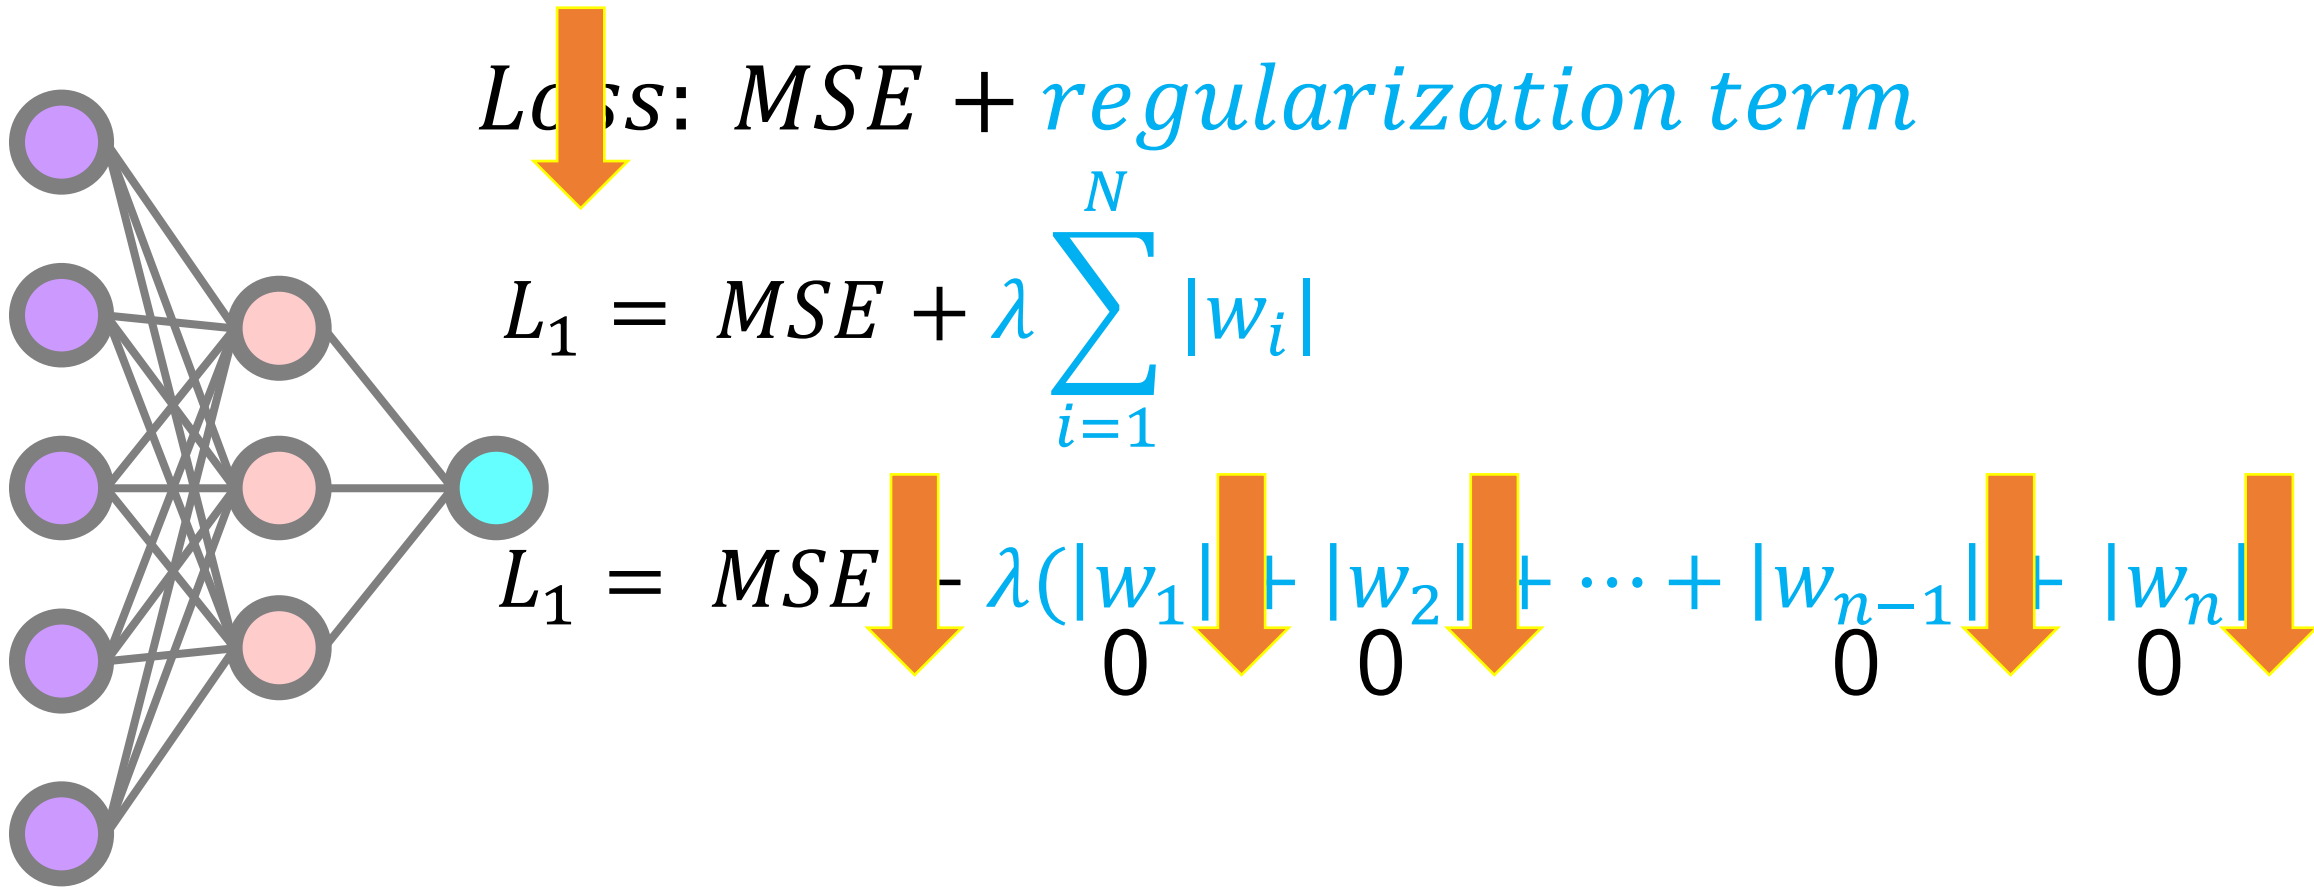
그러므로 결국 모든 항들이 다 최소가 되면 손실이 최소가 될 것 같은데요



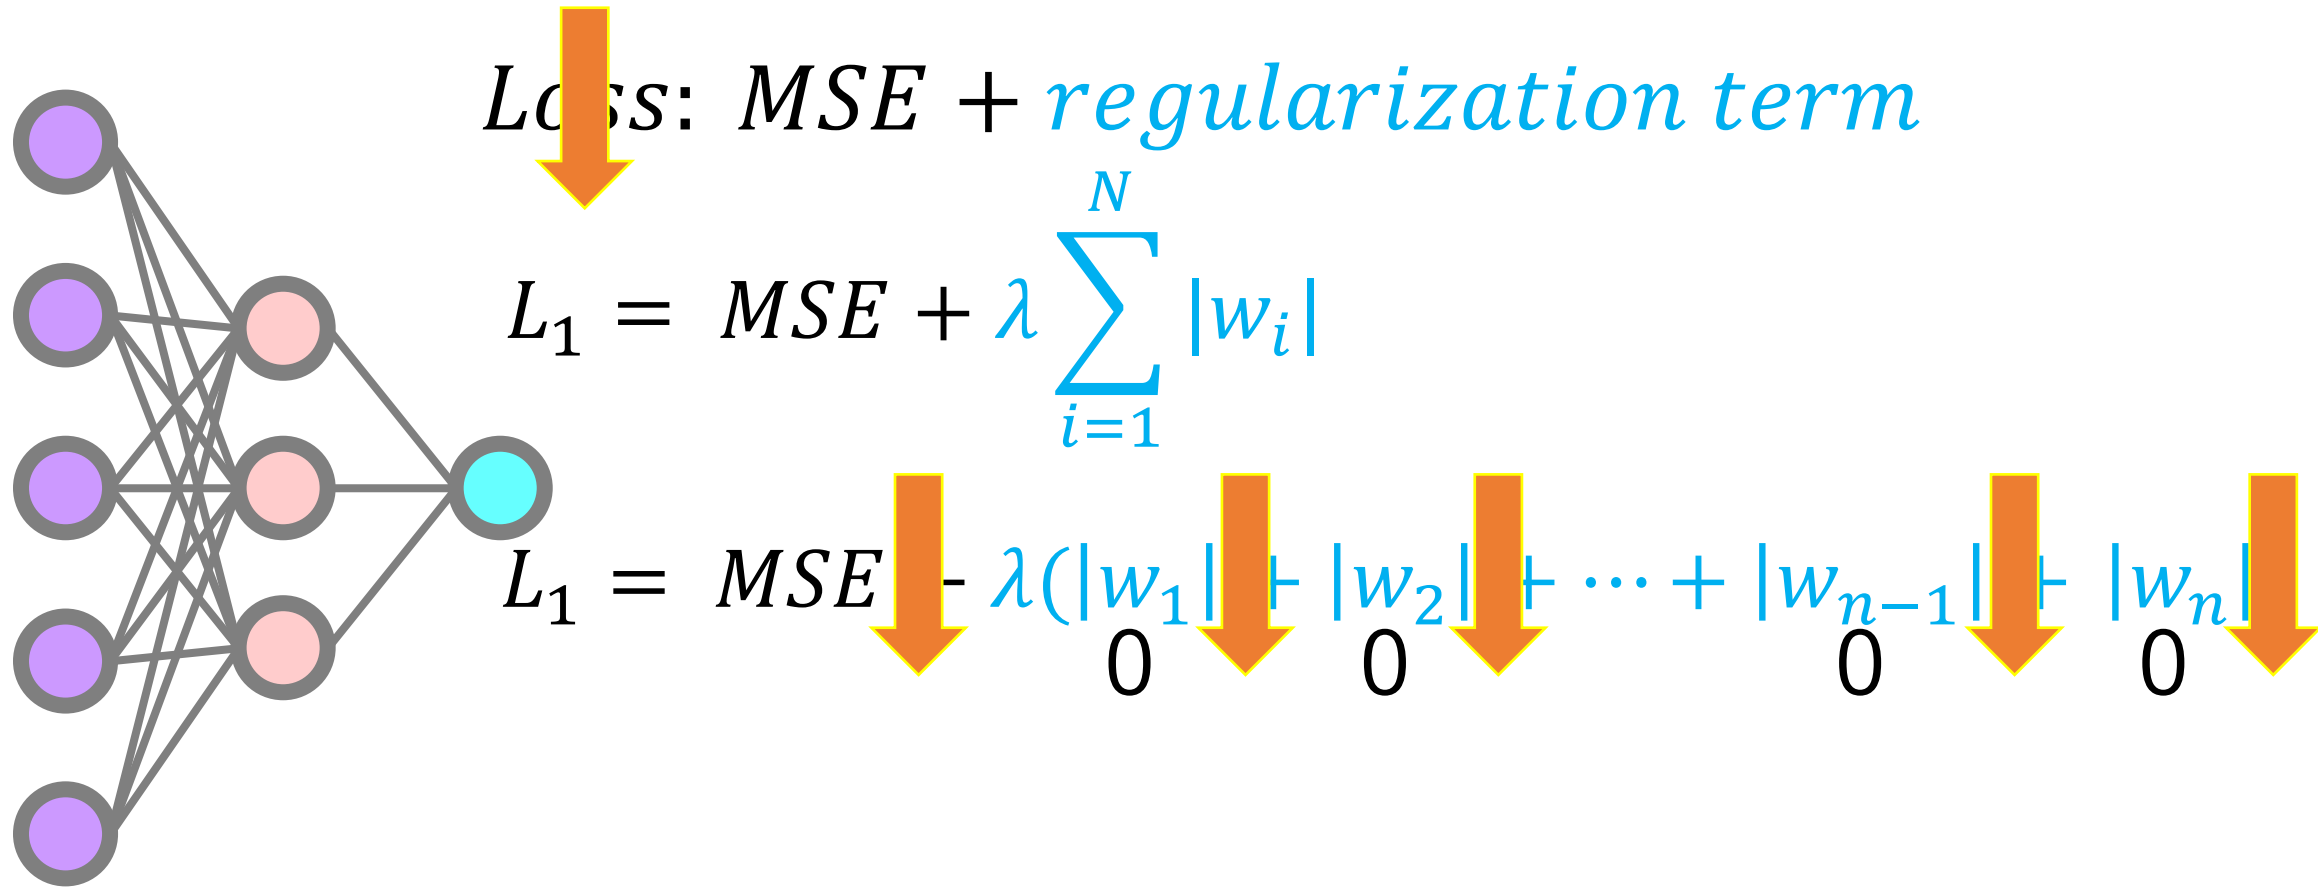
그러면 가중치들이 다 0로 수렴하게 되면 손실이 최소가 된다는 뜻일까요?



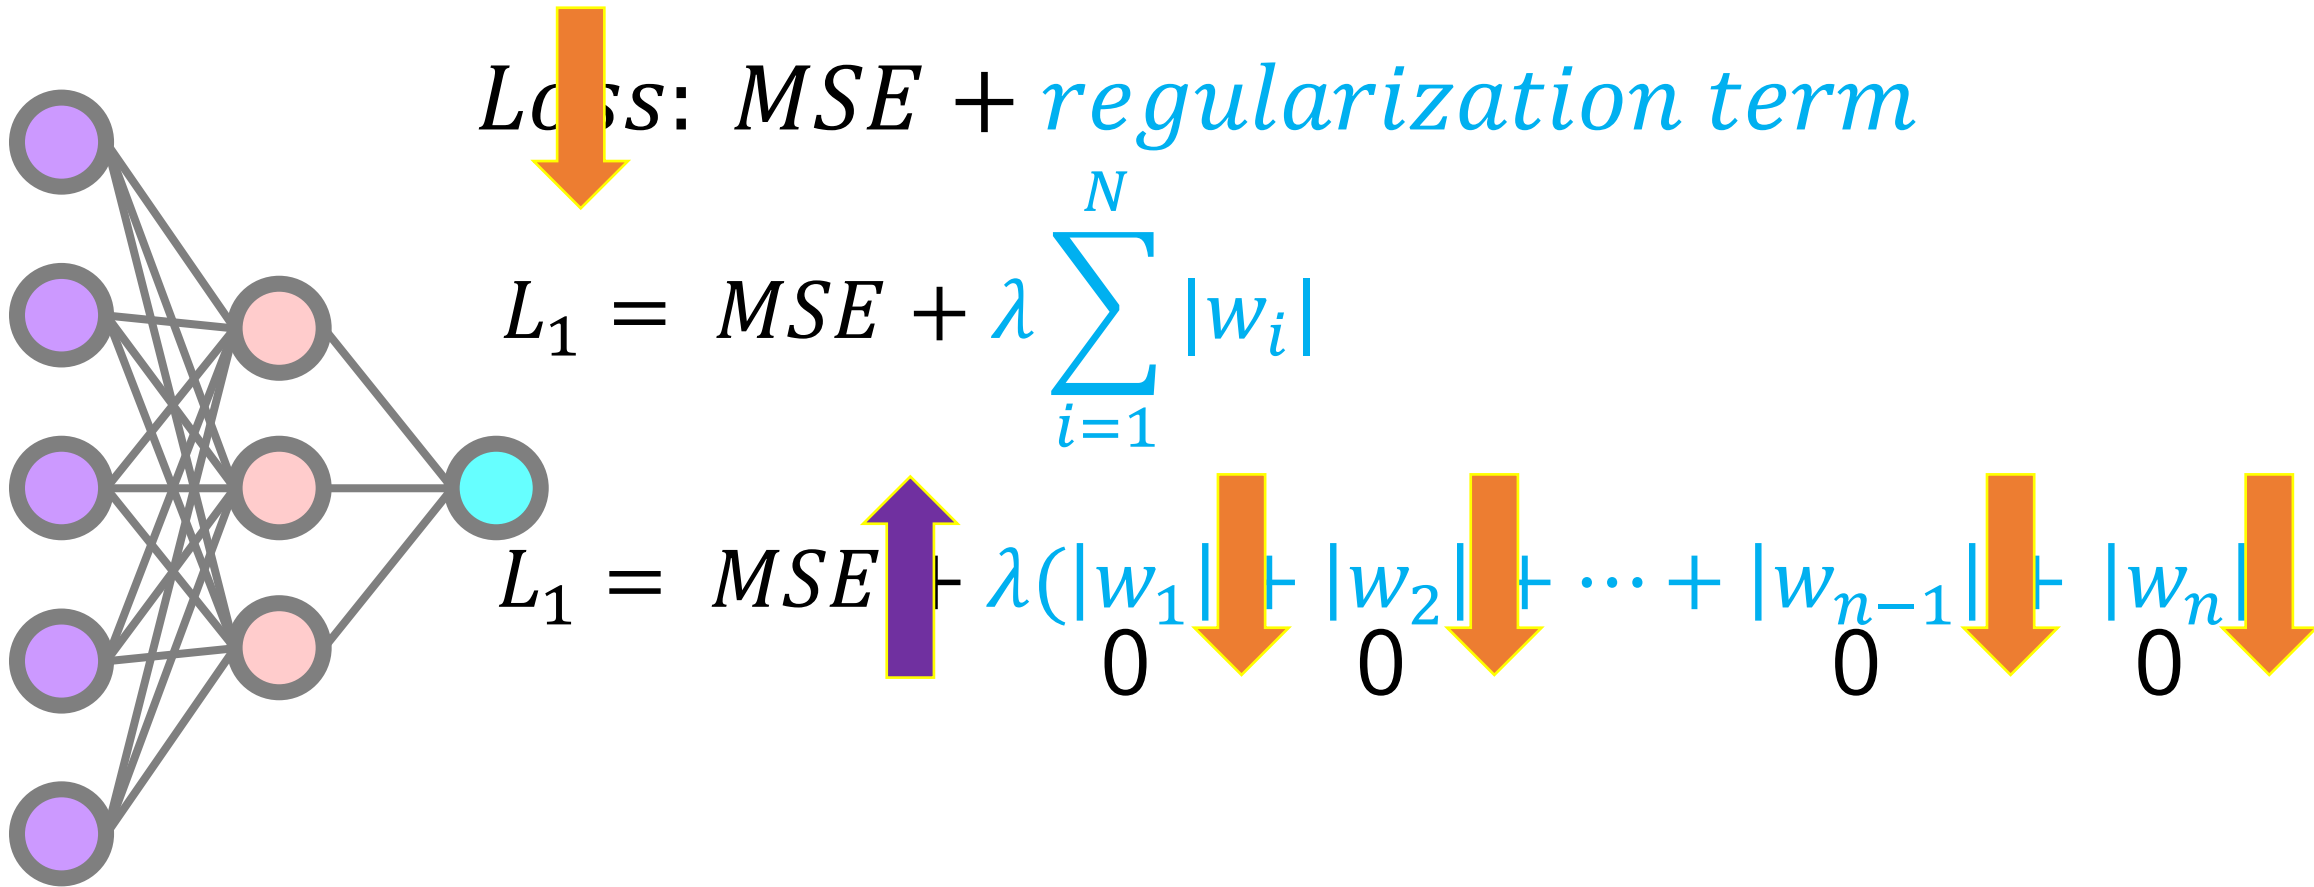
그렇지 않습니다.




이렇게 가중치들이 무작정 다 0으로 되어 버리면, 신경망 아웃풋은 0이 되어,



오히려 MSE 손실은 증가할 수도 있습니다.



그러므로, 가중치 절대값 합을 줄여 나가되,

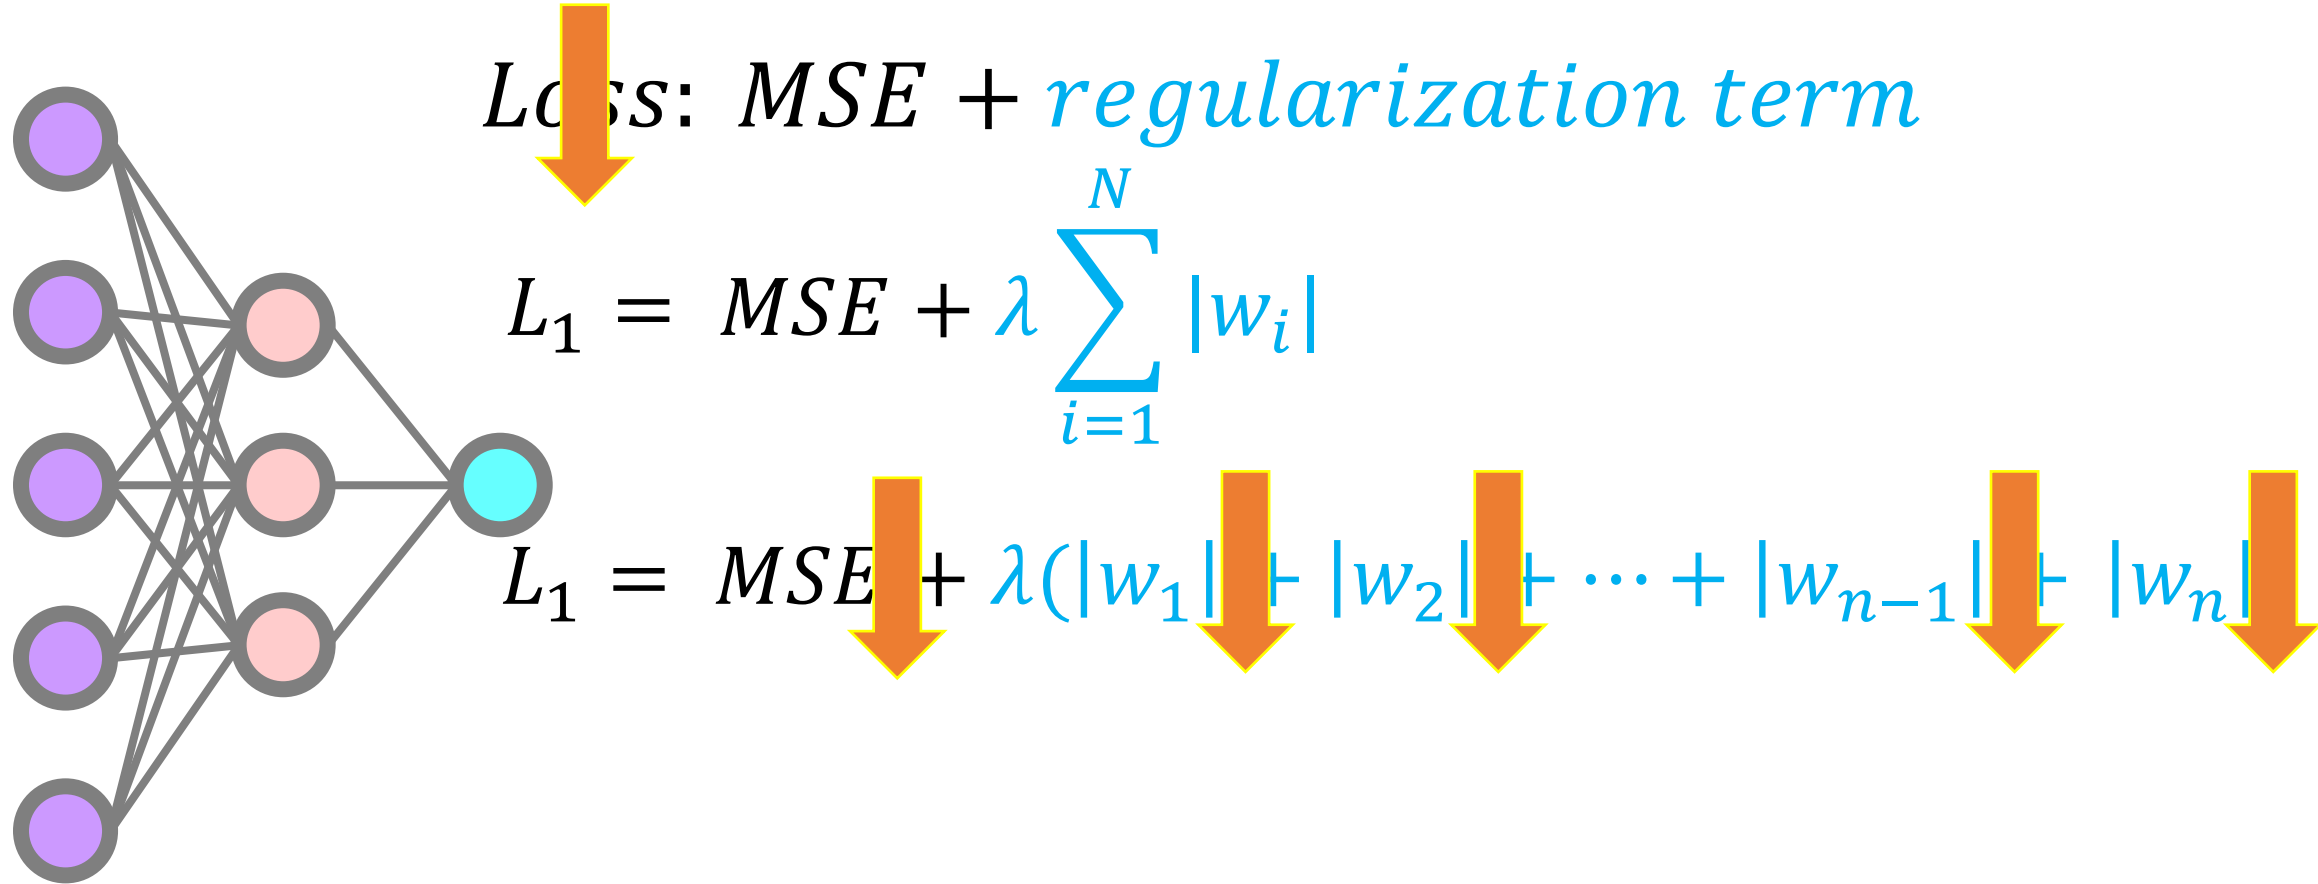


↓
 $Loss: MSE + regularization\ term$


$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda (|w_1| \downarrow + |w_2| \downarrow + \cdots + |w_{n-1}| \downarrow + |w_n| \downarrow)$$

MSE 손실도 최소가 되는 그 밸런스가 되는 가중치들을 찾아가는 것이 regularization의 과정이라 할 수 있습니다.



자 그러면 이제 수식을 통해 L1 regularization이 과정을 살펴보겠습니다.




$Loss: MSE + regularization\ term$

$$L_1 = MSE + \lambda \sum_{i=1}^N |w_i|$$

$$L_1 = MSE + \lambda(|w_1| + |w_2| + \dots + |w_{n-1}| + |w_n|)$$


자 그러면 이제 수식을 통해 L1 regularization이 과정을 살펴보겠습니다.



$$L_1 = MSE + \lambda(|w_1| + |w_2| + \cdots + |w_{n-1}| + |w_n|)$$


설명을 간단히 하기 위해 1차 함수 형태의 선형 학습 모델을 가정해봅시다

$$\hat{y} = w \cdot x + b$$



$$L_1 = MSE + \lambda(|w_1| + |w_2| + \cdots + |w_{n-1}| + |w_n|)$$


그러면 L1 은 다음과 같이 바꿀 수 있습니다




그리고 MSE는 $(\hat{y} - y)^2$ 이기 때문에,

$$\hat{y} = w \cdot x + b$$

$$L_1 = MSE + \lambda |w|$$




이렇게 전개할 수 있습니다.



$$\hat{y} = w \cdot x + b$$

$$\begin{aligned} L_1 &= (\hat{y} - y)^2 + \lambda |w| \\ &= (w \cdot x + b - y)^2 + \lambda |w| \end{aligned}$$

자 그리고, 손실함수를 최소로 하기 위한 방법은 역시 경사하강법!입니다




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

그러면 $\partial L_1 / \partial w$ 를 구하기 위해서 다음과 같이 편미분을 하면,



$$\hat{y} = w \cdot x + b$$


$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

결과는 다음과 같이 전개할 수 있습니다.



$$\hat{y} = w \cdot x + b$$


$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

여기서 $|w|$ 의 함수 그래프는 아래와 같기 때문에,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$


$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$



$|w|$ 의 함수의 미분 그래프는 또한 다음과 같습니다




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$


$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$



그리하여 $\partial L_1 / \partial w$ 를 정리하면 다음과 같이 됩니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$


$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) \begin{matrix} +\lambda \ (w \geq 0) \\ -\lambda \ (w < 0) \end{matrix}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$



복잡한 $2x(w \cdot x + b - y)$ 부분을 대문자 A로 치환하면,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$


$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$



결국 새로운 가중치 w^* 는 다음과 같이 정리할 수 있습니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w - \alpha \cdot \begin{pmatrix} +\lambda \\ -\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

좀 더 직관적으로 이해하기 쉽도록 부호를 안으로 넣도록 하겠습니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} & +\lambda \quad (w \geq 0) \\ & -\lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w - \alpha \cdot \begin{pmatrix} +\lambda \\ -\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

좀 더 직관적으로 이해하기 쉽도록 부호를 안으로 넣도록 하겠습니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

자 그러면, 이 식을 다음과 같이 해석할 수 있습니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

가중치가 양수일 경우,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \left(A^{-\lambda}_{+\lambda} \right) \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

새로운 가중치 w^* 는,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$\boxed{w^*} = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{aligned} &(w \geq 0) \\ &(w < 0) \end{aligned}$$

λ 에 비례하여 작아지게 되고,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \left(A \begin{matrix} -\lambda \\ +\lambda \end{matrix} \right) \begin{aligned} &(w \geq 0) \\ &(w < 0) \end{aligned}$$

마찬가지로, 가중치가 음수일 경우,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{pmatrix} (w \geq 0) \\ (w < 0) \end{pmatrix}$$

새로운 가중치 w^* 는,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$\boxed{w^*} = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

λ 의 비례하여 커지게 됩니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot (A \overset{-\lambda}{\underset{+\lambda}{\boxed{}}}) \begin{aligned} &(w \geq 0) \\ &(w < 0) \end{aligned}$$

이런 식으로 양의 가중치는 값을 줄이고, 음의 가중치는 값을 키우면,




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} & +\lambda \quad (w \geq 0) \\ & -\lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

학습이 지속될 수록, 가중치들은 0에 아주 가깝게 근접하려는 압력을 받게 됩니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$


$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$


그러면 처음부터 값이 작았던 가중치들은,




일정한 크기만큼 사라지게 되면,




일정한 크기만큼 사라지게 되면,




일정한 크기만큼 사라지게 되면,



일정한 크기만큼 사라지게 되면,




이와 같이 0에 거의 근접하는 가중치들이 나오기 시작하며,




이런 과정들을 통해서 아웃풋에 영향을 끼치지 않는 작은 가중치들을 제거해가는 과정이 학습중에 발생하게 됩니다.

아까 본 것 처럼, 장르나 감독은 남기고, 개봉연도나 상영시간은 없애나가는..



이러한 regularization과정을 L1 regularization이라 부릅니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

자 그러면 L2 regularization은 무엇일까요?



$$\hat{y} = w \cdot x + b$$


$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$


$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$



L1을 이해하셨다면, L2는 크게 어렵지 않습니다.




$$\hat{y} = w \cdot x + b$$

$$L_1 = (\hat{y} - y)^2 + \lambda |w|$$

$$= (w \cdot x + b - y)^2 + \lambda |w|$$

$$\frac{\partial L_1}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{|w|}{\partial w} = 2x(w \cdot x + b - y) + \lambda \frac{|w|}{\partial w}$$




A

$$\begin{aligned} &+ \lambda \quad (w \geq 0) \\ &- \lambda \quad (w < 0) \end{aligned}$$

$$w^* = w - \alpha \cdot \frac{\partial L_1}{\partial w}$$

$$w^* = w + \alpha \cdot \begin{pmatrix} -\lambda \\ +\lambda \end{pmatrix} \begin{matrix} (w \geq 0) \\ (w < 0) \end{matrix}$$

L2는 regularization항이 다음과 같이 바뀝니다.




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$


$$= (w \cdot x + b - y)^2 + \lambda w^2$$

$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$



가중치의 절대값에서 제곱으로 바뀌고,




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$


$$= (w \cdot x + b - y)^2 + \lambda w^2$$

$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$



그래서 미분값이 이렇게 바뀝니다.




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$

$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$



L1의 경우와 마찬가지로 $2x(w \cdot x + b - y)$ 을 A로 치환하면,



$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$


$$= (w \cdot x + b - y)^2 + \lambda w^2$$

$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$



새로운 가중치 w^* 는 다음과 같이 정리할 수 있습니다.



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$



L1의 경우와 마찬가지로,



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$



가중치가 양수인 경우엔,



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$



경사하강법에 있는 음수와 곱해져서




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$

새로운 가중치 w^* 는 크기가 줄어들고,



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$



반대로 가중치가 음수인 경우엔,



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$



경사하강법에 있는 음수와 곱해져서




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$

새로운 가중치 w^* 는 크기가 커지게 됩니다.



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$



그러나 결국 L1과 마찬가지로, 음수인 가중치는 커져서 0에 근접하게 되고,



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$



양수인 가중치는 작아져서 결국 0에 근접하게 됩니다.



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$

$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w}$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$



하지만 L2은 가중치의 크기 w 를 고려하여 변화하기 때문에,




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$

L1에 비해 좀 더 부드러운 regularization이 되는 특성이 있습니다.




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$

왜냐하면, 가중치 w 가 작을 경우에는 작은 페널티를 주고,




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$

가중치 w 가 클 경우에는 큰 페널티를 주기 때문에,




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$

가중치 크기와 상관없이 가중치별로 일정하게 변화를 시키는 L1에 비해




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$

좀더 안정적인 효과가 있을 수 있습니다.



$$\hat{y} = w \cdot x + b$$


$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$

$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$


$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$



하지만 L1 regularization은 불필요한 가중치는 0으로 만들어 버리는
경향성이 있기 때문에


$$\hat{y} = w \cdot x + b$$



$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$


$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$w^* = w - \alpha \cdot (A + 2\lambda w)$$

차원축소 같은 효율적인 모델을 구현하는데 사용되기도 합니다.




$$\hat{y} = w \cdot x + b$$

$$L_2 = (\hat{y} - y)^2 + \lambda w^2$$

$$= (w \cdot x + b - y)^2 + \lambda w^2$$

$$\frac{\partial L_2}{\partial w} = \frac{\partial}{\partial w} [(w \cdot x + b - y)^2] + \lambda \frac{\partial w^2}{\partial w} = 2x(w \cdot x + b - y) + 2\lambda w$$



$$w^* = w - \alpha \cdot \frac{\partial L_2}{\partial w} \dots$$

$$\boxed{w^*} = w - \alpha \cdot (A + 2\lambda w)$$

오늘은 모델의 과적합 문제를 해결하는
여러 방안 중 하나인,

L1, L2 regularization에 대하여
알아보았습니다

Regularization은 학습 과정 중에
모델의 학습에 방해가 되는
페널티 항을 추가함으로

오히려 모델이 과적합 문제를 해결하고
실제 환경에서 더 예측력이 높은 모델이
되어 간다는,

다소 우리의 직관에 반하는
그런 개념이라 할 수 있겠습니다.

하지만, 생각해보면, 공부와 학습환경에만
최적화 되어 있는 독서실보다는

때로는 카페같이 노이즈가 많고
방해자극이 많은 곳에서 오히려
학습능률이 오를 때도 있는 것처럼

방해라고 해서 다 나쁜것만은 아니며,
나에게 도움이 되는 방해도 있을 수 있다는
생각을 하게 됩니다

영상 끝까지 시청해 주셔서 감사합니다.
다음에도 흥미로운 주제로
찾아뵙겠습니다.

그럼 다음 시간에 또 만나요!

감사합니다!

좋은 하루 되세요!!

이 채널은 여러분의 관심과 사랑이 필요합니다


좋아요



댓글



공유



구독



‘좋아요’와 ‘구독’버튼은 강의 준비에 큰 힘이 됩니다!

좋아요



댓글



공유



구독



그리고 영상 자료를 사용하실때는
출처 '신박AI'를 밝혀주세요





Copyright © 2024 by 신박AI

All rights reserved

본 문서(PDF)에 포함된 모든 내용과 자료는 저작권법에 의해 보호받고 있으며, 신박AI에 의해 제작되었습니다.

본 자료는 오직 개인적 학습 목적과 교육 기관 내에서의 교육용으로만 무료로 제공됩니다.

이를 위해, 사용자는 자료 내용의 출처를 명확히 밝히고,

원본 내용을 변경하지 않는 조건 하에 본 자료를 사용할 수 있습니다.

상업적 사용, 수정, 재배포, 또는 이 자료를 기반으로 한 2차적 저작물 생성은 엄격히 금지됩니다.

또한, 본 자료를 다른 유튜브 채널이나 어떠한 온라인 플랫폼에서도 무단으로 사용하는 것은 허용되지 않습니다.

본 자료의 어떠한 부분도 상업적 목적으로 사용하거나 다른 매체에 재배포하기 위해서는 신박AI의 명시적인 서면 동의가 필요합니다.

위의 조건들을 위반할 경우, 저작권법에 따른 법적 조치가 취해질 수 있음을 알려드립니다.

본 고지 사항에 동의하지 않는 경우, 본 문서의 사용을 즉시 중단해 주시기 바랍니다.

